(Inwiefern) können Waldbrände in der Schweiz mittels Machine Learning prognostiziert werden

Olivier Meier

Betreuung:
Prof. Dr. Bastian Grossenbacher-Rieck

Departement für Informatik
Universität Fribourg

10. September 2026

Erklärung zur Eigenständigkeit und zur Verwendung generativer Sprachmodelle

Die Idee dieser Arbeit habe ich mir selbst ausgedacht und ausformuliert. Die grundlegende Problematik und darauf folgende Recherche sowie Datenbeschaffung habe ich alleine durchgeführt. Verschiedene Zwischenstände und daraus folgende Stossrichtungen der Arbeit wurden mit Herrn Prof. Dr. Bastian Grossenbacher-Rieck diskutiert. Den Text der folgenden Arbeit habe ich komplett selbst geschrieben. Einige Übersetzungen und wenige Formulierungen wurden mit Hilfe generativer Sprachmodelle diskutiert und angepasst.

Zum Erstellen der folgenden Prototypen wurde Claude.ai benutzt: API-Abfragen, insbesondere für Meteo- und Topografiedaten in grösserem Umfang, Plots und erläuternde Illustrationen, Confusion Matrices, SHAP-Analysen sowie den Prototyp der Webapplikation in Abschnitt 13.2 als *Proof of concept*. Weiter wurde Claude.ai dazu benutzt, Rohmodelle zu plausibilisieren und zu vergleichen, Benchmarks zu erstellen, und weiter auch Resultate und Stossrichtungen zu diskutieren.

Danksagung

An dieser Stelle gilt mein Dank Prof. Dr. Bastian Grossenbacher-Rieck, der diese Arbeit erst möglich gemacht hat, insbesondere auch durch seine Begleitung und ausführlichen Rückmeldungen.

Vielen Dank auch an Matin Mahmoudzadeh für seine Erläuterungen zur Modellierung seltener Ereignisse. Und zuletzt gilt mein Dank insbesondere auch Dr. Eva Bobst als Mentorin lebenslangen Lernens.

Inhaltsverzeichnis

1 Einleitung 1
1.1 Ausgangslage . . . 1
1.2 Fragestellung . . . 1

2 Existierende Vorhersagemodelle 3
2.1 Fire Weather Index und IGNIS . . . 3
2.1.1 IGNIS-Index . . . 4
2.2 INCENDI . . . 5
2.3 Sensorisches Frühwarnsystem FireLess II . . . 6
2.4 FireNiche . . . 6
2.5 FireScope.AI . . . 7

3 Datengrundlage Waldbrände 11
3.1 Waldbrand-Datensatz . . . 11
3.1.1 Koordinaten und deren Genauigkeit . . . 11
3.2 Brandgrösse . . . 11
3.3 Brandverursachung . . . 12
3.4 Bisaisonalität und menschliche Verursachung . . . 12
3.5 Höhenprofil und Bioregion . . . 14

4 Datengrundlage Meteorologie 17
4.1 Swiss National Basic Climatological Network . . . 17
4.1.1 Beschreibung Datensatz SNBCN . . . 18
4.2 SwissMetNet . . . 19
4.2.1 Beschreibung Datensatz SMN . . . 19

5 Datenaufbereitung und Feature Engineering 23
5.1 Meteodaten für Brandstandorte . . . 23
5.1.1 Ermittlung der nächsten umliegenden Stationen . . . 24
5.1.2 Sortierte Meteodaten je Station . . . 24
5.1.3 Gewichtetes Mittel aller Meteoparameter je Feuer . . . 24
5.1.4 Erstellung von Negativstichproben und Feature-Evaluation . . . 25

6 Basis-Modell: Modellierung und Evaluation 29
6.1 Modelldiskussion . . . 29
6.2 Splitstrategie: Aufteilung in Trainings- und Testdaten . . . 29
6.3 Modellauswahl . . . 30

6.4 Modelltraining . . . 31
6.4.1 Hyperparameter-Tuning . . . 31
6.4.2 Diskussion Hyperparameter-Tuning vs. Overfitting . . . 32
6.5 Modell-Evaluation . . . 33
6.5.1 Diskussion Feature-Importances . . . 34

7 Verbesserung der Trainingsdaten 37
7.1 Kritik der Negativstichproben . . . 37
7.2 Verbesserung der räumlichen Negativstichproben . . . 37
7.3 Resultat der verbesserten Negativstichproben . . . 39
7.3.1 Feature-Importances . . . 39
7.3.2 Overfitting . . . 40

8 Featureerweiterung Hangneigung und -ausrichtung 43
8.1 Grundüberlegungen . . . 43
8.2 Berechnung Hangneigung und Hangausrichtung . . . 43
8.2.1 Codierung der Hangausrichtung . . . 44
8.3 Plausibilisierung Hangneigung und -ausrichtung . . . 45
8.4 Evaluation des räumlich-erweiterten Modells . . . 45

9 Kontexterweiterung des Modells 49
9.1 Grundüberlegungen . . . 49
9.2 Kontexterweiterungen . . . 50
9.2.1 Erweiterung Höhenprofil . . . 50
9.2.2 Saisonale Kontextualisierung . . . 50
9.2.3 Kontextfenster Trockentage . . . 51
9.2.4 Vapor Pressure Deficit (VPD) . . . 53
9.3 Evaluation des kontexterweiterten Modells . . . 54
9.3.1 Modellvereinfachung durch Featurereduktion . . . 54
9.3.2 Diskussion exponentiell gewichteter Akkumulatoren . . . 56

10 Strukturerweiterung des Modells 59
10.1 Grundüberlegungen . . . 59
10.1.1 Evaluation der statischen Strukturerweiterung . . . 61

11 Modellvergleich 63
11.1 Grundüberlegungen . . . 63
11.2 Verifikation Modellauswahl . . . 63
11.3 Modellbewertung . . . 63

12 Modellevaluierung 67
12.1 Zeitliche Abhängigkeit und Durchmischung (*Shuffling*) . . . 67
12.2 Validierung durch Label-*Shuffling* . . . 67
12.3 Räumliche Kreuzvalidierung . . . 67
12.4 Evaluation Schwellenwert . . . 69

12.5 Evaluation veränderter Trainingsgewichtung 69

13 Konklusion und Ausblick 73
13.1 Abschliessendes Ergebnis der Modellierung 73
13.2 Praktische Anwendung des Modells 74
13.2.1 Farbskala zur Bewertung der Feuerwahrscheinlichkeit 75
13.2.2 Visuelle Plausibilisierung 77
13.3 Zusammenführung und Ausblick 77

Glossar 83

Literatur 85

1 Einleitung

1.1 Ausgangslage

Das Bundesamt für Umwelt (BAFU) geht davon aus, dass ein „weiterer Anstieg der Brandgefahr aufgrund des Klimawandels wahrscheinlich ist.“[1] Zur Einschätzung der tatsächlichen Gefahrenlage setzt das BAFU seit 2022 ein neues Waldbrandinformationssystem ein: IGNIS. Auf dem kanadischen System Fire Weather Index (FWI) basierend, wurde IGNIS dem Alpenraum angepasst.[2] Zur Berechnung der aktuellen Gefahrenlage[3] benötigt das System vier meteorologische Parameter: die Temperatur, die Luftfeuchtigkeit, die Niederschlagssummen und die Windstärke.[2] Laut MeteoSchweiz berücksichtigt IGNIS allerdings nicht alle Faktoren, die für die Entstehung von Waldbränden wichtig sind:

> Auch wenn das FWI-System weit verbreitet ist, so hat es doch seine Grenzen: Es werden noch nicht alle Faktoren, berücksichtigt, die für die Entwicklung von Waldbränden wichtig sind. Zum Beispiel die lokale Topografie oder das tatsächlich vorhandene brennbare Material (vom Untergrund bis hinauf zu den Baumkronen). Ausserdem wurde das in den 70er-Jahren entwickelte FWI-System für reine Kiefernwälder konzipiert. Dies kann dazu führen, dass das System den in der Schweiz anzutreffenden Mischungsgrad der Wälder (Anteil Laub- und Nadelbäume) nicht genau widerspiegelt. [2]

Die Vermutung liegt daher nahe, dass mehr Parameter zu einer genaueren Vorhersage führen könnten. Hierbei würden sich zusätzliche meteorologische Messdaten wie zum Beispiel Windstärke, Luftfeuchtigkeit oder Sonnenexposition anbieten. Neben meteorologischen Daten könnten zusätzliche Daten über den Baumbestand und damit auch die Bodenbeschaffenheit über eine Satelliten-Auswertung berücksichtigt werden.[1] Neben diesen Umweltdaten ist auch das Einpflegen von menschlichen Bewegungsmustern denkbar. Zukünftig wird das neue Wettermodell ICON [4, 2] zudem eine wesentlich genauere meteorologische Auflösung, insbesondere des Alpenraums, bieten.

1.2 Fragestellung

Bereits existierende Modelle zur Waldbrandvorhersage markieren zwei Enden eines Spektrums: FWI, IGNIS und INCENDI basieren auf festgelegten Formeln, FireNiche benützt ökologische Nischenmodellierung und damit eine klassische statistische Methode. FireScope.AI hingegen

[1] Die öffentlich zugänglichen Baumkataster sind bestenfalls von Städten vorhanden.

basiert auf einem ausgeklügelten, vielschichtigen und datenintensiven System, welches Textinformation und grosse Mengen an visuellen Daten kombiniert. Die vorliegende Arbeit soll sich zwischen diese Ausprägungen stellen und primär auf Basis von bestimmten meteorologischen und geographischen Parametern sowie des Schweizer Waldbrand-Datensatzes einen Ansatz des sogenannten *supervised learning* – ein Modell überwacht lernen zu lassen – verfolgen. Dieser Ansatz ermöglicht es zudem, die Relevanz einzelner Parameter aus den Daten zu erlernen, was die Interpretierbarkeit des Modells ermöglicht.

Mittels dieses Aufbaus soll 1) erkundet werden, ob Waldbrände in der Schweiz mittels Machine Learning prognostiziert werden können und 2) inwiefern diese Vorhersage durch das Einpflegen von zusätzlichen Parametern an Genauigkeit gewinnt.

Dazu werden im folgenden Kapitel zuerst die bestehenden Modelle als Referenzrahmen diskutiert. Darauf folgend, werden die Datenbestände der Waldbrände sowie meteorologische wie geographische Gegebenheiten untersucht. Diese Grundlage ermöglicht nach der Datenaufbereitung schliesslich das *Feature Engineering* und die Modellierung.

2 Existierende Vorhersagemodelle

2.1 Fire Weather Index und IGNIS

Das Schweizer Modell IGNIS wurde ursprünglich aus dem kanadischen *Fire Weather Index* entwickelt. Dieser setzt sich aus vier verschiedenen Grundparametern zusammen.[5] Drei primäre Parameter fliessen in verschiedene *Codes* ein, welche in erster Linie Feuchtigkeit abbilden. Ergänzend werden Windparameter eingespiesen, die das Ausbreitungsverhalten bereits entstandener Feuer abbilden soll. Das Resultat stellt schliesslich schlicht die Feuerintensität dar.[6]

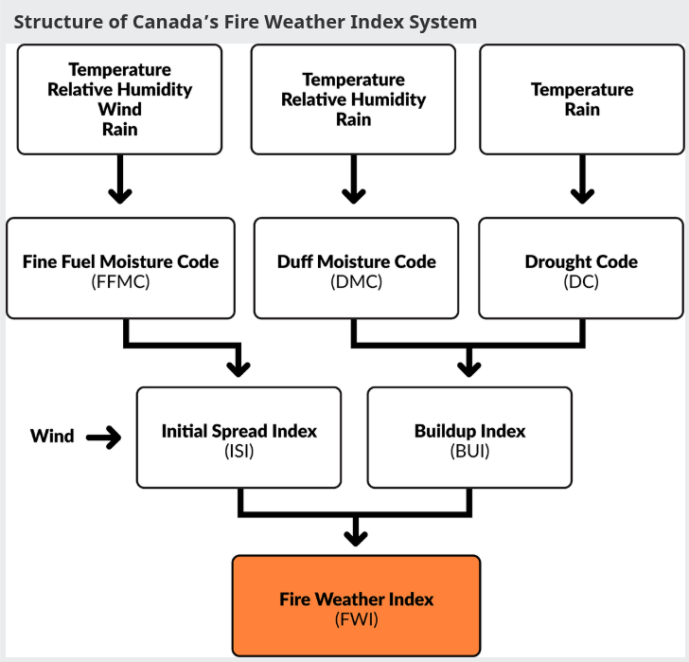


Abbildung 2.1: Struktur des Fire Weather Index System, Quelle: natural-resources.canada.ca,[5].

IGNIS wurde vom BAFU in Zusammenarbeit mit *Natural Resources Canada* aus dem FWI weiterentwickelt und den spezifischen Besonderheiten des Alpenraums angepasst.[2] Wie auch FWI ist IGNIS nur auf vier primäre meteorologische Parameter angewiesen: Temperatur, Luftfeuchtigkeit, Niederschlagssumme und Windstärke.[2]

> MeteoSchweiz liefert dem BAFU jeden Tag die Daten, die IGNIS für die Berechnung der Indizes braucht. Diese Indizes geben relevante Hinweise auf das mögliche Verhal-

ten und die Entwicklung eines Waldbrandes und erlauben es, den Feuchtigkeitsgehalt des Bodens und anderer brennbarer organischer Stoffe im Wald einzuschätzen.[2]

Anschliessend interpretieren „Expertinnen und Experten des Bundes und der Kantone [...] die IGNIS-Daten und bewerten damit die tägliche Waldbrandgefahr für die verschiedenen Warnregionen."[2] Das BAFU publiziert die mittels IGNIS berechnete aktuelle Gefahrenlage visuell aufbereitet.[7, 3]

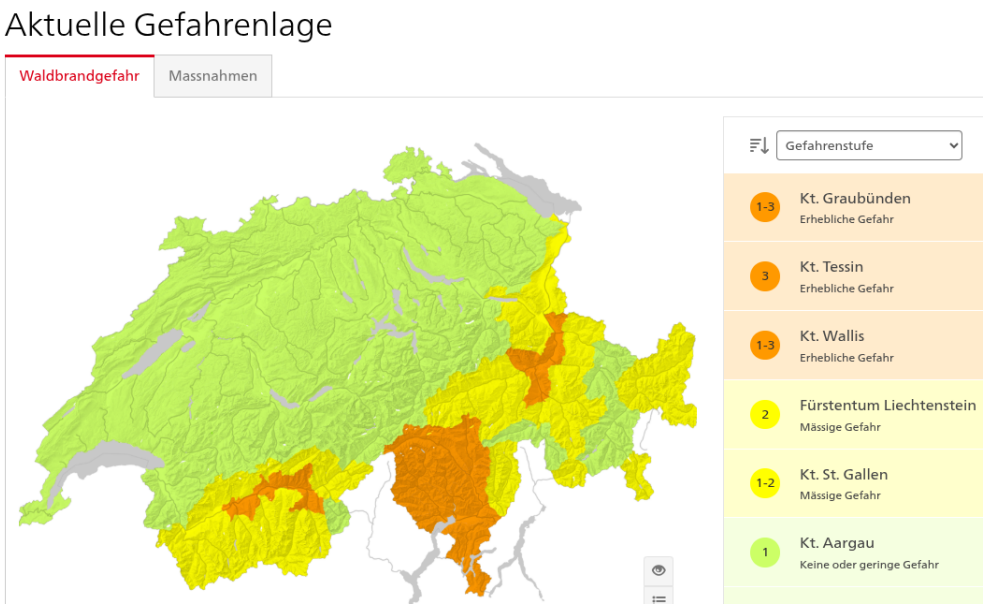


Abbildung 2.2: Visuelle Darstellung der Waldbrandgefahr auf waldbrandgefahr.ch, besucht am 25.05.2026

Maschinenlesbare Daten dieser Waldbrandwarnungen sind über den entsprechenden Linked Data Service (LINDAS)[8] mittels SPARQL abfragbar.[9] Leider sind nur Abfragen aktuell laufender Waldbrandwarnungen möglich – historisierte Daten können über diese Schnittstelle nicht abgerufen werden. IGNIS vorangegangen ist ein System namens *Flamma*, welches 2022 von IGNIS abgelöst worden ist. Die Daten dieses Systems sind teilweise in einem proprietären Format und weisen zudem Archivlücken auf.[1] Aus diesen Gründen ist es leider nicht möglich, die historisierten Vorhersagen in eine allfällige Auswertung und gegebenenfalls Weiterentwicklung des hier zu entwickelnden Modells einzubeziehen.

2.1.1 IGNIS-Index

Der dem FWI angelehnten Index des IGNIS-Systems wird nicht öffentlich publiziert. Die Abbildung 2.3 zeigt eine zur Illustration veröffentlichte rasterhafte Auflösung einer Gefahrenkarte des IGNIS-Systems am Tag eines Brandes in der Ortschaft Bitsch (Wallis), am 17.07.2023.[2][2]

[1] Mail von Davide Ferriroli, BAFU vom 15.4.2026

[2] Die Ortschaft befindet sich in der vertikalen und horizontalen Mitte des oben rechts angesiedelten höher aufgelösten Bereiches.

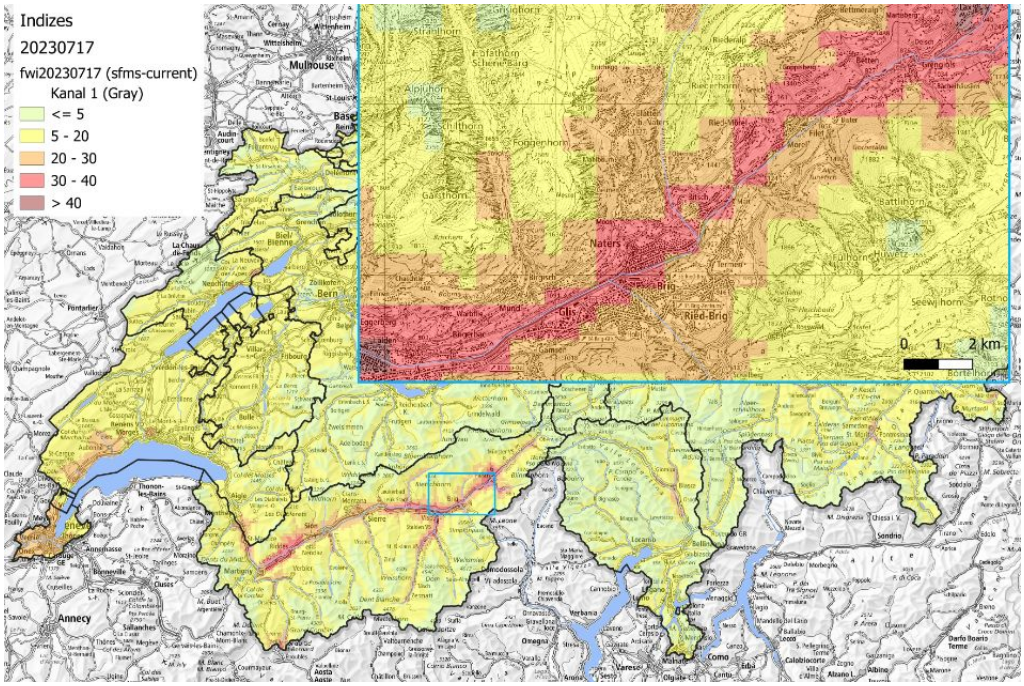


Abbildung 2.3: Darstellung FWI-Index auf IGNIS, Quelle MeteoSchweiz[2], besucht am 25.05.2026

2.2 INCENDI

Bei INCENDI handelt es sich um eine GIS-Anwendung, die in den Kantonen Graubünden und Wallis eingesetzt wird und die Waldbrandgefahr der verschiedenen Regionen[10] und als „Risikoprognosesystem“[11] dient.

> Diese computerunterstützte Applikation hat das Amt für Wald in Zusammenarbeit mit dem Geographischen Institut der Universität Zürich 1997 entwickelt. Mit INCENDI werden Messwerte der MeteoSchweiz in die bekanntesten Waldbrandmodelle implementiert. Gearbeitet wird in Graubünden hauptsächlich mit den kanadischen Waldbrandindices. INCENDI wurde im Jahr 2005 komplett überarbeitet und an die neuen Anwenderbedürfnisse angepasst. [12]
>
> INCENDI integriert die täglich gemessenen Meteodaten von Meteo-Schweiz in eine Oracle Datenbank und berechnet mehrere meteobasierte Waldbrandindizes für diese Meteo-Standorte (Messstationen). Schliesslich erfolgt die Ausgabe von standardisierten Waldbrandgefahrenkarten.[6, S. 9]

Informationen zur eigentlichen Berechnung sind leider nicht öffentlich verfügbar. Das kantonale Waldbrandbekämpfungskonzept des Kantons Wallis beschreibt jedoch gewisse grundlegende Punkte zur Funktionsweise von INCENDI:[3]

[3] Es ist anzunehmen, dass die Parameter von INCENDI für den Kanton Wallis nachträglich spezifisch angepasst wurden.

> Die drei Primärindizes FFMC, DMC und DC [vgl. obige Abbildung zur Struktur des FWI 2.1] beschreiben den Feuchtigkeitsgehalt des Brandgutes [...] Im Kanton Graubünden wird der Index DC verwendet. Bei diesem Index werden die Faktoren Wind und Luftfeuchtigkeit nicht berücksichtigt. Für den Kanton Wallis muss noch abgeklärt werden, mit welchem Index in Zukunft gerechnet werden soll. Ein Vorschlag wäre der Index FFMC; bei diesem Index werden Temperatur, relative Luftfeuchtigkeit, Wind und Niederschlag einkalkuliert. Mit diesem Index würden alle wesentlichen Faktoren des kontinentalen Klimas [des Kantons Wallis] berücksichtigt[6, S. 9]

2.3 Sensorisches Frühwarnsystem FireLess II

Die obigen erwähnten klassischen Waldbrandprognose-Methoden (*FWI*, *IGNIS*) arbeiten im Wesentlichen mit meteorologischen Daten, die Feuchtigkeit anzeigen. Um nicht auf meteorologische Parameter angewiesen zu sein, wurde im Tessin erprobt, mit dem Frühwarnsystem *FireLess II* die Feuchtigkeit des Untergrunds direkt durch Sensoren zu messen.

> [*FireLess II*] erfasst unmittelbare Brandrisiken direkt im Waldboden, sagt Marco Conedera, Forstingenieur an der WSL [...]. Sensoren stecken in der Streuschicht aus Blättern, Nadeln und Ästen sowie in der darunterliegenden Humusschicht und messen die Feuchtigkeit. Die Messwerte werden einem Server per Mobilfunk übermittelt. So können Forstexperten die Gefahr online abschätzen: Ist die Streuschicht trocken, aber der darunterliegende Humus noch feucht, können Waldbrände leicht ausbrechen, sie breiten sich allerdings nur langsam aus. [13]

FireLess II wird aber aufgrund der Wartungsanforderungen nicht benützt[4] und zur Implementierung in grösserem Stil finden sich in der Literatur keine Hinweise.

2.4 FireNiche

Bei *FireNiche* handelt es sich um eine Methode der Eidgenössischen Forschungsanstalt für Wald, Schnee und Landschaft (WSL), Waldbrände in Anlehnung an ökologische Nischenmodellierung nach der Maximum-Entropie-Methode (MAXENT) zu modellieren:

> [FireNiche] verwendet [...] die statistisch bekannten Waldbrandtage der Vergangenheit. Den Umweltparametern entsprechen die Wetterinformationen. Die „Waldbrand-Nische“ wird durch die besondere Wetterkonstellation definiert, die an den Brandtagen herrschte. [14]

Als Grundlage dieser Berechnungen dienen die erfassten Waldbrände der Jahre 1981 bis 2012 des Kantons Tessins. Mittels *FireNiche* werden Gefahrenregionen bestimmt und die Brandrisiken dieser Gefahrenregionen sind über eine Webanwendung abrufbar:

[4] Mail von Gianni Boris Pezzatti, WSL vom 20.10.2025

> Meteoschweiz-Daten [werden] vollautomatisch aufbereitet, die nötigen Waldbrand-Wetterindizes und der FireNiche Index errechnet [...] in Gefahrenklassen eingeteilt und auf einer internen Web-Oberfläche dargestellt, die den Fachspezialisten (Forst- und Meteodienste, Feuerwehren) als Entscheidungshilfe zur Verfügung steht. [14]

FireNiche benutzt zur Modellierung zwölf Parameter[5] Die vorhandenen Stichproben beziehungsweise Feuerereignisse werden in die zwei Saisons Winter und Sommer unterteilt, wobei letztere zusätzlich nach Verursachung (anthropogen oder natürlich) unterteilt wird.[15, S. 5] Die Resultate von FireNiche sind in De Angelis, Ricotta, Conedera und Pezzatti [15] evaluiert und variieren zwischen durchschnittlichen (k-fold cross-validated) **AUC** von **0.7516** bis **0.8517**. FireNiche klassifiziert binär und modelliert die Tage, an denen es nicht brennt, als echte Absenzdaten:

> Each day of the study period and of the corresponding fire regime represents a binary response variable for which we considered the days with at least one fire ignition (fire days) as presence and the days without fire ignitions as absence. [15, S. 7]

Da echte Absenzdaten verwendet werden (die uns bekannten Tage, an denen es nicht brannte) und nicht die häufig in Nischenmodellierung vorkommende Annahme eines unbestimmten *Backgrounds*, unterliegt die AUC von FireNiche in diesem Fall nicht der von Jiménez-Valverde [16] vorgebrachten Kritik[6], was für spätere Vergleiche wichtig ist. In Abbildung 2.4 sind obige Resultate und interessanterweise auch durchschnittliche AUC-Werte anderer Modelle ablesbar: Die drei schwarzen Marker beschreiben die unterschiedlichen Ausprägungen der FireNiche-Modellierung.[7] Die Label in Grossschrift und den grauen Markern beschreiben die AUC anderer Modelle wie zum Beispiel FWI und dessen einzelnen Primärparameter (FFMC, DMC und DC)[8], die einen **AUC** von **0.67** bis **0.76** erreichen.[9]

2.5 FireScope.AI

FireScope.AI sagt die Waldbrandgefahr anhand Sentinel-2 Satellitendaten[10] des Vorjahres voraus. Dazu werden 3'000 Feuerereignisse und 2'000 bekannte Nicht-Ereignisse des European Forest Fire

[5] Lufttemperatur, Luftfeuchtigkeit, Windgeschwindigkeit, Niederschlag, Bedecktheit des Himmels (*CloudCover*), Schneedecke (*SnowCover*), Total Niederschlag der letzten sieben Tage, Tage seit den letzten Niederschlägen (*DaysSinceRain*), Summe der letzten Niederschläge (*consecutive days with rain* und *LastRainSum*), Taupunkt und Vapour Pressure Deficit (VPD).

[6] „AUC is only truly informative when there are true instances of absence available and the objective is the estimation of the realized distribution."[16]

[7] Die Label 'meteo', 'indices' und 'mixed' beschreiben „combinations of meteorological parameters, fire weather indices or both as input variables for modelling", die drei Boxen entsprechen den drei Saisonalitäten (Winter, Sommer: anthropogen oder natürlich verursacht).

[8] Vergleiche hierzu Abbildung 2.1.

[9] Aufgrund dieser anderen aufgeführten Modell ist hier auch von AUC.bg die Rede, da gewisse Modelle teilweise keine echten Negativstichproben aufweisen: „Where no reliable absence data is available, the AUC is calculated by distinguishing presence from the whole background (AUC.bg)"[15, S. 9] Nichtsdestotrotz sind die AUC-Werte der Modelle mit echten und Modellen ohne echte Absenzdaten doch vergleichbar: „approach allowed us to show that the values resulting from the traditional AUC and from the AUC.bg were very similar [...] We therefore opted to use the AUC.bg to evaluate and make both the Maxent and logistic models comparable."[15, S. 9]

[10] https://sentinels.copernicus.eu/web/sentinel/copernicus/sentinel-2

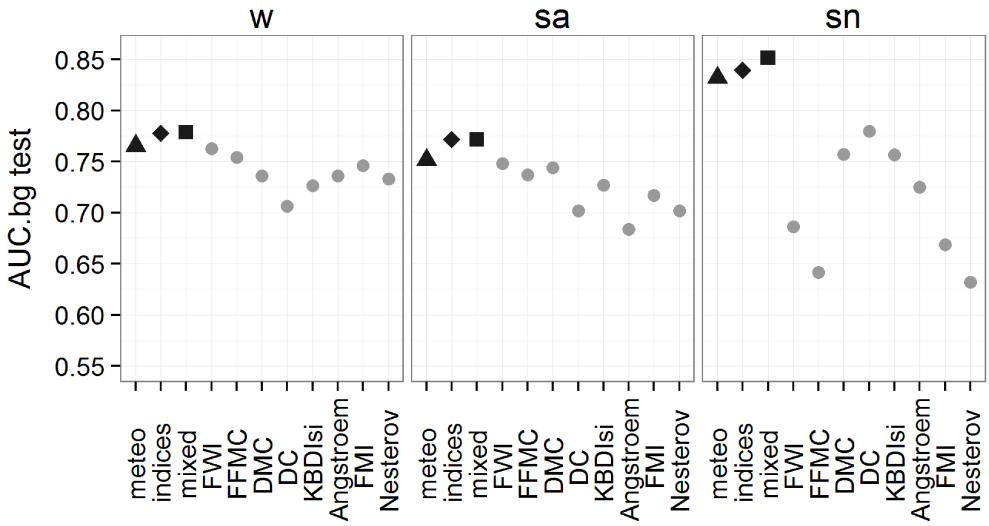


Abbildung 2.4: AUC verschiedener Modelle, Quelle: De Angelis, Ricotta, Conedera und Pezzatti [15, S. 11]

Information System[11] aus den Jahren 2018 – 2025 ausgelesen. Abgedeckt wird ein grossflächiger Bereich über eine Fläche von 5.7 Millionen km² und 55'000 Regionen.[17] Das Modell wird um Niederschlag, Feuchtigkeit, Windgeschwindigkeit und -richtung erweitert. Diese Daten werden (in monatlicher Auflösung) mittels NASA POWER[12] bezogen, um nicht auf lokale Messstationen angewiesen zu sein. Diese optischen Satellitendaten werden mit den meteorologischen Daten an ein Vision-Language Modell (VLM) Qwen2.5-VL[13] weitergereicht, welches lernt, weitere Faktoren mittels *chain-of-thought reasoning* zu berücksichtigen.[14]

Trainiert wird das Modell mit Feuerereignissen der Vereinigten Staaten, evaluiert an obiger europäischer Datengrundlage. Das Modell soll also auf europäische und andere Regionen übertragbar sein und trotz des Domain-Shifts generalisieren.[18] Hierbei erreicht FireScope.AI **ROC-AUC-Werte** von **0.750**, verglichen mit dem FWI, der in diesem Setting nur 0.551 erreicht.[17][15]

[11] EFFIS: https://forest-fire.emergency.copernicus.eu
[12] https://power.larc.nasa.gov/data-access-viewer/
[13] https://qwen.ai/blog?id=qwen2.5-vl
[14] „so that it learns to consider intermediate factors such as vegetation density, dryness, temperature, precipitation, humidity, wind, and visible land patterns before producing its final risk estimate."[17]
[15] Hinsichtlich der Vergleichbarkeit der AUC-ROC-Werte ist festzuhalten, dass FireScope.AI mit den europäischen Feuerereignissen einerseits echte Absenzdaten benützt, im Bereich der Satellitendatenauswertung eines *background* annimmt: „due to the stochastic nature of ignition, we treat non-burnt areas within wildfire tiles as background rather than negative samples"[18, S. 13].

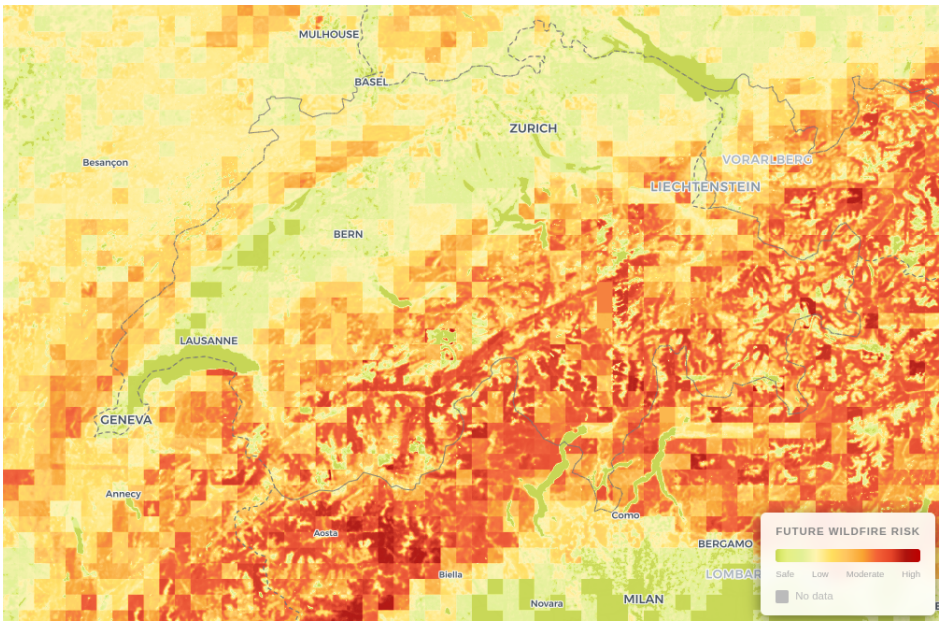


Abbildung 2.5: Ausschnitt Schweiz aus FireScope Gefahrenkarte 2026, Quelle FireScope.AI[17], besucht am 7.8.2026

3 Datengrundlage Waldbrände

3.1 Waldbrand-Datensatz

Die Eidgenössische Forschungsanstalt für Wald, Schnee und Landschaft, WSL führt eine nationale Waldbranddatenbank, SwissFire[19]. Von Herrn Pezzatti vom WSL habe ich freundlicherweise die Daten seit Messbeginn 1900 erhalten. Der erhaltene Datensatz umfasst **insgesamt 11'991 erfasste Waldbrände** in der Schweiz, von 1900 bis Ende 2025.[1] Im Folgenden wird dieser Waldbrand-Datensatz analysiert und die Ausprägungen der Waldbrände hinsichtlich der späteren Integration in ein Modell untersucht.

3.1.1 Koordinaten und deren Genauigkeit

Die Koordinaten im Datensatz der Waldbrände sind aus historischen Gründen im alten Format CH1903 (LV03) und nicht im moderneren und genaueren LV95. Die relative Nachbargenauigkeit von Punkten in LV03 beträgt 3 bis 5 cm.[20] Allfällige Transformationen zwischen LV03 und LV95 können zu Verzerrungen von höchstens 1.6 m führen.[21]

Da Waldbrände in den allermeisten Fällen eine wesentlich grössere Ausbreitung aufweisen und zudem die genaue Festlegung einer Brandkoordinate herausfordernd ist, ist der Verlust an Genauigkeit beim Wechsel von LV03 zu LV95 für die folgenden Zwecke vernachlässigbar.

3.2 Brandgrösse

Die meisten Waldbrände bleiben relativ klein und entwickeln sich nicht zu Grossbränden:

> 70 von hundert Feuerereignissen brennen weniger als 0,5 Hektaren Wald ab. Sie verursachen keine Probleme und ergeben zusammengerechnet weniger als fünf Prozent der gesamten verbrannten Fläche. „Aber grossflächige Brände dürfen nicht entstehen. Ihre Auswirkungen auf die Sicherheit der Bevölkerung können gravierend sein.“ [13]

Die folgende Untersuchung widmet sich in erster Linie der Feuerentstehung und deren Vorhersage und nicht der möglichen Brandgrösse. Unabhängig von einer möglichen Grösse interessiert daher schlicht die primäre Feuerentstehung.

[1] Die Daten gehören den „Kantonen und [...] Bund, können aber für Forschungszwecke benutzt werden.“ (E-Mail von Hr. Boris Pezzatti, WSL, vom 2.5.2025.) Dennoch sollten sie aber nicht ohne weitere Erlaubnis publiziert werden.

3.3 Brandverursachung

Der untersuchte Datensatz kategorisiert die Ursachen der Waldbrände als 'anthropogen', 'unbekannt' oder durch 'Blitzschlag' verursacht. Anthropogen wird hierbei weiter unterteilt in Kategorien wie 'privat (Touristen, Wanderer, weggeworfene Raucherwaren, sonstiges)', 'Eisenbahn', 'Brandstiftung', 'ungenügend gelöschte Feuerstellen', 'Forstwirtschaft' u.v.a. Die Waldbrände des Datensatzes sind damit in rund 77% als anthropogen verursacht kategorisiert und in beinahe 6% der Fälle durch Blitzschlag erklärt. In rund 17% der Fälle sind die Ursachen als unbekannt angegeben. Diese Kategorisierung scheint konsistent mit der Annahme des BAFU, dass „90% der Waldbrände in der Schweiz [...] von uns Menschen verursacht"[22] werden.[2]

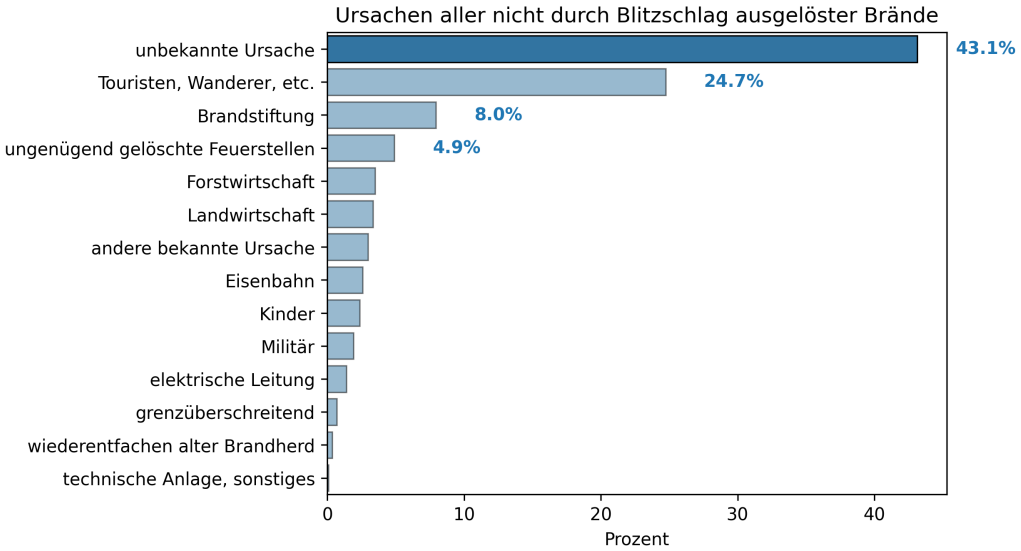


Abbildung 3.1: Brandursachen ohne Blitzschläge (Ursachenbeschrieb gekürzt)

Wenn der Datensatz hinsichtlich der Anzahl Feuer pro Jahr analysiert wird, fällt sofort auf, dass die zweite Hälfte des 20. Jahrhunderts wesentlich mehr Brände aufweist. Deutlich zu sehen ist auch die bereits diskutierte anthropogene Verursachung eines Grossteils der Brände. Die Brandursache Blitzschlag scheint hingegen über Zeit relativ konstant zu bleiben. Auch Extremereignisse wie der Hitzesommer 2003 mit Temperaturen von „3 bis 5 $°C$ über dem langjährigen Mittelwert"[23] sind als eindeutiger Ausschlag ablesbar.

3.4 Bisaisonalität und menschliche Verursachung

Die Untersuchung der Verteilung der Brände auf die jeweiligen Monate, zeigt deutlich auf, dass Waldbrände in der Schweiz zweimal Hochsaison haben: Anfangs April und Ende Juli. In Abbildung 3.3 wird zudem deutlich, dass Blitzschläge nur von Mai bis September für Waldbrände

[2] Die anthropogene Verursachung ist im SwissFire-Datensatz ebenfalls aufgeschlüsselt, aber alles andere als klar: Um die 43% der nicht durch Blitzschlag ausgelösten Brände weisen eine unbekannte Ursache auf.

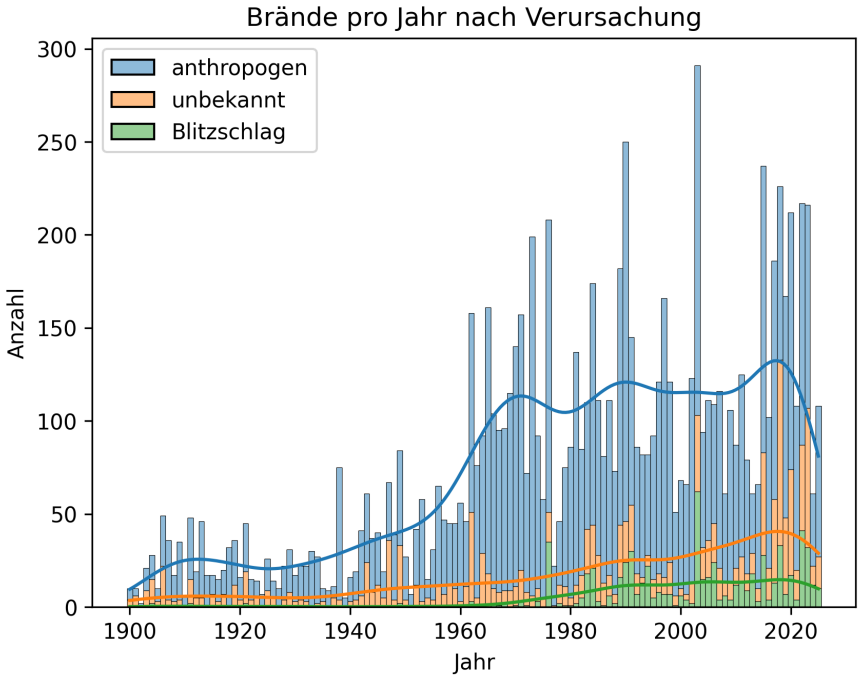


Abbildung 3.2: Feuer pro Jahr nach Verursachung

verantwortlich gemacht werden können. Interessanterweise fallen die Brände, deren Ursache unbekannt ist, ebenfalls in diesen Zeitraum.

> In der Schweiz herrscht die höchste Gefahr für Grossflächenbrände im März und April. Laubbäume haben noch keine Blätter und die schon starken Sonnenstrahlen können die Streuschicht aus Blättern und Ästen sowie den Humus rasch trocknen, besonders wenn die Niederschläge gering sind und womöglich noch der Föhn bläst. Dann genügen ein Zigarettenstummel, ein schlecht überwachtes oder gelöschtes Feuer, um ein sich rasch ausbreitendes Oberflächenfeuer auszulösen [...] Sobald die Blätter spriessen, endet die erste Waldbrandsaison. Dank der schützenden Baumkronen entsteht ein feuchtes Klima im Wald und die Feuchtigkeit im Boden steigt. Feuer können kaum ausbrechen oder sich ausbreiten. Die Gefahr steigt meistens im Juli und August wieder, mit Sommerwetter, Blitzschlägen und erhöhten menschlichen Aktivitäten. Meist brechen nur mottende Bodenfeuer aus, die bloss kleine Flächen abbrennen. Gefährlich können aber Brände in trockenen Nadelwäldern werden, etwa in Kieferwäldern wie dem Pfynwald im Wallis.[13]

Das BAFU verortet erhöhte Waldbrandgefahr „Im Winter und anfangs Frühling [...] besonders wenn sich eine Föhnlage einstellt“. [22] Im Sommer hingegen aufgrund ausbleibendem Tau „insbesondere in sonnenexponierten Gebieten und bei trockenen Winden wie Bise oder Föhn“.[22] Mögliche Brandindikatoren sind daher Trockenheit und Wind. Aber die Gefahr menschenge-

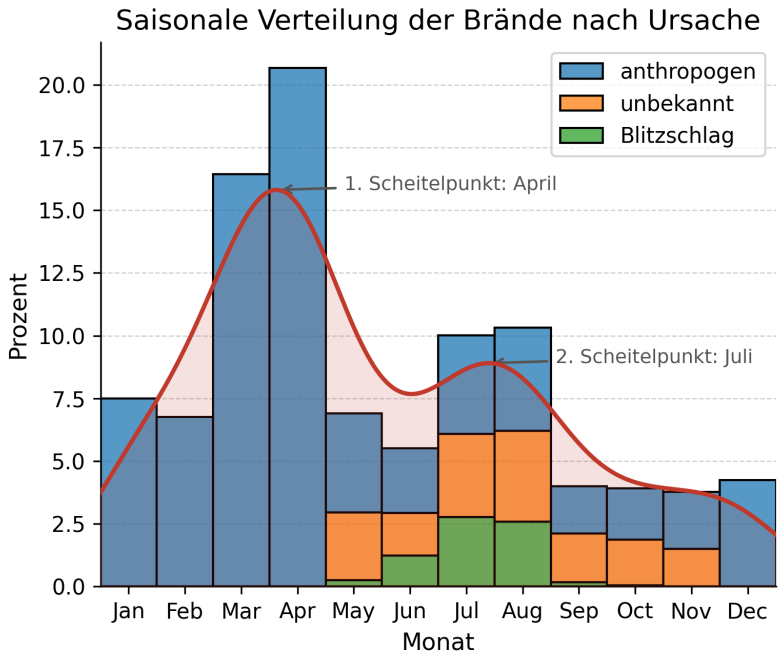


Abbildung 3.3: Saisonale Verteilung der Brände

machter Feuer wird nicht nur durch meteorologische Parameter bestimmt, sondern auch durch menschliche Bewegungsmuster. Natural Resources Canada schreibt hierzu:

> [H]uman activity is creating ignition sources in or near the forest (for example, clear patterns can appear as clusters close to populated areas, roads and railways)[5]

Auch das BAFU betont die menschlichen Aktivitätsmuster, denen zusätzliche Aufmerksamkeit zuteil kommen muss.

> Rund 90 % der Waldbrände entstehen durch menschliche Aktivitäten, weshalb diese im Rahmen der Waldbrandgefahrenbeurteilung berücksichtigt werden müssen (z.B. Ostern im Tessin). [22]

3.5 Höhenprofil und Bioregion

Interessant ist auch die Aufschlüsselung nach Höhenmeter in Abbildung 3.4: Während sich unbekannte Brandursachen einigermassen gleich über alle Ereignisse verteilen, sind Blitzschläge als Ursache am häufigsten auf über 1500 m.ü.M. verortet. Anthropogene Verursachung ist hingegen im Mittel- und Flachland deutlich häufigste Brandursache. Auch die Verteilung nach der sogenannten Bioregion in Abbildung 3.5 ist aufschlussreich: Der Grossteil der Waldbrände ist auf der Alpensüdseite verortet, gefolgt von der Alpenregion. Abbildung 3.6 zeigt dies ebenfalls sehr deutlich auf. Anthropogen verursachte Brände verteilen sich hingegen relativ gleichmässig über

die gesamte Schweiz.

Nach dieser grundlegenden Untersuchung des Waldbrand-Datensatzes wird sich das folgende Kapitel nun der verfügbaren meteorologischen Datengrundlage widmen.

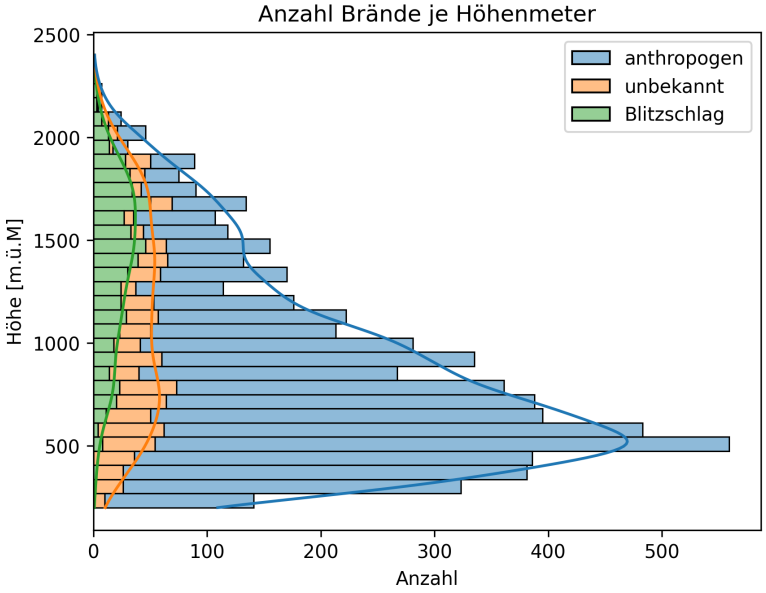


Abbildung 3.4: Brandverteilung je Höhenmeter

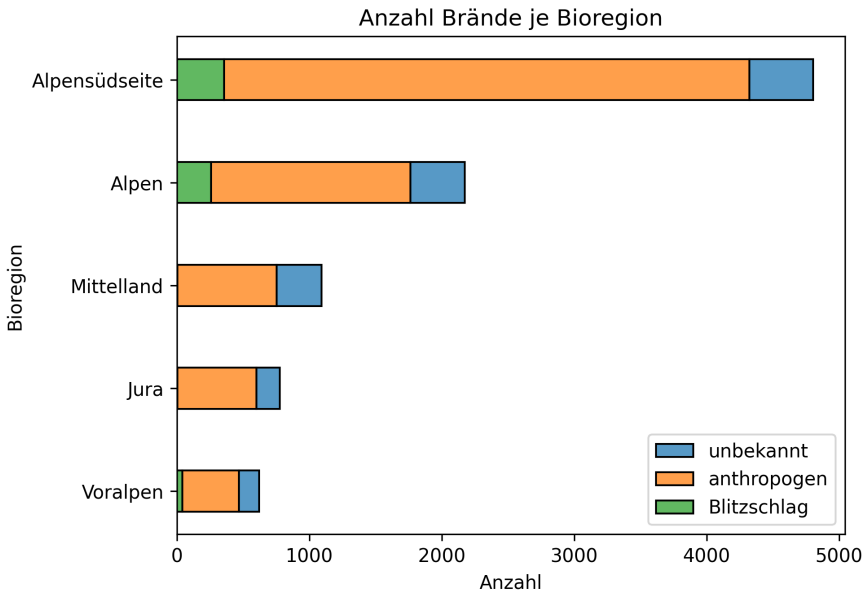


Abbildung 3.5: Brandverteilung je Bioregion

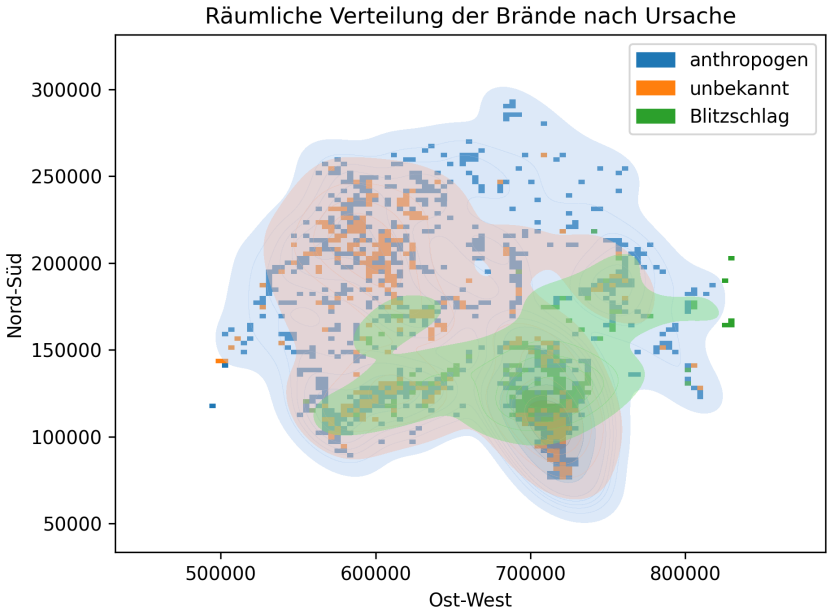


Abbildung 3.6: Räumliche Verteilung nach Ursache

4 Datengrundlage Meteorologie

4.1 Swiss National Basic Climatological Network

Nach der Untersuchung des Waldbrand-Datensatzes widmet sich dieses Kapitel der zweiten Datengrundlage: den verfügbaren meteorologischen Messnetzen der Schweiz: Die Schweiz betreibt mit dem *Swiss National Basic Climatological Network (SNBCN)* ein nationales Netzwerk an Messstationen. Dieses besteht aus 29 Klima-Monitoring Stationen und 46 Niederschlagsstationen und reicht bis zum Messbeginn 1864 zurück. Im Verlaufe der Zeit ist es zu Änderungen und Anpassungen der Messmethodik gekommen. Um die Daten dennoch über Zeit vergleichen zu können, sind sie von MeteoSchweiz entsprechend homogenisiert[24] worden.[1]

Die meteorologischen Daten von MeteoSchweiz stehen unter der Creative Commons Licence CC BY 4.0.[25] und sind über eine REST-API zugänglich[26]. Damit ist jede der insgesamt 75 Stationen abfragbar. Über den Entry-Point[27] gelangen wir an Metadaten mit Informationen unter anderem über alle Stationen[28] und Parameter[29] sowie die als *items* abgebildeten Messstationen.[30] Schliesslich können wir von jeder Station historisierte Wetterdaten seit Messbeginn 1.1.1864 erhalten.[31][2] Abfragen können wir die Daten über data.geo.admin nach folgendem Schema:

```
data.geo.admin.ch/ch.meteoschweiz.ogd-nbcn/{statId}/ogd-nbcn_{statId}_{sfx}.csv.
```

Wobei der Suffix `{sfx}` in unserem Falle jeweils *d_historical* lautet und die Stations-ID `{statId}` kleingeschrieben wird. Historische Daten der Messstation Bern beispielsweise können wie folgt abgefragt werden:

```
https://data.geo.admin.ch/ch.meteoschweiz.ogd-nbcn/ber/ogd-nbcn_ber_d_historical.csv
```

Diese Messdaten enthalten einen codierten Parameter, bestehend aus einem kurzen Bezeichner (*shortname*), längerer verschiedensprachiger Bezeichnungen und Angaben zum Datentyp.

[1] Homogenisierung erfolgt zum Beispiel bei der Versetzung einer Messstation oder dem Wechsel von Sensorik oder ähnlichem. Dies ist insbesondere wichtig, wenn beispielsweise Temperaturveränderungen über längere Zeit untersucht werden und Trends analysiert werden sollen. Wir nehmen an, dass Untersuchungen aktueller Waldbrandgefahr nicht auf homogenisierte Daten angewiesen sind, da die untersuchten Zeiträume derart klein sind, dass eine fehlende Homogenisierung als vernachlässigbar erscheint.

[2] Wenn auch auf eine ursprünglich beschränkte Anzahl Parameter und teilweise lückenhafter Messreihen.

4.1.1 Beschreibung Datensatz SNBCN

Die Beschreibung der Meta-Parameter von MeteoSchweiz [29, Siehe weiter oben.] enthält unter Anderem für unseren Zweck geeignet erscheinenden folgenden Parameter:

- **ths200d0** - *Lufttemperatur 2 m über Boden; homogenes Tagesmittel*
- **ths200dn** - *Lufttemperatur 2 m über Boden; homogenes Tagesminimum*
- **ths200dx** - *Lufttemperatur 2 m über Boden; homogenes Tagesmaximum*
- **fhs010m0** - *Windgeschwindigkeit skalar; homogenes Monatsmittel* (tägliche Messungen nicht verfügbar)

Die folgende Monatssumme des Niederschlags und Anzahl Niederschlagstage erlauben die Berechnung eines täglichen Niederschlagsschnitts:

- **rhs001m0** - *Anzahl Tage im Monat mit Niederschlag* $\geq 1\,mm$
- **rhs150m0** - *Niederschlag; homogene Monatssumme* (tägliche Messungen nicht verfügbar)

Weiter verfügt der Datensatz auch über Luft- und Dampfdruck:

- **phsstam0** - *Luftdruck auf Barometerhöhe; homogenes Monatsmittel*
- **pva2hsm0** - *Dampfdruck 2 m über Boden; homogenes Monatsmittel*

Dies erlaubt die Berechnung der relativen Luftfeuchtigkeit RH als Verhältnis des Dampfdrucks e_a zum aktuellen Sättigungsdampfdruck e_s bei Lufttemperatur T. e_a entspricht dem gemessenen Dampfdruck [hPa] und e_s dem Sättigungsdampfdruck [hPa] bei der aktuellen Temperatur, welcher mittels der Formel von Magnus berechnet wird.[32]

$$\mathrm{RH} = \frac{e_a}{e_s} \cdot 100 \quad \simeq \frac{e_a}{6.112 \cdot \exp\left(\dfrac{17.67 \cdot T}{T + 243.5}\right)} \cdot 100 \tag{4.1}$$

Grösstenteils basieren die Berechnungen des FWI auf Messungen um die Mittagszeit.[33] Das uns bekannte Tagesmaximum **ths200dx** wird zuverlässig ein paar Stunden nach der Mittagszeit erreicht[33, S. 44], ist daher plausibel und erlaubt eine trockenere und damit akzentuiertere Schätzung als das Tagesmittel. Zusätzlich eingesetzt werden könnten folgende Parameter, die vom klassischen FWI nicht berücksichtigt werden:

- **shs000m0** - *Sonnenscheindauer; homogene Monatssumme*
- **ths30xm0** - *Hitzetage* ($\geq 30°C$)*; Monatssumme, homogen*

Die SNBCN-Datensätze reichen zwar sehr weit zurück, bieten in ihrer Auflösung für die meisten Parameter häufig aber nur monatliche Auflösung und sind daher für die Vorhersage von Bränden weniger interessant als eine tägliche Auflösung.

4.2 SwissMetNet

Neben dem SNBCN können meteorologische Daten auch über *SwissMetNet (SMN)* abgerufen werden. SMN erlaubt den Zugriff auf tägliche Messungen von über 100 Stationen.[3] Diese Daten sind im Unterschied zu obigen SNBCN-Daten nicht homogenisiert. Auch verfügen SMN-Datensätze über andere Parameter als die obigen SNBCN-Datensätze, sind aber in ihrem Umfang vergleichbar. Die tägliche Auflösung und das wesentlich grössere Stationsnetz sind ein wesentlicher Vorteil gegenüber den Datensätzen des SNBCN. Mittels folgendem Kommandozeilenbefehl[4] können über data.geo.admin.ch/api/stac/v1/collections/ch.meteoschweiz.ogd-smn/items Datensätze mit täglicher Auflösung bis teilweise weit ins 19. Jahrhundert von rund 100 Stationen heruntergeladen werden:

```
curl -s "https://data.geo.admin.ch/api/stac/v1/collections/ch.meteoschweiz.ogd-smn/items" \
| jq -r '
  .features[].assets
  | to_entries[]
  | select(.key | test("_d_historical\\.csv$"))
  | .value.href
' \
| xargs -n 1 curl -O
```

4.2.1 Beschreibung Datensatz SMN

Die Beschreibung der Meta-Parameter von MeteoSchweiz (siehe weiter oben)[5] enthält viele geeignet erscheinende Parameter, aber viele davon sind leider nicht in den eigentlichen Datensätzen zu finden. Historische Messstationen wie *BER*, mit ausführlichen Datensätzen, enthalten bestenfalls folgende Parameter:[6]

- **prestad0** - *Luftdruck auf Barometerhöhe (QFE); Tagesmittel*
- **tre200dx** - *Lufttemperatur 2 m über Boden; Tagesmaximum*
- **tre200dn** - *Lufttemperatur 2 m über Boden; Tagesminimum*
- **gre000d0** - *Globalstrahlung; Tagesmittel*
- **ure200d0** - *Relative Luftfeuchtigkeit 2 m über Boden; Tagesmittel*
- **pva200d0** - *Dampfdruck 2 m über Boden; Tagesmittel*
- **fu3010d0** - *Windgeschwindigkeit (skalar); Tagesmittel in km/h*

[3] https://www.meteoswiss.admin.ch/weather/measurement-systems/land-based-stations/automatic-measurement-network.html und https://www.meteoschweiz.admin.ch/service-und-publikationen/service/open-data.html

[4] In dieser Form auf Linux lauffähig, dürfte aber auf allen Betriebssystemen mit curl und jq vergleichbar ausführbar sein.

[5] https://data.geo.admin.ch/ch.meteoschweiz.ogd-smn/ogd-smn_meta_parameters.csv

[6] QFE bezeichnet Luftdruck auf Stationshöhe, ohne Höhenkorrektur.

- **wcc006d0** - *Föhnindex; Tageswert*
- **rre150d0** - *Niederschlag; Tagessumme 6 UTC - 6 UTC Folgetag*

Der SMN-Datensatz enthält also wesentlich mehr interessante Parameter als der SNBCN-Datensatz und dies zudem in täglicher Auflösung. Wenn wir alle SMN-Datensätze auf ihre Vollständigkeit hin überprüfen, sehen wir leider, dass der Föhnindex **wcc006d0** und die Globalstrahlung **gre000d0** bei sehr wenigen Stationen und zudem erst sehr spät vollständig erfasst wurde - daher streichen wir diese Werte. Weiter entfernen wir die Stationen, welche nicht über alle restlichen Parameter verfügen.[7] Der daraus entstehende Datensatz [8] enthält schliesslich noch 79 Stationen mit den übriggebliebenen folgenden sieben Parameter[9]:

- **rre150d0** - *Niederschlag; Tagessumme 6 UTC - 6 UTC Folgetag*
- **tre200dn** - *Lufttemperatur 2 m über Boden; Tagesminimum*
- **tre200dx** - *Lufttemperatur 2 m über Boden; Tagesmaximum*
- **fu3010d0** - *Windgeschwindigkeit (skalar); Tagesmittel in km/h*
- **pva200d0** - *Dampfdruck 2 m über Boden; Tagesmittel*
- **prestad0** - *Luftdruck auf Barometerhöhe (QFE); Tagesmittel*
- **ure200d0** - *Relative Luftfeuchtigkeit 2 m über Boden; Tagesmittel*

Da die Messstationen im Verlaufe der Zeit erweitert wurden, verfügen sie erst ab einem gewissen Jahr vollständig über obige Parameter. Wir können entweder retrospektiv weit zurück, haben aber im schlechtesten Fall nur wenige Stationen mit ebensolchen vollständigen Messungen oder wir schränken den zu untersuchenden Zeitraum ein und erhalten eine grosse Anzahl an Stationen, aber nur ein kleines Zeitfenster. Es muss also eine Güterabwägung vorgenommen werden: ab welchem Zeitpunkt verfügen wir über eine als hinreichend eingeschätzte Anzahl an Stationen mit vollständigen von uns gewünschten Parametern?

Bei näherer Betrachtung unserer eingeschränkten Auswahl wird klar, dass ab und an einzelne Stationen tatsächlich über mehrere Tage keine Werte aufweisen[10]. Wir schwächen die Bedingung der Vollständigkeit ab und fordern, dass nur mindestens 80% der erfassten Tage auch Werte aufweisen.[11] Die tatsächlich erfassten Waldbrände in Abbildung 3.2 zeigen, dass die Erfassung vermutlich überhaupt erst ab den 1960ern systematisch erfolgte. Die Anzahl an Stationen mit $\geq 80\%$ von

[7] Stationen (entfernt) mit unvollständigen Datensätzen: AEG, BAN, BIA, BIN, BIV, BOU, BRZ, CDM, CHB, COY, FLU, FRU, GES, GOS, ILZ, LAC, LAT, MAR, MAS, MOB

[8] Der Code liegt als Jupyter-Notebook-Pipeline im projektinternen Repository vor; nachfolgende Fussnoten verweisen auf die jeweilige Datei relativ zu dessen Wurzelverzeichnis, hier: `FireRiskModelPipeline/1_Analyze-SMN-Data.ipynb`.

[9] `FireRiskModelPipeline/StationsData/ogd-smn_meta_parameters.csv`

[10] Diese fehlenden Tage sind grösstenteils vermutlich durch Ausfall der Sensorik und anschliessender Reparatur verursacht.

[11] `FireRiskModelPipeline/1_Analyze-SMN-Data.ipynb`

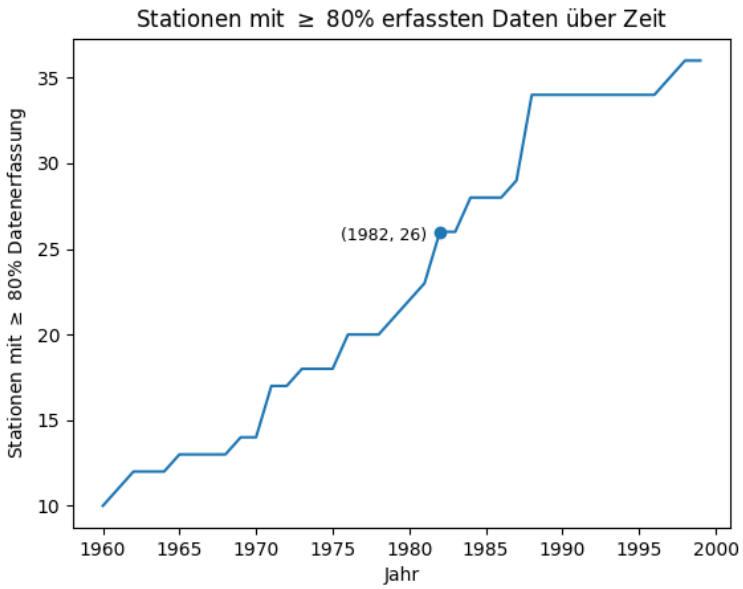


Abbildung 4.1: Anzahl Stationen mit $\geq 80\%$ erfassten Datensätzen, eingegrenzt 1960-2000

uns gewünschten Parametern in Abbildung 4.1 zeigt einen deutlichen Anstieg gegen Ende der Siebziger. Da die „Einführung automatischer Messungen im Jahr 1981“[34] begann, können wir gerechtfertigterweise auch eine gewisse Qualitätszunahme ab diesem Jahr annehmen. Ab Jahr 1982 verfügen 26 Messstationen über die geforderte Vollständigkeit. Erst gegen Ende der Achtziger können wesentlich mehr Stationen mit vollständigerer Datenerfassung aufwarten. Die Anzahl von 26 Messstationen scheint daher aus obigen Überlegungen eine vernünftige Datengrundlage zur Vorhersage von Waldbränden zu sein. Mit dieser meteorologischen Datengrundlage und dem im vorangegangenen Kapitel vorgestellten Waldbrand-Datensatz kann nun jedes einzelne Brandereignis mit den entsprechenden Meteodaten zusammengeführt und aufbereitet werden.

5 Datenaufbereitung und Feature Engineering

5.1 Meteodaten für Brandstandorte

Mit dem Datensatz der Waldbrände und der ausgewählten meteorologischen Daten liegen nun zwei unabhängige Datengrundlagen vor. Wenn die Auswahl an Messstationen aus dem vorherigen Kapitel auf einer Karte verortet wird, zeigt sich sofort, dass diese nicht gleichmässig verteilt sind. Ausgerechnet der exponiert südlich gelegene Kanton Wallis weist beispielsweise nur eine einzelne Station auf. Dies müsste allenfalls bei einer späteren Interpretation berücksichtigt werden. Von nachteiligen Löchern auf der Karte abgesehen sind die Messstationen nicht nur unglücklich verteilt: Der nördliche Alpenraum zumindest scheint relativ dicht mit Stationen[1] abgedeckt zu sein.

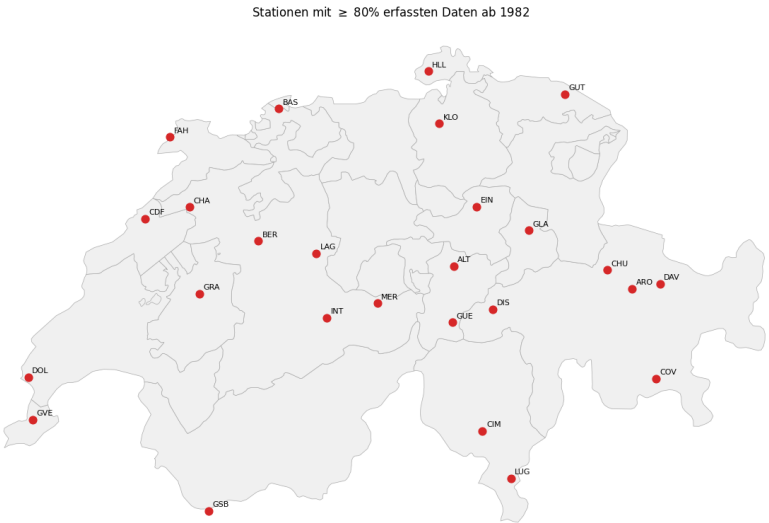


Abbildung 5.1: Verteilung Stationen mit $\geq 80\%$ erfassten Datensätzen ab 1982

Ich werde also die uns nun bekannten meteorologischen Gegebenheiten für die jeweiligen Brandstandorte abschätzen. Aus unserem ursprünglichen Datensatz aller Waldbrände sind insgesamt 5852 in dem von uns gewählten **Zeitraum 1982-2025** aufgetreten. Leider verfügen 326 (∼5.5%) davon über keine genauen Koordinatenangaben[2] und werden daher neben einigen Dubletten

[1] Volle Stationsnamen: `FireRiskModelPipeline/StationsData/ogd-smn_meta_stations.csv`

[2] Teilweise sind zwar Flurnamen o.ä. vorhanden, aber eine genaue Lokalisierung des Feuers wäre unverhältnismässig aufwändig und vermutlich ungenau.

entfernt: **bereinigte 5512 Feuer** bleiben übrig. Die Feuerkoordinaten werden nun durch eine einfache Addition von LV03 nach LV95 konvertiert.[35][3]

5.1.1 Ermittlung der nächsten umliegenden Stationen

Nun bestimmen wir mittels eines 2-d-Baums[36][4] für jeden Waldbrand die drei nächsten umliegenden Messstationen.

```
1   # Aufbau Koordinaten-Matrix
2   station_coords =
3       selected_meta_station_infos[['stat_coord_lv95_east', 'stat_coord_lv95_north']]
4       .to_numpy()
5
6   # Initialisierung des KDTree ebendiesen Koordinaten und Abfrage
7   tree = KDTree(station_coords)
8
9   # Bsp.: Berechne naechste 3 Stationen um Schwarzwasserbruecke (E=2'594'099, N=1'190'304)
10  dist, idx = tree.query([2_594_099, 1_190_304], k=3)
11
12  # Ausgabe der 3 naechsten Messstationen mit Distanz
13  for d, i in zip(dist, idx):
14      print(f"{station_abbrs[i]}: distance={d/1000:.1f}km")
```

Listing 5.1: Distanzberechnung zu nächsten Messstationen eines Brandes

Der über `scipy.spatial.KDTree` eingebundene `KDTree` gibt automatisch die entsprechende Anzahl an gewünschten nächsten Punkten und der jeweiligen Distanz zu ebendiesen zurück (Zeile 10). Schliesslich wird über dieses Resultat iteriert und die Stationsabkürzungen mit jeweiliger Distanz zum abgefragten Punkt ausgegeben: `BER: distance=16.1km, GRA: distance=21.5km, LAG: distance=35.0km`. Dieses Resultat kann auf der Karte in Abbildung 5.1 optisch plausibilisiert werden.

5.1.2 Sortierte Meteodaten je Station

Weiter werden alle sieben Parameter der Wetterdaten je Station in ein Dictionary[5] geladen, sortiert nach Datum. Stationen können nun einfach mit Kürzel abgefragt werden: `station_data['BER']`. Das Resultat je Station enthält die meteorologischen Werte nach Datum sortiert und wird die spätere Abfrage von Wetterfenstern vereinfachen. Siehe Tabelle 5.1 als Beispiel für Station BER. Aus Gründen der Lesbarkeit werde ich im Folgenden die Codes der meteorologischen Parameter jeweils mit menschenlesbaren Kürzeln ergänzen.

5.1.3 Gewichtetes Mittel aller Meteoparameter je Feuer

Mit den drei nächsten Stationen um jedes Feuer können gewichtete Mittel der Meteodaten für den spezifischen Brandstandort berechnet werden. Der Funktion `weighted_features_for_fire()`[6]

[3] `FireRiskModelPipeline/2_CalculateMeanFeaturesForAllFilteredFires.ipynb`
[4] Benötigter Import: numpy und scipy.spatial.
[5] Ein Dictionary entspricht einer Hash-Tabelle in Python. Zugriff erfolgt je Station daher in O(1).
[6] `FireRiskModelPipeline/2_CalculateMeanFeaturesForAllFilteredFires.ipynb`

Datum	Luftdr. prestad0	Wind fu3010d0	T.max tre200dx	Dampfdr. pva200d0	T.min tre200dn	Feuchtig. ure200d0	Niederschl. rre150d0
1982-01-01	942.8	5.8	4.9	7.1	2.0	91.0	2.0
1982-01-02	955.7	2.5	5.9	6.2	-0.9	86.8	0.0
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
2025-12-30	957.5	8.6	1.2	4.0	-3.6	74.8	0.0
2025-12-31	957.5	5.8	0.2	3.4	-7.6	75.5	0.0

Tabelle 5.1: Nach Datum sortierte meteorologische Daten **je Station**, am Beispiel BER

werden das Feuerdatum, die drei umliegenden Stationen und ihre jeweiligen Distanzen zum Feuer sowie ein gewünschtes Zeitfenster übergeben.

Damit werden Meteodaten je Station abgefragt und zwar für das gewünschte Zeitfenster von sieben Tagen *vor* dem eigentlichen Feuer. Die drei abgefragten Stationen werden nach ihrer Distanz zum Feuer gewichtet. Nun wird der Durchschnitt jedes Parameters in diesem siebentägigen Zeitfenster berechnet und entsprechend ihrer Herkunftsstation gewichtet. Damit wird für jedes Feuer unseres bereinigten Datensatzes das gewichtete Mittel der gewünschten sieben Parametern berechnet und nach Feuer-Id und damit chronologisch geordnet. Siehe hierzu Tabelle 5.2.

Feuer-Id	Luftdr. prestad0	Wind fu3010d0	T.max tre200dx	Dampfdr. pva200d0	T.min tre200dn	Feuchtig. ure200d0	Niederschl. rre150d0
198202072101	965.487	6.331	4.179	4.079	-1.889	62.184	0.124
198202132101	969.722	4.790	6.428	4.838	-0.401	65.572	0.004
198202282301	834.120	13.651	-4.048	2.660	-11.067	72.034	0.729
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
202511140201	946.740	3.390	11.991	7.697	1.038	84.905	0.000
202512192201	885.721	7.763	2.892	5.644	-1.184	85.859	1.044

Tabelle 5.2: Gewichtetes Mittel aller Meteoparameter **je Feuer**

Wir prüfen mit `fire_features[PARAMS].isna().sum()` ob der Datensatz vollständig ist. Anschliessend können die Daten aus Tabelle 5.3 plausibilisiert werden: Die durchschnittliche Woche vor einem Feuerereignis weist eine maximale Durchschnittstemperatur von 14.4°und minimale Durchschnittstemperatur von 5.25°auf, was gut auf die zwei erwarteten Scheitelpunkte der Bisaisonalität passt. Auch der 1.6 mm durchschnittliche Niederschlag in diesem Zeitfenster scheint plausibel.

5.1.4 Erstellung von Negativstichproben und Feature-Evaluation

Oben besprochene Parameter kommen also als Feature-Kandidaten für ein mögliches Vorhersage-Modell in Frage. Versuchen wir ihre Eignung zu untersuchen, indem wir die gewichteten Meteoparameter über alle Feuer mit Meteodaten für dieselben Brandorte vergleichen, aber zu Zeitpunkten, in denen es nicht gebrannt hat.

	Luftdr. prestad0	Wind fu3010d0	T.max tre200dx	Dampfdr. pva200d0	T.min tre200dn	Feuchtig. ure200d0	Niederschl. rre150d0
mean	898.50	9.60	14.48	8.64	5.25	65.60	1.60
std	47.33	3.62	8.01	4.20	6.47	10.57	2.33
min	703.07	2.38	-9.32	1.35	-17.17	26.71	0.00
25%	862.92	7.09	8.26	5.07	0.19	58.57	0.10
50%	903.29	8.94	14.43	7.68	4.65	66.24	0.70
75%	940.06	11.42	20.65	12.15	10.97	73.13	2.20
max	989.40	33.30	35.69	22.62	21.27	95.56	27.98

Tabelle 5.3: Deskriptive Statistik der gewichteten Meteoparameter über alle 5512 Feuer

Dazu wird an zufällig ausgewählten Tagen überprüft, ob es gebrannt hat. Falls dies nicht der Fall ist, wird ein zufällig ausgewählter Standort aus den existierenden Brandorten ausgewählt und mit dem weiter oben besprochenen Code die gewichteten Mittel der Meteoparameter eines siebentägigen Fensters vor diesem künstlich erzeugten Non-Feuerereignis geladen. Auf diese Weise werden 5012 sogenannte Non-Feuerereignisse erstellt. 5.2[7]

```
# Stelle sicher, dass es am zufaellig generierten Tag nicht brannte
if (rand_date.year, rand_date.month, rand_date.day) in fire_day_set:
    continue

# Waehle an ebendiesem Tag einen Standort aus unseren Brandstandorten aus
row = station_assignments[random.randint(0, len(station_assignments) - 1)]

# Lies die drei naechsten Messstationen und ihre Distanzen dieses Standortes aus
abbrs = [row[0], row[1], row[2]]
dists = [float(row[3]), float(row[4]), float(row[5])]

# Gewichte wie ueblich die Meteodaten entsprechend Stationsdistanzen
feat = weighted_features_for_fire(pd.Timestamp(rand_date), abbrs, dists)
```

Listing 5.2: Erzeugung von randomisierten Non-Feuerereignissen

Nun können wir die gewichteten Meteodaten für alle Parameter überprüfen. Um die Ausprägungen zu vergleichen, bieten sich Boxplots an: Die Ausprägung aller Feuerereignisse ist in Abbildung 5.2 sichtbar, die Ausprägungen der Non-Feuerereignisse in Abbildung 5.3.

Wir sehen, dass sich Luftdruck, Wind und Dampfdruck in den beiden Ausprägungen nicht sehr stark voneinander unterscheiden. Hingegen sind **Temperatur-, Feuchtigkeits- und Niederschlagsunterschiede** deutlich auszumachen.[8] Eingeworfen werden kann, dass die Erzeugung von Non-Feuerereignissen mit Daten arbeitet, die zufällig übers ganze Jahr verteilt sind, was nicht sehr realistisch ist, da Waldbrände in der Schweiz eine deutliche bisaisonale Häufung aufweisen

[7] `FireRiskModelPipeline/2_CalculateMeanFeaturesForAllFilteredFires.ipynb`
[8] Man beachte hier die unterschiedliche Skalierung.

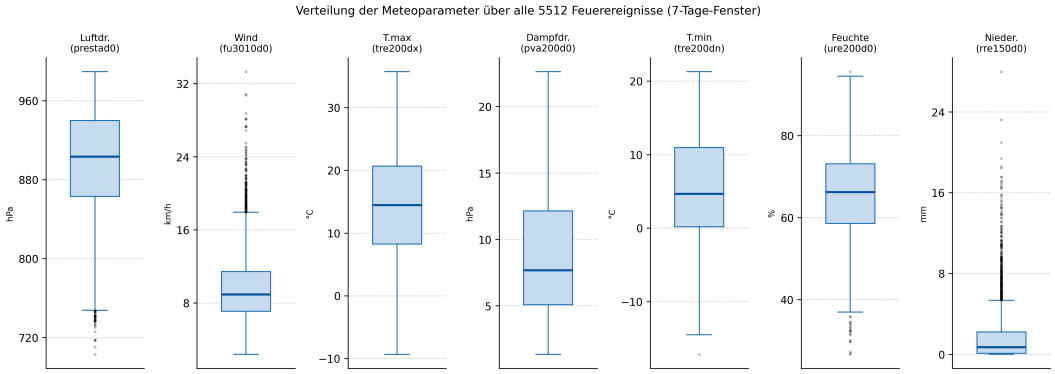


Abbildung 5.2: Boxplot der Meteoparameter eines 7-Tage-Fensters vor einem Feuerereignis

und eben nicht gleichmässig übers Jahr verteilt auftreten.[9] Die meteorologischen Unterschiede zwischen einem Waldbrand und keinem Waldbrand dürften daher sicherlich kleiner sein. Die Erzeugung von saisonal sensitiven Non-Feuerereignissen wäre denkbar, würde aber die einstweilige Auswahl der Parameter vorerst nicht verbessern.

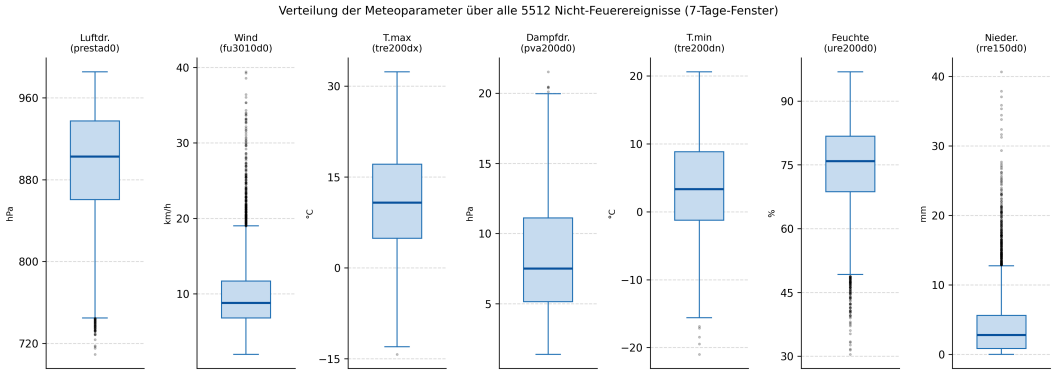


Abbildung 5.3: Boxplot der Meteoparameter eines 7-Tage-Fensters vor einem Non-Feuerereignis

Mit diesen Überlegungen und der Aufbereitung, Sichtung und Plausibilisierung der Feuer- und Meteodaten können wir daher die gewichteten Mittel aller Meteoparameter für jedes Feuer 1982-2025 (siehe Tabelle 5.2 als Beispielsauszug) als Feature-Datensatz für ein erstes Basis-Modell benützen.

[9] Siehe hierzu Abbildung 3.3

6 Basis-Modell: Modellierung und Evaluation

6.1 Modelldiskussion

Das von uns angestrebte Modell soll bestenfalls Waldbrände voraussagen können. Da wir über Branddaten verfügen, wissen wir, bei welchen Eingabedaten, in unserem Falle Meteodaten, es auch tatsächlich gebrannt hat. Damit können wir das Modell mit sogenanntem *supervised learning* überwacht lernen lassen.

Ob es brennt oder nicht, ist eine binäre Klassifikation und benötigt entsprechend ein klassifizierendes Modell. Weiter verfügen wir über eine kleine Anzahl von sieben Features (die im vorherigen Kapitel beschriebenen Meteoparameter) und sind aufgrund der möglichen Anwendung zur Gefahrenabschätzung an deren Interpretierbarkeit interessiert. Aus diesen Gründen[37, 38] versuchen wir uns an einer ersten Brandvorhersage mittels klassischer Modelle, da diese bei tabellarischen Datensets häufig bessere Resultate liefern als *Deep Learning*-Modelle.[39] Wir versuchen uns an einer einfachen Vorauswahl gängiger bekannter Modelle:

- Logistic Regression
- Random Forest
- XGBoost

Die bereinigte Datengrundlage enthält zwar 5512 Feuer, aber diese sind auf 44 Jahre verteilt, was noch ∼125 Feuer pro Jahr entspricht und theoretisch in etwa 0.4 Feuer pro Tag entspräche. Die 5512 erzeugten Negativbeispiele der Non-Feuer sollten dieses Problem der Unbalanciertheit[40] ausgleichen, sind aber für eine spätere Modellbewertung im Hinterkopf zu behalten.

6.2 Splitstrategie: Aufteilung in Trainings- und Testdaten

Um ein Modell trainieren zu können, muss der Feature-Datensatz in Trainings- und Testdaten *gesplittet* werden. 80% der Daten werden zum Training des Modells verwendet und die restlichen 20% der Daten, um zu überprüfen, ob das Modell tatsächlich auch erfolgreiche Vorhersagen trifft. Diese Aufteilung kann nun zufällig erfolgen oder *temporal*. Ein temporaler Split würde zum Beispiel mit gewissen Jahrzehnten trainieren und an anderen prüfen, inwiefern die Modellvorhersage zutrifft.

Da die Klimaerwärmung systematisch zu immer wärmeren Durchschnittstemperaturen führt[41], stellt sich die Frage, ob ein Modell beispielsweise mit kälteren Durchschnittstemperaturen trainiert wird, aber die Prüfung erst an später aufgetretenen, wärmeren Temperaturen erfolgt — oder umgekehrt. Ich gehe davon aus, dass ein Einzelereignis eines Feuers durch die konkreten Bedingungen vor Ort (das siebentägige Zeitfenster) ausgelöst wird und systematische meteorologische Veränderungen hierbei vorerst vernachlässigbar sind: Die Häufigkeit von Bränden mag durch die Klimaerwärmung steigen, aber die auslösenden Faktoren und damit unsere Meteoparameter dürften dieselben bleiben. [1] Um dieses Problem aber gänzlich auszuschliessen, kann nach der folgenden Modellauswahl der ganze Feature-Datensatz mit aufwändigeren Methoden in Trainings- und Testdaten aufgeteilt werden.

6.3 Modellauswahl

Die zu prüfenden vorausgewählten Modelle mit den Trainings- und Testdaten können nun trainiert und ausgewertet werden. In Listing 6.1 sehen wir, wie den unterschiedlichen Modellen der Feature-Datensatz und der Labelvektor mit `model.fit` zum Training übergeben wird und in den folgenden Test AUC-ROC-Werten[42] resultiert:

- Logistic Regression: 0.7885
- Random Forest: 0.8071
- XGBoost: 0.7959

```
model_candidates = {
  "Logistic Regression": LogisticRegression(),
  "Random Forest":       RandomForestClassifier(n_estimators=300, random_state=42),
  "XGB": XGBClassifier(random_state=42),
}

for name, model in model_candidates.items():
  model.fit(X_train, y_train)
  auc = roc_auc_score(y_test, model.predict_proba(X_test)[:, 1])
  print(f"{name}: ROC-AUC={auc:.4f}")
```

Listing 6.1: Training verschiedener Modelle

Alle drei Modelle resultieren in guten **Test AUC-ROC-Werten** von $\sim$**0.8**. Die Unterschiede zwischen den verschiedenen Modellen sind ganz allgemein klein. Dies deutet auch darauf hin, dass in allererster Linie mehr oder bessere Features die Vorhersagekraft eher verbessern werden als Wechsel und Ausbau der Modelle an und für sich. Für das weitere Vorgehen ist der Entscheid für Random Forest damit rechtfertigbar.

[1] Harmonisierte Daten wie SNBCN würden diese temporalen Probleme ausschliessen, aber aufgrund der Messstationsdichte wurden die nicht harmonisierten SMN-Daten als Datengrundlage ausgewählt, siehe weiter oben.

6.4 Modelltraining

Wie in Abschnitt 6.2 besprochen, können wir die Robustheit der Resultate des gewählten Random Forest Modells mit einer stratifizierten fünffachen Kreuzvalidierung (*stratified K-Fold cross-validation*)[43][44] überprüfen. Die Datensätze der Feuer und Non-Feuer werden damit in fünf Blöcke aufgeteilt, die jeweils Trainings- und Testdaten enthalten. Die aktivierte Randomisierung stellt zudem sicher, dass die chronologisch erfassten Brände und die Klimaerwärmung keinen temporalen Bias einführen.

```
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)

rf = RandomForestClassifier(n_estimators=300, random_state=42, n_jobs=-1)
scores = cross_val_score(rf, X, y, cv=cv, scoring='roc_auc', n_jobs=-1)
```

Listing 6.2: Stratified K-fold Validierung des Random Forest

Die fünffache Kreuzvalidierung des Random Forests resultiert in einem mittleren **Test AUC-ROC** von **0.8129**. Dieses Resultat weicht kaum vom ersten vorgenommenen *train_test_split* ab und zeigt eine stabile Generalisierungsleistung auf. Somit ist sichergestellt, dass temporale Aspekte des Datensatzes, wie zum Beispiel wärmere Durchschnittstemperaturen im Verlaufe der Jahre, die Vorhersage nicht systematisch verzerren.

6.4.1 Hyperparameter-Tuning

Das ausgewählte Modell des Random Forest kann nun mittels `RandomizedSearchCV` automatisch auf optimale Hyperparameter untersucht werden. Dazu untersucht die Funktion `RandomizedSearchCV` randomisierte Konstellationen verschiedener Parameter wie Anzahl Bäume (`n_estimators`), Baumtiefe (`max_depth`), Mindestanzahl Samples je Blatt (`min_samples_leaf`) und andere.

```
param_grid = {
  'n_estimators': [100, 200, 300, 500],
  'max_depth': [5, 10, 15, None],
  'min_samples_leaf': [1, 2, 5, 10],
  'max_features': ['sqrt', 'log2', 0.5]
}

search = RandomizedSearchCV(
  RandomForestClassifier(random_state=42, n_jobs=-1),
  param_distributions=param_grid,
  n_iter=30,          # tries 30 random combinations
  cv=5,               # 5-fold cross-validation
  scoring='roc_auc',
  random_state=42,
  n_jobs=-1
)
```

Listing 6.3: Randomisierte Suche idealer Hyperparameter

Dies resultiert in der Empfehlung folgender Hyperparameter: `n_estimators: 500, min_samples_leaf: 1, max_features: 'log2', max_depth: 15`, mittels derer der RandomForest einen AUC-ROC von 0.8119 erreicht. Diese Hyperparameter sollen nun im Folgenden weiter überprüft werden.

6.4.2 Diskussion Hyperparameter-Tuning vs. Overfitting

```python
from sklearn.ensemble import RandomForestClassifier

model = RandomForestClassifier(
  n_estimators=500,
  max_depth=15,
  min_samples_leaf=1,
  max_features='log2',
  random_state=42,
  n_jobs=-1
)
model.fit(X_train, y_train)

auc_train = roc_auc_score(y_train, model.predict_proba(X_train)[:, 1])
auc_test  = roc_auc_score(y_test, model.predict_proba(X_test)[:, 1])
print(f'Train AUC: {auc_train:.4f}')
print(f'Test AUC:  {auc_test:.4f}')
print(f'Gap:       {auc_train - auc_test:.4f}')
```

Listing 6.4: Prüfung Overfitting nach Hyperparameter-Tuning

Mit obigen empfohlenen Hyperparametern erreicht Random Forest im Training einen AUC-ROC-Wert von 0.9983 und einen AUC-ROC-Wert im Testlauf von 0.8077. Der resultierende Gap von 0.1905[2] deutet auf Overfitting hin: Der Random Forest memorisiert die Trainingsdaten beinahe vollständig (vermutlich durch die eher hohe `max_depth` von 15), kann aber nicht auf noch nicht gesehene Daten generalisieren. Der AUC-ROC des Testlaufs 0.8077 hingegen, weicht wenig vom AUC-ROC der obigen stratifizierten fünffachen Kreuzvalidierung von 0.8129 ab. Obwohl also der Trainingslauf sehr stark memorisiert, bleibt die Vorhersagekraft konsistent um die 0.8. Das beobachtete Overfitting scheint die Vorhersageleistung nur geringfügig zu beeinträchtigen.

Im Folgenden nehmen wir an, dass hauptsächlich `min_samples_leaf` und `max_depth` interessante Parameter des Hyperparameter-Tunings 6.4.1 sind.[3] Die Folgen unterschiedlicher Baumtiefen und Mindestanzahl Samples je Blatt können leicht untersucht werden, indem der Random Forest für unterschiedlichste Baumtiefen mit jeweils unterschiedlicher Mindestanzahl Samples je Blatt trainiert und getestet wird.[4] Die Auswirkungen dieser unterschiedlicher Werte auf Train und Test AUC-ROC sind in Abbildung 6.1 ablesbar.

[2] `FireRiskModelPipeline/2_CalculateMeanFeaturesForAllFilteredFires.ipynb`

[3] Dies weil das Vergrössern des `n_estimators` kaum Verbesserung brachte. Auch `log2` und `sqrt` liegen aufgrund der nur 7 Parameter wenig auseinander.

[4] `FireRiskModelPipeline/2_CalculateMeanFeaturesForAllFilteredFires.ipynb`

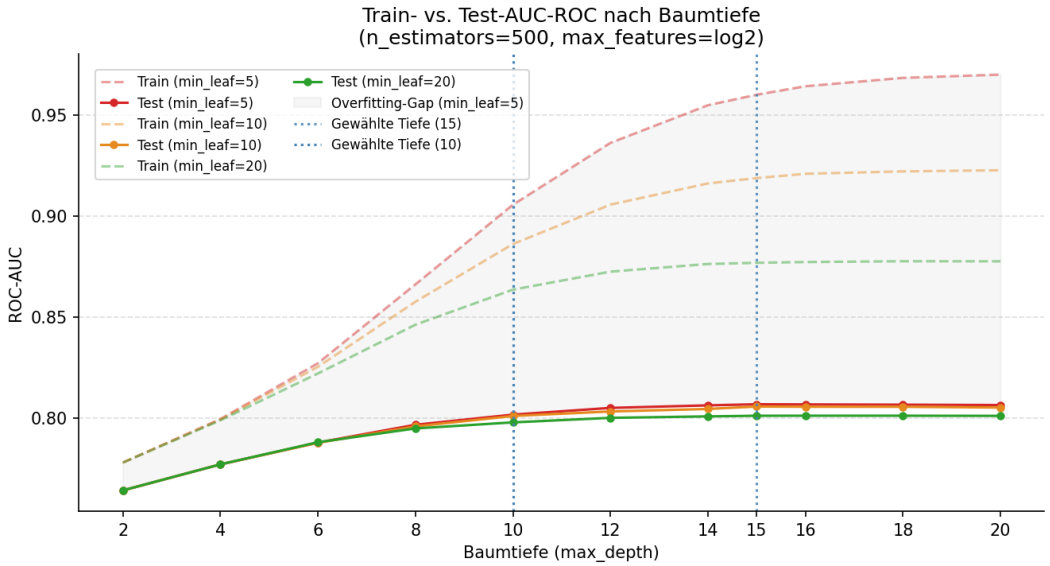


Abbildung 6.1: Verifikation Baumtiefe und Blattanzahl hinsichtlich Overfitting

Tatsächlich liegt die ausgewählte Baumtiefe von 15 mit einem AUC-ROC von 0.8068 am Scheitelpunkt der Testwerte — führt aber mit `min_leaf` von 5 zu einem relativ grossen Gap von 0.1533. Abbildung 6.1 zeigt auch deutlich auf, dass eine hohe Mindestanzahl Samples je Blatt (`min_leaf` von 20, grüne Kurven) das Overfitting teilweise annähernd halbiert. Die Mindestanzahl Samples je Blatt wirkt der Memorisierung des Baumes entgegen, da so nicht mehr nur für wenige Eigenschaften abgesplittet werden kann.[45]

Ein kleinerer Baum reduziert Rechenaufwand, erhöht die Interpretierbarkeit und verbessert die Generalisierbarkeit hinsichtlich noch nicht gesehener Daten.[45] Aus diesen Gründen und auch, weil das Modell noch weiter ausgebaut werden soll, entscheiden wir uns, vorerst mit einer Baumtiefe von 10 und einer Mindestanzahl Samples von 20 je Blatt weiterzufahren. Mit diesen Werten erreicht unser Random Forest im **Training** einen **AUC-ROC-Wert** von **0.8636** und im **Testing** von **0.7979**, mit einem deutlich kleineren Gap von 0.0657. Diese Werte sind minimal bescheidener als die AUC-ROC-Ausgangswerte in der vorgängigen Modellselektion 6.3. Aufgrund der diskutierten Vorteile wird die weitere Modell-Evaluation aber mit ebendiesen Hyperparametern weitergeführt.

6.5 Modell-Evaluation

Nach der Auswahl der Hyperparameter kann das resultierende Modell nun mit einer *Confusion Matrix* 6.2 evaluiert werden: Das Basis-Modell mit sieben Features erreicht für die Klasse der Feuer eine Präzision (*precision*) von 0.7174 und einer Sensitivität (*recall*) von 0.7396. Die Klasse der Non-Feuer erreicht eine Präzision von 0.73 und Sensitivität von 0.71. Die beiden Klassen Feuer und Non-Feuer sind gut ausgeglichen und tragen zu einer ausgewogenen Klassifikationsleistung

bei. Der F1-Score, als gewichtetes harmonisches Mittel von Präzision und Sensitivität, beträgt 0.72.

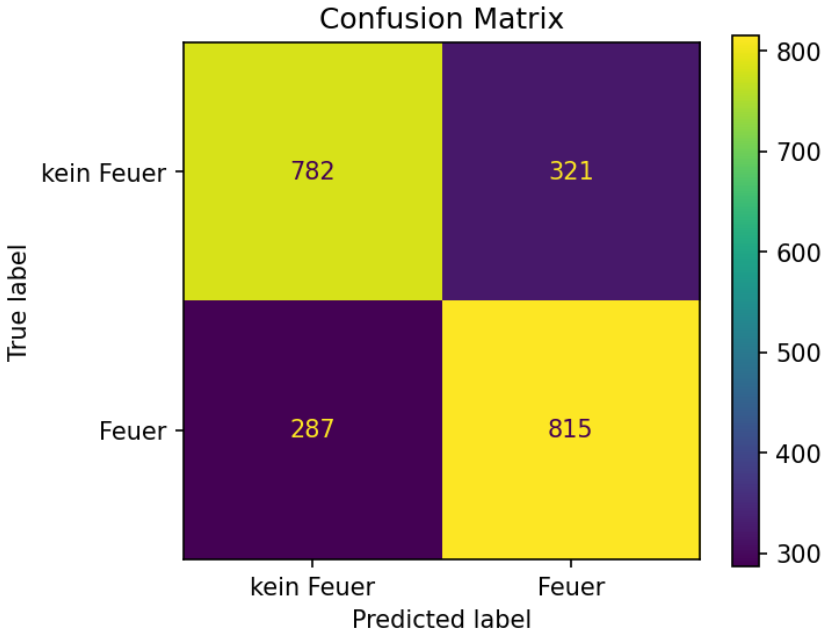


Abbildung 6.2: Confusion Matrix des Basis-Modells

Im Rahmen einer Waldbrand-Vorhersage sind falsch-negative Ergebnisse — ein nicht erkanntes, aber tatsächlich aufgetretenes Feuer — am schwerwiegendsten. Die Sensitivität (*recall)* ist daher die relevante Metrik.[5] Ziel muss es also sein, den Anteil falsch-negativer Vorhersagen (momentan 287) idealerweise auf Null zu bringen. Dies erfolgt primär durch die allgemeine Verbesserung des Modells und kann zu guter Letzt schliesslich durch Anpassung der Entscheidungsschwelle (*decision treshold*) den entsprechenden operativen Bedingungen angepasst werden.

6.5.1 Diskussion Feature-Importances

Mittels `model.feature_importances_` legt das RandomForest-Modell ohne Umschweife eine Bewertung der *Feature-Importances* aus (siehe Abbildung 6.3). Sofort wird deutlich, was sich anhand erster Vorabüberlegungen, der Diskussion anderer Modelle wie FWI und dem Vergleich von Durchschnittswerten (siehe Boxplots in Abbildung 5.3) vermuten liess: Die gewichtigsten Features sind Feuchtigkeit, Niederschlag und (Maximal)temperatur:

[5] Zur Erinnerung: Recall $= \frac{TP}{TP+FN}$.

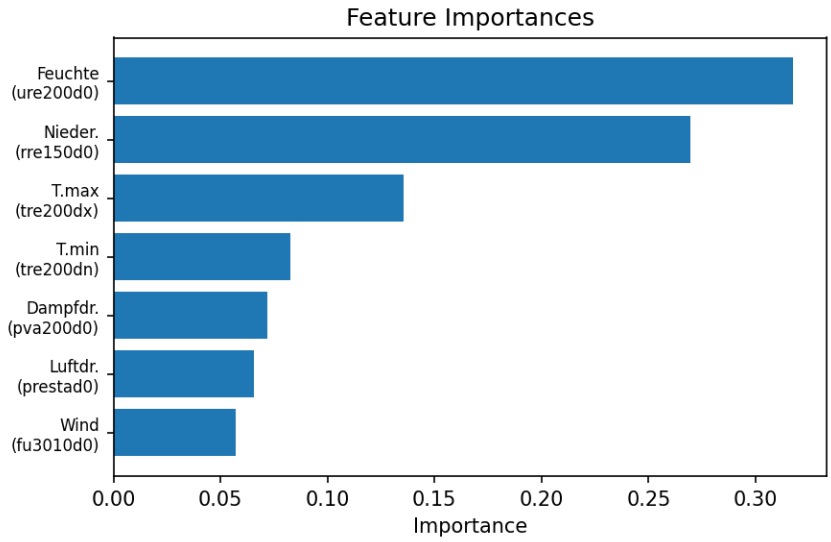


Abbildung 6.3: Feature-Importances des Basis-Modells, sortiert

Der Beitrag jedes Features zur Modellvorhersage kann mittels SHAP-Werten auch quantifiziert werden.[46] Die horizontale Achse beschreibt die Gewichtigkeit mit der ein Feature die Vorhersage beeinflusst: Positive Werte befördern Feuer, während negative Werte feuerverhindernd wirken. Die vertikale Achse (*Feature value*) quantifiziert das jeweilige Feature: Ein roter *Feature value* zeigt einen hohen Wert des entsprechenden Features an, niedrige Werte sind blau.

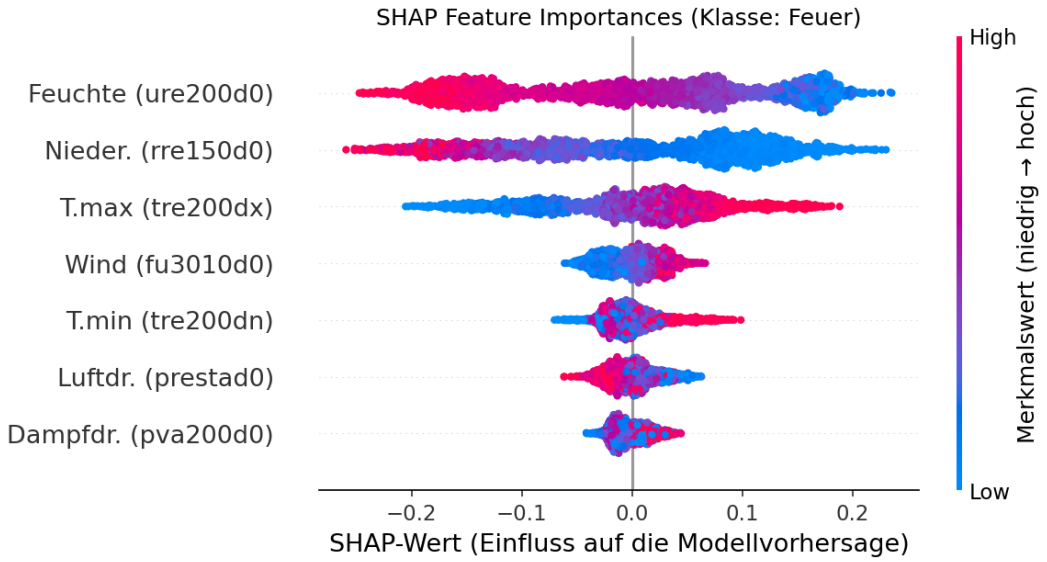


Abbildung 6.4: SHAP Feature-Importances des Basis-Modells

Einfach zu erkennen sind die bereits obig genannten gewichtigsten Features Feuchtigkeit, Niederschlag und (Maximal)temperatur, da diese eine deutliche horizontale Ausbreitung über $[-0.2,\ 0.2]$

aufweisen. Die restlichen vier Werte bewegen sich ungefähr in $[-0.1, 0.1]$ und damit in wesentlich kleinerem Rahmen um den Nullpunkt hinsichtlich Vorhersagewirkung.

Weiter sehen wir, dass das Feature **Feuchtigkeit** in seiner starken Ausprägung (rot) eine negative Auswirkung auf Feuer hat. Niedrige Niederschlagswerte (blau) wirken hingegen begünstigend auf Feuerentstehung. Ähnlich treten **Niederschläge** in Erscheinung, wenn auch Auswirkungen der Niederschläge offenbar weniger gleichmässig verteilt zu Tage treten. So ist eine grössere und sehr niedrige (hellblaue) Anhäufung auf der rechten, positiven Seite zu erkennen: Tiefe Niederschlagswerte sind offenbar ganz wesentlich um Feuer vorherzusagen, während hingegen bereits wenig Niederschlag (als schwache Verfärbungen ins Violette oder gar Rote) die Feuerentstehung negativ beeinflusst. Die Feuchtigkeitswerte hingegen scheinen weniger kritisch auf die Feuerentstehung einzuwirken; der Übergang der horizontalen Verfärbung ist wesentlich ausgeglichener und erst hohe Feuchtigkeitswerte wirken sich negativ auf die Feuerentstehung aus. Der Feuchtigkeitsparameter `ure200d0` beschreibt aber auch **Relative Luftfeuchtigkeit 2 m über Boden; Tagesmittel** und erlaubt dadurch keine Aussagen über die Durchnässung des Waldbodens und dessen Streuschicht.[6]

Während die **Minimaltemperatur** relativ wenig Einfluss auf die Feuerentstehung geltend machen kann und zudem farblich uneindeutiger verteilt zu sein scheint, ist die **Maximaltemperatur** offenbar wesentlich bedeutsamer. Ich nehme an, dass die Schweizer Maximaltemperaturen vermutlich stärker schwanken als nächtliche Minimaltemperaturen und zudem durch *solar radiation*[33] stärkeren Einfluss auf Bodentrockenheit und Luftfeuchtigkeit nehmen dürfte. Zumindest die Berechnung des FWI basiert auch auf der täglichen Höchsttemperatur.[33]

Wind spielt in vielen Fällen eine wichtige Rolle hinsichtlich der Feuerausbreitung[33]. Es scheint aber doch auch bereits das Vorhandensein von Wind für die Feuerentstehung von Bedeutung zu sein. Dies könnte allenfalls durch einen austrocknenden Effekt des Windes erklärbar sein. Während der **Dampfdruck** kaum interpretierbar scheint, scheint der **Luftdruck** keine sehr starke Rolle zu spielen, aber doch nach gewissen Mustern verteilt zu sein. Hoher Luftdruck ist zumindest deutlich stärker auf der linken Seite vertreten und wirkt damit offenbar — kontraintuitiv — der Feuerentstehung entgegen. Eine mögliche Erklärung sind durch Blitzschlag ausgelöste Feuer, die somit eher während Tiefdruckgebieten auftreten dürften.

Zusammenfassend ist dadurch gezeigt, dass niedrige Feuchtigkeit, wenig Niederschlag und hohe Temperaturen Feuerprädikatoren sind, und das Modell somit plausible meteorologische Muster gelernt hat.

[6] Siehe hierzu das System Fireless II in Abschnitt 2.3, das genau die Feuchtigkeit dieser Streuschicht gemessen hat.

7 Verbesserung der Trainingsdaten

7.1 Kritik der Negativstichproben

Die Modell-Evaluation im vorherigen Kapitel hat sich mit den Features und deren Gewichtigkeit auseinandergesetzt. Bei allen sieben Features handelt es sich um meteorologische Parameter. Für jeden Brandstandort wurden meteorologische Durchschnittswerte über ein siebentägiges Fenster vor jedem Brandereignis berechnet. Um das Model dahingehend zu trainieren, Brandereignisse zu erkennen, wurden, wie in Abschnitt 5.1.4 besprochen, zufällige Negativstichproben erzeugt: Diese Negativstichproben wurden auf die bereits bekannten Feuerkoordinaten gesetzt und das Datum auf einen Tag gesetzt, an welchem es eben nicht gebrannt hat. Für dieses Datum (und diesem Ort) wurden wie gehabt der siebentägige meteorologische Parameter-Durchschnitt ausgerechnet.

Die solcherart erzeugten Negativstichproben weisen zwar wie die tatsächlichen Feuer unterschiedliche meteorologische Features auf. Sie tragen aber keine explizite räumliche Information in sich, die das Modell erlernen könnte. Weil Feuer und Non-Feuer dieselben Koordinaten tragen, ist kein räumlicher Kontrast im Datensatz vorhanden. Zwar ist implizite räumliche Information vorhanden: Ein Feuer im Tessin dürfte vermutlich vor dem Hintergrund eines höheren Temperaturdurchschnitts ausgelöst worden sein, als ein Feuer im Nordwesten der Schweiz. Schlicht weil die Durchschnittstemperatur südlich der Alpen zuverlässig höher ist. Aufgrund der nächstgelegenen Stationen und Distanzgewichtungen bleibt der Klimahintergrund für Feuer und Non-Feuer jedoch strukturell identisch.

Aufgrund dieser identischen Koordinaten waren alle Negativstichproben an Orten verortet, an denen es zumindest einmal bereits gebrannt hat und vermutlich in vielen Fällen günstige Bedingungen für Feuer vorherrschen. Damit befinden sich die Negativstichproben auf einer gedachten Verteilung von Non-Feuer zu Feuer bereits ziemlich nah am Ende eines möglichen Feuers und sind dadurch für das Modell schwieriger zu erlernen.

7.2 Verbesserung der räumlichen Negativstichproben

Um die Negativstichproben zu verbessern, werden diese im eigens dafür vorgesehenen Skript `gen_extra_negatives.py` neu auf zufällige, innerhalb der schweizerischen Landesgrenzen liegende, Koordinaten gelegt. Am Tag der Negativstichprobe darf es nicht gebrannt haben, die Koordinaten des Non-Feuers dürfen nicht auf Gletscher, Seen oder oberhalb der Waldgrenze (2200 m.ü.M) liegen. Dazu greifen wir auf die STAC API swissALTI3D[47] zu, „ein sehr präzises digitales Höhenmodell, welches die Oberfläche der Schweiz [...] beschreibt“.[1]

[1] Abfragbar über `https://data.geo.admin.ch/api/stac/v1/collections/ch.swisstopo.swissalti3d/items`.[48]

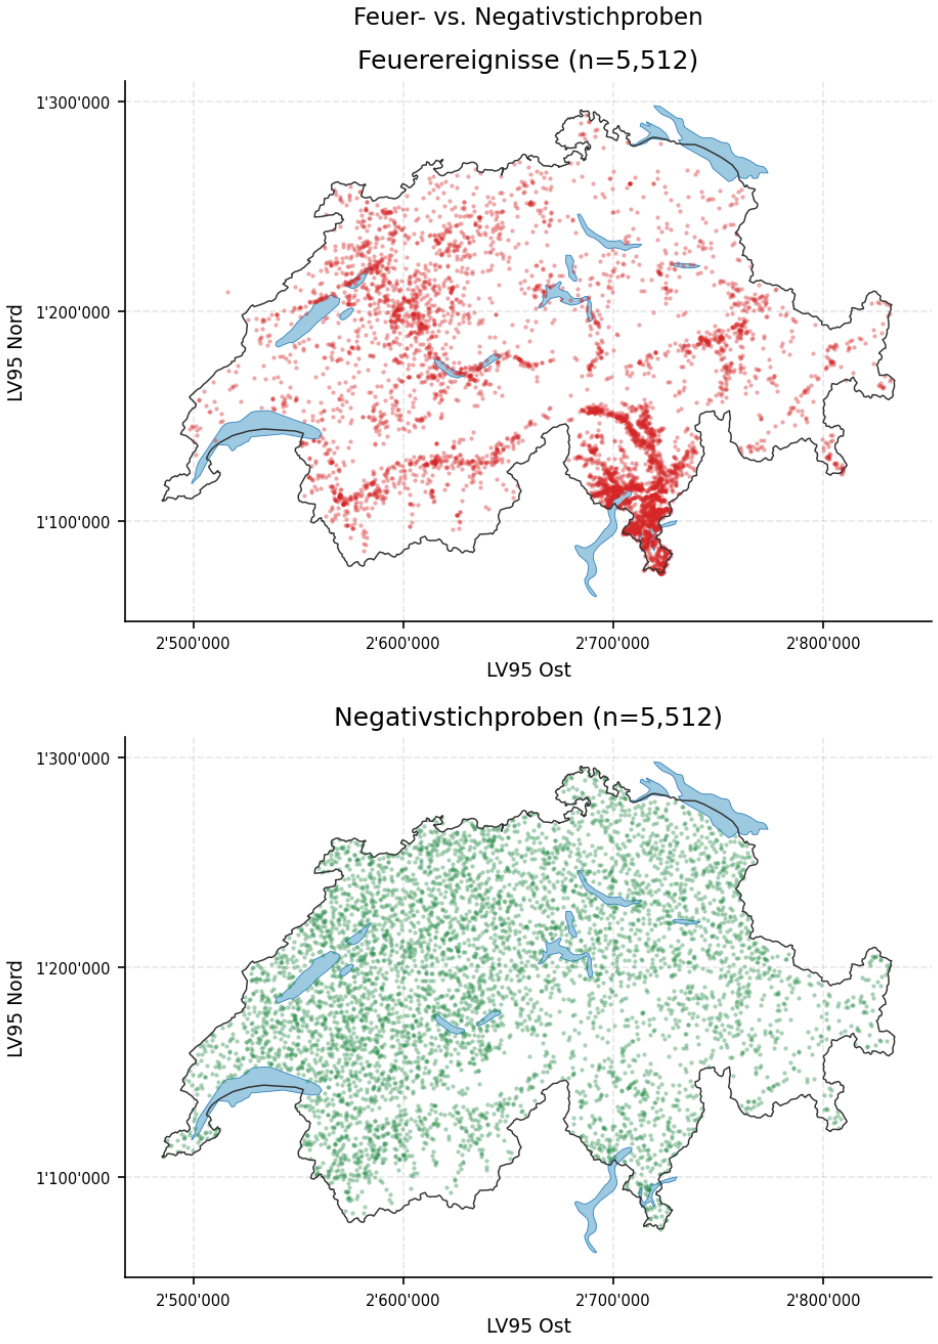


Abbildung 7.1: Generierte Negativstichproben von Non-Feuer

Mittels der Abbildung der Negativstichproben auf der Karte 7.1 ist zu sehen, dass die gewünschten Eigenschaften der Non-Feuer eingehalten werden: Grosse Teile der Alpenregion sind von Non-Feuer ausgeschlossen. Das Flach- und Mittelland hingegen ist aufgrund der randomisierten

Koordinaten sehr gleichmässig von Non-Feuer "betroffen". Die erstellten Negativstichproben scheinen daher plausibel und können nun benützt werden, um das Modell[2] erneut zu trainieren.

Analog der Erstellung der ersten einfacheren Negativbeispiele in Abschnitt 5.1.4, werden die drei nächstgelegenen Stationen um gewichtete Mittel der Features für ein siebentägiges Wetterfenster vor dem Non-Feuer abgefragt.[3] Schliesslich werden diese 5512 Negativstichproben für die weitere Verwendung in ein CSV geschrieben.[4] So entsteht ein impliziter räumlicher Kontrast zwischen den Klassen der Feuer und Non-Feuer, vorerst ohne die explizite Einpflegung von Geländemerkmalen.

7.3 Resultat der verbesserten Negativstichproben

Tatsächlich erhalten wir mit den verbesserten Negativstichproben einen **wesentlich verbesserten AUC-ROC von 0.8580**. Damit ist der AUC-ROC des Modells um 0.0601 gestiegen. In Abbildung 7.2 wird im Vergleich mit der Abbildung der Confusion Matrix des Basis-Modells in Abbildung 6.2 deutlich, dass Richtig-Positive und Richtig-Negative höhere Werte erreichen. Falsch-Negative und Falsch-Positive weisen hingegen kleinere Werte auf: Die Sensitivität (*recall*) und auch die Präzision (*precision*) sind leicht gestiegen, wie auch der F1-Score. Für alle drei Kennzahlen beträgt der gewichtete Durchschnitt nun `0.77` und zeigt damit auch Ausbalanciertheit der beiden Klassen an. Leider sind dennoch 264, ungefähr ein Viertel aller aufgetretenen Feuer, nicht als solche erkannt worden (sogenannte Falsch-Negative).

7.3.1 Feature-Importances

Interessanterweise hat sich auch die Wichtigkeit der Modellfeatures verändert. Die SHAP Feature-Importances des Basis-Modells in Abbildung 6.4 sind nicht nur in ihren Ausprägungen akzentuierter: Die Reihenfolge des Einflusses auf die Modellvorhersage selbst hat sich verändert. Feuchtigkeit und Niederschlag bleiben wichtigste Prädikatoren. Luftdruck, der bislang schwierig zu interpretieren schien, ist neu an dritte Stelle gerückt. Der Einfluss des Luftdrucks wurde nicht nur ausgeweitet, sondern ist auch deutlich klarer ausgeprägt. Alle Features weisen nun eine viel homogenere, monotonere Farbverteilung auf. Dies deutet darauf hin, dass die Feature-Importances über alle Stichproben stabil sind.

[2] Die Hyperparameter wurden und werden in der Folge nicht verändert, um den Effekt der verbesserten Negativstichproben isoliert überprüfen zu können.

[3] `FireRiskModelPipeline/3_ImprovedNegativeSampling.ipynb`

[4] negatives_engineered.csv

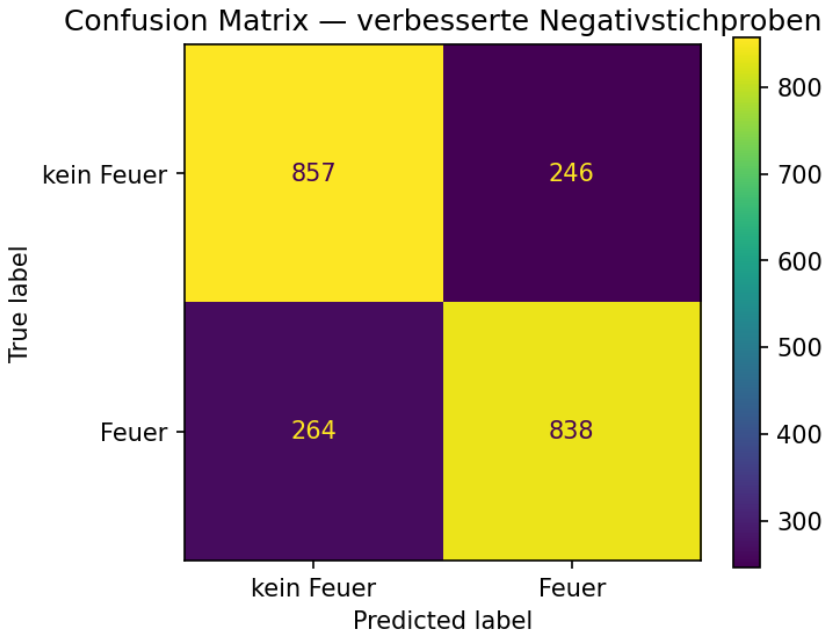


Abbildung 7.2: Confusion Matrix nach verbesserten Negativstichproben

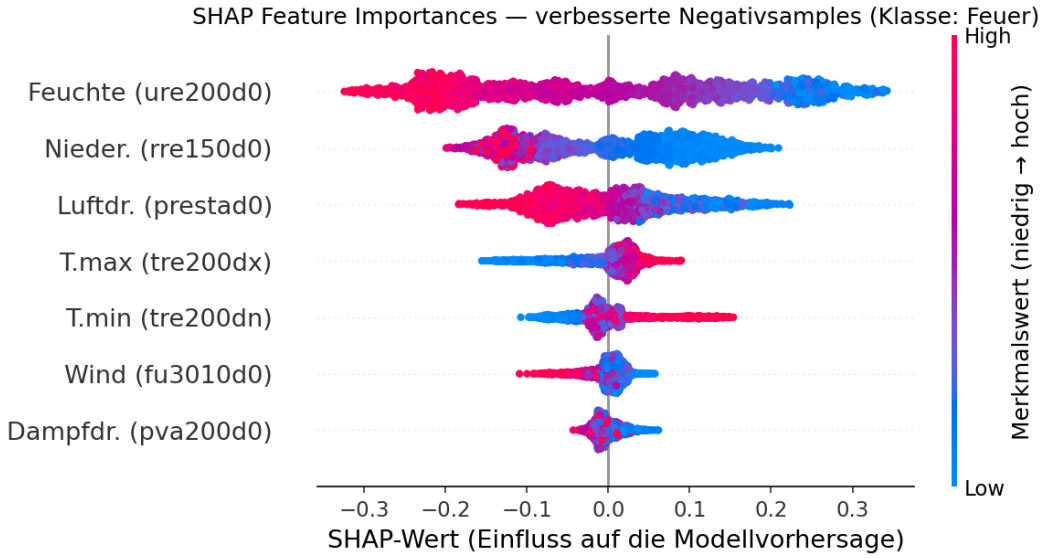


Abbildung 7.3: SHAP Feature-Importances nach verbesserten Negativstichproben

7.3.2 Overfitting

Bemerkenswert ist weiterhin auch der Rückgang des Overfittings. Verglichen mit dem Overfitting des Basis-Modells in Abschnitt 6.4.2, führen verbesserte Negativstichproben zu einem robusteren

Lernverhalten des Modells. Der AUC-ROC des Trainings ist wesentlich von seinem verdächtig hohen Wert gesunken, hat sich dem Test AUC-ROC angenähert und beträgt nur noch 0.9027 statt 0.9983. Mit dem erreichten AUC-ROC des Tests von **0.8580** weist das Modell nun eine fünffach kleinere Gap von 0.0446 (ehemals 0.1905) auf. Das ursprünglich vorhandene Overfitting ist damit wesentlich gesunken. Vermutlich memorisierte das Basis-Modell schlicht die unterschiedlichen meteorologischen Bedingungen an den identisch bleibenden Standorten, konnte dies aber in den Testdatensätzen nicht generalisieren. Dies dürfte das vorherige hohe Overfitting erklären. Die verbesserten Negativstichproben scheinen dazu geführt zu haben, dass das Modell an den gleichbleibenden Standorten *nicht nur* meteorologische Features memorisieren konnte: Dem Modell wurde damit das Lernen erschwert, aber gleichzeitig auch die Vorhersagekraft wesentlich verbessert.

Das Modell ist durch die verbesserten Negativstichproben wesentlich besser und robuster geworden. Ausserdem dürften die räumlich randomisierten Negativstichproben ganz wesentlich dazu beitragen, dass räumliche Features wie zum Beispiel Hanglagen, ganz signifikant zur Verbesserung des Modells beitragen könnten.

8 Featureerweiterung Hangneigung und -ausrichtung

8.1 Grundüberlegungen

Die Schweiz weist unterschiedliche geographische Zonen auf: den Jura, das Mittelland und die Alpen.[49] Dies stellt andere Bedingungen an die Vorhersage als grössere, homogenere Landschaften — insbesondere die Alpen wirken „als markante Klimaschranke zwischen der Nord- und der Südschweiz“[50]. Es ist anzunehmen, dass die Exposition von Hängen wesentlichen Einfluss auf die Trockenheit eines Standortes ausübt. Südhänge sind hierbei aufgrund der Sonnenexposition am gefährdetsten.[1] Im Folgenden soll das bestehende Modell um die Hangneigung und die Exposition (hinsichtlich der Himmelsrichtung) erweitert werden.

8.2 Berechnung Hangneigung und Hangausrichtung

Mittels der STAC API swissALTI3D[47], die bereits zur Erzeugung der randomisierten Negativstichproben benützt wurde, kann die Hangneigung und die Hangausrichtung beziehungsweise Exposition eines Feuerstandortes berechnet werden. Die Oberfläche wird von swissALTI3D mittels 1 km × 1 km grossen Kacheln (*tiles*) abgebildet. Mittels der STAC-Schnittstelle können nun via `https://data.geo.admin.ch/api/stac/v1/collections/ch.swisstopo.swissalti3d/items` die jeweilig gewünschte Kachel für jede Feuerkoordinate heruntergeladen werden. Eine solche Kachel resultiert für eine gewünschte Feuerkoordinate von beispielsweise E=**2'597**'450 N=**1'194**'820 in einem TIF-Dokument `swissalti3d_2019_`**`2597-1194`**`_2_2056_5728.tif` und kann mit einem GIS-Programm zur Plausibilisierung betrachtet werden.[2]

Die Kacheln für alle Feuerkoordinaten werden in der Datei `tile_url_cache.pkl` gecached. Schliesslich wird mit COG (Cloud-Optimized GeoTIFF) mittels `row, col = ds.index(east_lv95, north_lv95)` von jeder Kachel ein kleines benötigtes Fenster der Grösse 30 m × 30 m um die Feuerkoordinate geschnitten: `rasterio.windows.Window(col_off, row_off, width, height)`. In diesem Fenster um den Feuerstandort wird mit `np.gradient` die vertikale und horizontale Steigung dieses Standorts berechnet. Schliesslich kann aus horizontaler und vertikaler Steigung mit $\texttt{slope} = \arctan\left(\sqrt{g_x^2 + g_y^2}\right)$ die an diesem Punkt vermutet vorherrschende **Hangneigung** als Näherung berechnet werden.

[1] Siehe hierzu auch[51]

[2] `FireRiskModelPipeline/4.1_AddTerrainFeatures.ipynb`

Wie in Listing 8.1 dargestellt, wird zugleich auch die **Exposition** als Richtung des Gradienten berechnet. Das Resultat erfährt durch eine Addition von 180° einen zusätzlichen Richtungswechsel: Damit zeigt ein beispielsweise nach Norden zeigender Gradient schliesslich nach Süden — und identifiziert damit einen Aufstieg nach Norden korrekterweise als einen Südhang.

```
slope_deg = np.degrees(np.arctan(np.sqrt(gx**2 + gy**2)))

# + 180 Grad konvertiert z.B. noerdliche Steigung in Suedhang und vice versa
aspect_deg = (np.degrees(np.arctan2(gx, gy)) + 180) % 360
```

Listing 8.1: Berechnung der Exposition

Abbildung 8.1 illustriert obige Erläuterung am Beispiel zweier Brände im Tessin und Wallis: Zu sehen sind in der ersten Spalte die abrufbaren Kacheln (1 km×1 km) der swisstopo STAC API. Die erste Kachel hier zur Illustration als Landeskarte, die zweite Kachel ein vergrössertes Luftbild. Kachel drei zeigt denselben Ausschnitt als Höhenprofil an (swissALTI3D, falschfarbig). Aus diesem Ausschnitt wird nun mittels COG ein 15 px×15 px (= 30 m×30 m) Fenster geschnitten und in KACHEL vier wie oben erläutert benützt, um Hangexposition und -Neigung zu berechnen.

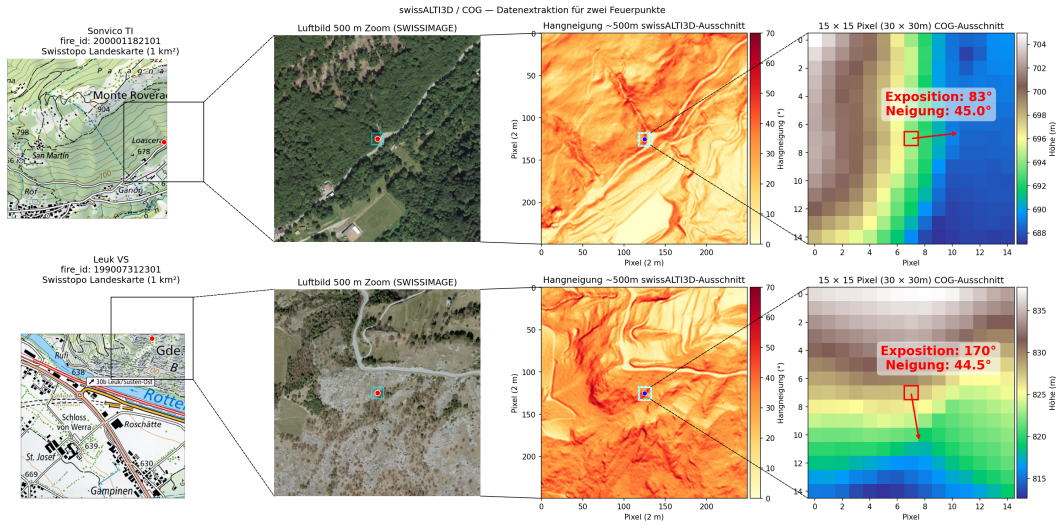


Abbildung 8.1: Berechnung Hangneigung und Exposition: Die ersten zwei Spalten dienen nur der Illustration: die Hanglage und Exposition wurden direkt aus den mittels swissALTI3D empfangenen GeoTiff-Daten (Kacheln in dritter Spalte) extrahiert und in Ausschnitt der vierten Spalte berechnet.

8.2.1 Codierung der Hangausrichtung

Da die Hangausrichtung in Grad berechnet wird, entsteht folgendes Problem: 1° und 359° zeigen annähernd in dieselbe Richtung, sind aber arithmetisch doch einigermassen unterschiedlich. Mit der Encodierung durch Sinus und Cosinus kann die Hangausrichtung in Grad mittels der zwei Komponenten Ost-West ([`sin(270) = -1`, ..., sin(90) = 1]) und Nord-Süd ([`cos(0) = 1`, ...,

`cos(180) = -1`]) codiert werden. Diese Codierung stellt ein konsistentes Signal für den Random Forest sicher.

8.3 Plausibilisierung Hangneigung und -ausrichtung

Nun können Hanglage- und Hangausrichtung für alle Feuer berechnet werden und das Modell entsprechend um diese Features erweitert werden.[3] Zur Plausibilisierung kann die Hangneigung in einem Histogramm und die Hangausrichtung in einem Polardiagramm dargestellt werden, siehe Abbildung 8.2. Deutlich erkennbar ist, dass der Grossteil der Feuer innerhalb einer Hanglage von $\leq 40°$ auftritt, aber danach mit steigender Steilheit, durch vermutlich abnehmenden Bewuchs, rapide abnimmt. Die Exposition der Hänge ist wie erwartet hauptsächlich zwischen Südwesten und Südosten auszumachen, ein Muster welches sich bei steilen Hängen sogar noch weiter akzentuiert.

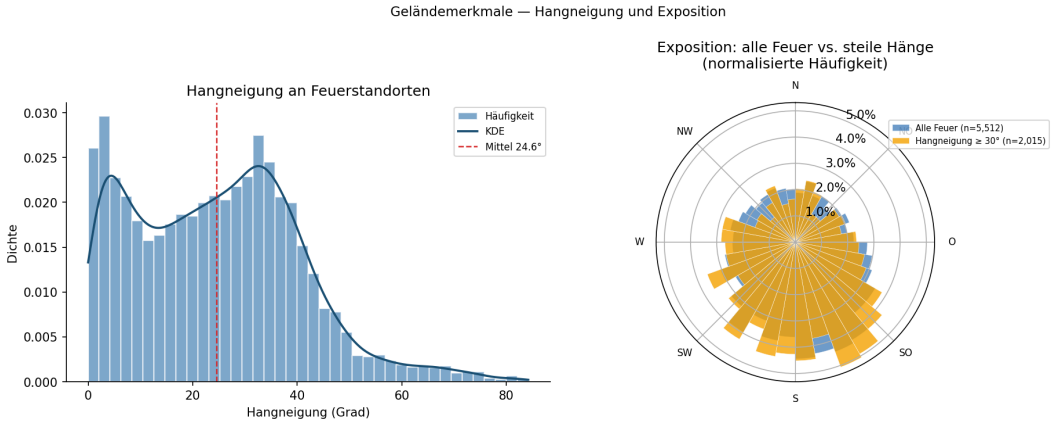


Abbildung 8.2: Hangneigung und Exposition

8.4 Evaluation des räumlich-erweiterten Modells

Nun kann das bestehende Datenset des Modells mit bisher rein meteorologischen Features um die Features Hangneigung (`dem_slope_deg`) und Hangexposition (codiert in den zwei Komponenten `aspect_sin` und `aspect_cos`) erweitert werden. Auch die Negativstichproben müssen ebenso erweitert werden.[4] Der so angereicherte Datensatz `fires_with_terrain_features.csv` wird mit den erweiterten Negativstichproben `negatives_engineered.csv` konkateniert. Feuerkoordinaten ohne Hangneigung und infolgedessen auch ohne Hangexposition werden hierbei ignoriert. Der resultierende Datensatz wird dem Random Forest zum Training und anschliessenden Testen übergeben und resultiert in einem **AUC-ROC** von **0.8782**.

[3] Dies, nachdem die berechneten Neigungen und Ausrichtungen händisch mittels map.geo.admin.ch stichprobenartig überprüft worden sind.

[4] Die Spalte `dem_aspect_deg` als Hangausrichtung in Grad wird ebenfalls in die Datensätze eingefügt, aus Gründen der Les- und Nachvollziehbarkeit.

Gegenüber dem Resultat mit den Wetterfeatures und verbesserten Negativstichproben in Abschnitt 7.3 mit einem AUC-ROC von 0.8580, ist das Resultat um 0.0202 gestiegen. Glücklicherweise ist aber auch das Overfitting mit einem Wert von 0.0326 vergleichsweise niedrig geblieben — das Modell generalisiert gut. Die Werte der Confusion Matrix in Abbildung 8.3 zeigen leicht verbesserte Werte an. Insbesondere der möglichst niedrig angestrebte Falsch-Negativ-Anteil ist sogar ein wenig gesunken.

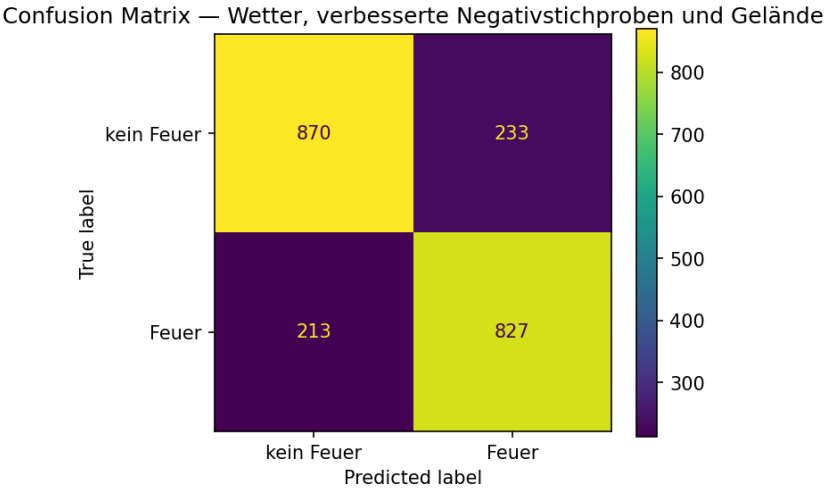


Abbildung 8.3: ConfusionMatrix, Modell mit Geländemerkmalen

Die SHAP Feature-Importances in Abbildung 8.4 der drei wichtigsten Features Feuchtigkeit, Niederschlag und Luftdruck haben sich zum vorherigen Modell mit den verbesserten Negativstichproben in Abbildung 7.3.1 kaum sichtbar verändert. An vierter Stelle findet sich aber bereits das neu eingefügte Feature der Hangneigung. Eine gewisse Hangneigung scheint sich durchaus positiv auf die Entstehung eines möglichen Feuers auszuwirken. Dieses Resultat scheint konsistent mit der bereits in Abbildung 8.2 diskutierten Auswirkung von Hanglagen.

Gefolgt wird die Hangneigung von der Nord-Süd-Exposition, codiert durch eine Cosinus-Funktion ([`cos(0) = 1, ..., cos(180) = -1`]). Hier zeigt sich erneut die vermutete höhere Feuergefahr in Südhängen ($\cos(180°) = -1$) (blauer Merkmalswert), wohingegen Nordhänge ($\cos(0°) = 1$) (rot) eine feuerhemmende Eigenschaft aufweisen. Interessanterweise tritt die Ost-West-Exposition an letzter Stelle und kaum prägnant auf. Zwischen diesen beiden Expositionsfeatures finden sich unverändert die Features Maximal- und Minimaltemperatur, Wind und Dampfdruck.

Die SHAP-Analyse zeigt erneut auf, dass Feuchtigkeit ganz wesentlicher Parameter in der Feuervorhersage ist:[5] Feuchtigkeit und Niederschlag zeigen grössten und akzentuierten Einfluss auf die Modellvorhersage. Temperatur und Wind sind sogar erst nach Hangneigung und -exposition

[5] Vgl. Diskussion zu FWI, IGNIS, Fireless II etc. in Abschnitt 2.3.

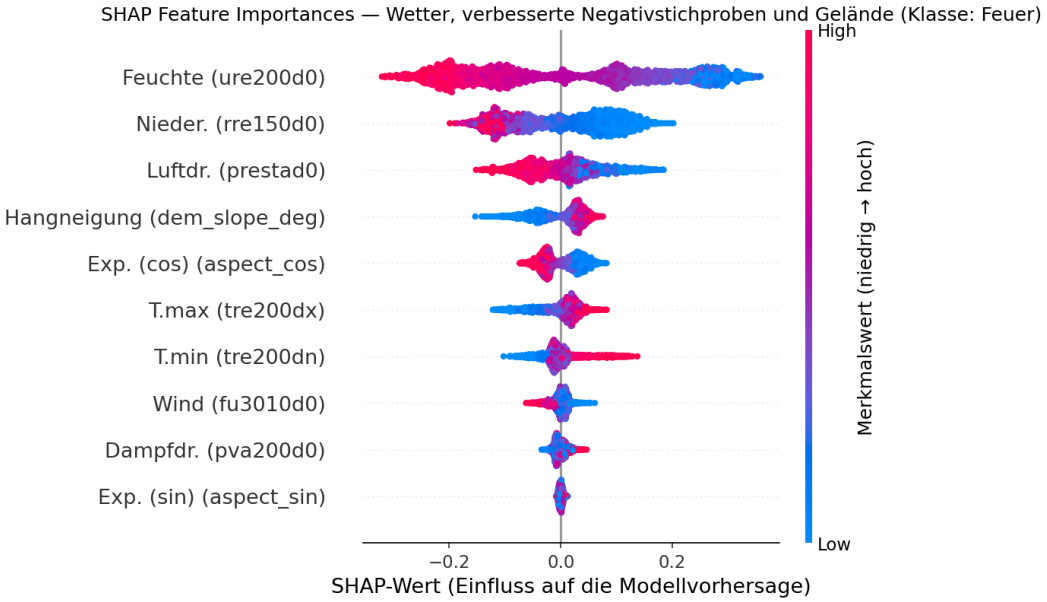


Abbildung 8.4: SHAP Feature-Importances, Modell mit Geländemerkmalen

überhaupt von Bedeutung. Dampfdruck und die Ost-West-Exposition hingegen weisen nur noch einen äusserst kleinen Einfluss aus.

9 Kontexterweiterung des Modells

9.1 Grundüberlegungen

Im bisherigen Modell sind alle zur Verfügung stehenden Parameter eingesetzt. Die Herausarbeitung der vielversprechenden Hanglage und -ausrichtung hat zu einer bescheidenen kleinen Verbesserung des AUC-ROC von 0.0055 geführt. Parameter wie Wind, Dampfdruck und Exposition weisen wenig Einfluss auf die Modellvorhersage auf, siehe Abschnitt 8.4. Es stellt sich die Frage, inwiefern das Modell weiter verbessert werden kann. Im Folgenden hierzu einige Überlegungen:

i) Wie erwähnt tragen Exposition und Hanglage weniger zum Modell bei als erhofft. Hier fällt zumindest auf, dass der Geländeinformation eine wichtige Information fehlt: die Höhe über Meer. Das Höhenprofil wurde in Abschnitt 3.5 besprochen, aber noch nicht weiter bearbeitet. Die Höhenmeter eines Standortes versprechen interessant zu sein, hängen doch auch Temperatur und in gewissem Masse vermutlich auch Sonnenexposition mit ihr zusammen.

ii) Die ausführlich besprochene Bisaisonalität der Schweizerischen Waldbrände ist bisher ebenfalls gänzlich ausser Acht gelassen worden.[1] Zwar dürften Schwankungen zwischen Minimal- und Maximaltemperatur durchaus saisonale Information tragen, aber einzig durch die meteorologischen Informationen und nicht die tatsächliche Saisonalität.

iii) Die bisherigen meteorologischen Features fliessen als Durchschnitt der letzten sieben Tage vor einem Feuerereignis in das Modell ein.[2] Das bisherige Modell kann also nicht unterscheiden, ob es eine Woche vor dem Feuer zu 7 mm Niederschlag gekommen ist, es jeden Tag genau 1 mm geregnet hat, oder es gar zu 7 mm Niederschlag kurz vor dem Feuer kam: Das Modell verfügt über keine historisierte Datenlage, obwohl diese über grosse Zeiträume vorhanden ist — und vermutlich wesentlichen Einfluss auf ein mögliches Feuerereignis haben dürfte. Die fehlende Erinnerung des Modells betrifft zudem alle sieben meteorologischen Features.

iv) Der Dampfdruck trägt wenig zur bisherigen Vorhersage bei. Wie in Abschnitt 4.1.1 gezeigt, kann mit dem Dampfdruck und der temperaturabhängigen Sättigung die relative Luftfeuchtigkeit berechnet werden. Die relative Luftfeuchtigkeit beschreibt den prozentualen Anteil Wasserdampf in der Luft in Relation zum möglichen Maximum an Wasserdampf. Dieser Anteil verändert sich aber „abhängig von der Entwicklung der Temperatur“[52]. Aussagekräftiger als die temperaturabhängige Sättigung der Luft mit Wasserdampf ist aber die „(atmospheric) vapor pressure deficit (VPD)“[53].

[1] Siehe hierzu Abschnitt 3.3
[2] Siehe hierzu Abschnitt 5.1.3.

9.2 Kontexterweiterungen

Die SHAP-Analyse im vorherigen Kapitel motiviert die bereits bestehenden Features anzureichern, statt dem Modell nur zusätzliche rohe Variablen hinzuzufügen. Diese Anreicherung kann als Kontexterweiterung obiger Punkte gedacht werden:

i) Die räumliche Verortung eines Feuerstandortes soll um die Höhe erweitert werden, die auch temperaturspezifische Auswirkungen hat.

ii) Das Feuerereignis soll um den wesentlichen saisonalen Kontext der Bisaisonalität erweitert werden.

iii) Das Modell soll um einen temporalen Kontext erweitert werden, indem eine Menge an Einzeltagen vor Feuerereignissen betrachtet wird und wesentlich spezifischere Muster erlernbar sind, als der vorherige simplere siebentägige Durchschnitt.

iv) Der nahezu bedeutungslose Dampfdruck soll in der Interaktion mit Temperaturinformationen Aufschluss darüber geben, wie schnell eine Umgebung tatsächlich trockener wird.

Damit erweitern wir den Kontext des Modells um räumlich-klimatologische, saisonale, temporale und atmosphärisch-thermodynamische Aspekte. Ungleich den vorangegangenen Kapiteln mit isolierten Feature-Erweiterungen, erfährt das Modell im Folgenden verschiedene kontextuelle Erweiterungen.

9.2.1 Erweiterung Höhenprofil

Die Erweiterung des Feuerstandortes um die Höhe über Meer ist einfach: Die über swissALTI3D abgerufenen Kacheln[3] können hinsichtlich einzelnen Pixel abgefragt werden. In der folgenden Auflistung 9.1 wird also schlicht das Pixel der Feuerkoordinate mittels Rasterio hinsichtlich der hinterlegten Höhe abgefragt.

```
row, col = ds.index(east_lv95, north_lv95)
[...]
# Grid-Komponente obiger Koordinaten auslesen (Band 1 enthaelt Hoeheninformation).
height = float(ds.read(1, window=rasterio.windows.Window(col, row, 1, 1))[0, 0])
```

Listing 9.1: Höhenberechnung

9.2.2 Saisonale Kontextualisierung

Um Feuerereignisse saisonal zu kontextualisieren, wird das Branddatum in eine Zahl verwandelt (*Day Of Year*). Diese Zahl wird durch 365.25 geteilt[4] — so erhält man einen im Intervall $[\frac{1}{365.25}...1)$ liegenden Wert, der die Position des Tages im Jahresverlauf abbildet.

[3] Siehe hierzu Abschnitt 7.2.
[4] Die Nachkommastelle 0.25 modelliert den zusätzlichen Tag, der alle vier Jahre durch ein Schaltjahr entsteht.

Analog der räumlichen Verortung auf den Achsen Nord-Süd und Ost-West in Abschnitt 8.2.1 wird dieser Wert mit dem Bogenmass von $2 * \pi$ und Cosinus- und Sinusfunktion codiert: Der erste Januar als Tag 1 entspricht demnach $sin(\approx 0) \approx 0, cos(\approx 0) \approx 1$. Der 31. Dezember wird mit $sin(\approx 2\pi) \approx 0, cos(\approx 2\pi) \approx 1$ nahezu identisch codiert.[5]

```
def compute_doy_features(year, month, day):
    doy = pd.Timestamp(year=int(year), month=int(month), day=int(day)).day_of_year
    angle = 2 * np.pi * doy / 365.25
    return np.sin(angle), np.cos(angle)
```

Listing 9.2: Codierung der Saisonalität

9.2.3 Kontextfenster Trockentage

Der klassische FWI enthält ausgeklügelte, häufig exponentielle Funktionen, um die Austrocknung verschiedener Untergründe abzubilden. Der Boden verliert gemäss dieser Modellierung exponentiell an Feuchtigkeit.[54, S. 13]. Erwähnt wird aber auch ein wesentlich einfacherer *Drought Index*, mit welchem ein meteorologisches Kontextfenster erstellt wird. Damit werden schlicht die Anzahl Trockentage vor einem Feuerereignis gezählt. Trockentage sind Tage, an denen es nicht oder nur unter einem bestimmten Grenzwert geregnet hat:

> [T]he Drought Index took account of up to 25 days of weather history. Its purpose was to stratify the day-to-day fire weather according to the number of days since appreciable rain; in physical concept it could be likened to a simple reservoir in which rain accumulated additively, and which lost a constant amount for each day without rain.[54, S. 10]

Statt wie bisher nur den siebentägigen Durchschnittswert des Niederschlages in das Modell einfliessen zu lassen, kann solcherart relativ einfach ein grosses Kontextfenster vor Brandereignisse gelegt werden. Dieses auf 30 Tage festgelegte Fenster wird durchiteriert und geprüft, an wie vielen zusammenhängenden Tagen vor dem Feuerereignis es nicht gerechnet hat, beziehungsweise in welchen es nur Niederschläge unterhalb des Grenzwerts von 1 mm gegeben hat. Abbildung 9.1 illustriert, wie die drei nächstgelegenen Stationen um ein Brandereignis hinsichtlich Niederschlag abgefragt, mittels ihrer Distanz zum Feuer gewichtet werden und so schliesslich einen Trockentage-Wert liefern. Diese Berechnung erfolgt mittels einer Funktion, die in ihren Grundzügen in Listing 9.3 beschrieben wird.

```
# abbr_list  = [row['nearest_station_1'], row['nearest_station_2'], row['nearest_station_3']]
def compute_cdd_3station(event_date, abbr_list, distances_m, lookback=30, threshold_mm=1.0):
    [...]
    cdd_values, cdd_weights = [], []
    for abbr, weight in zip(abbr_list, weights):
        station_df = station_data.get(abbr)
        if station_df is None or 'rre150d0' not in station_df.columns:
            continue
```

[5] Diese zweidimensionale Codierung ist notwendig, da zum Beispiel Brandereignisse im Frühling und Herbst mit einer eindimensionalen Codierung nicht auseinanderzuhalten wären.

```
        window = station_df.loc[start_cdd:end_cdd, 'rre150d0'].dropna()
        [...]

        # Count backwards from the most recent day until a wet day breaks the streak
        cdd = 0
        for val in reversed(window.values):
            if val < threshold_mm:
                cdd += 1
            else:
                break
        cdd_values.append(cdd)
        cdd_weights.append(weight)
    [...]
```

Listing 9.3: Berechnung aufeinanderfolgender Trockentage (CDD)

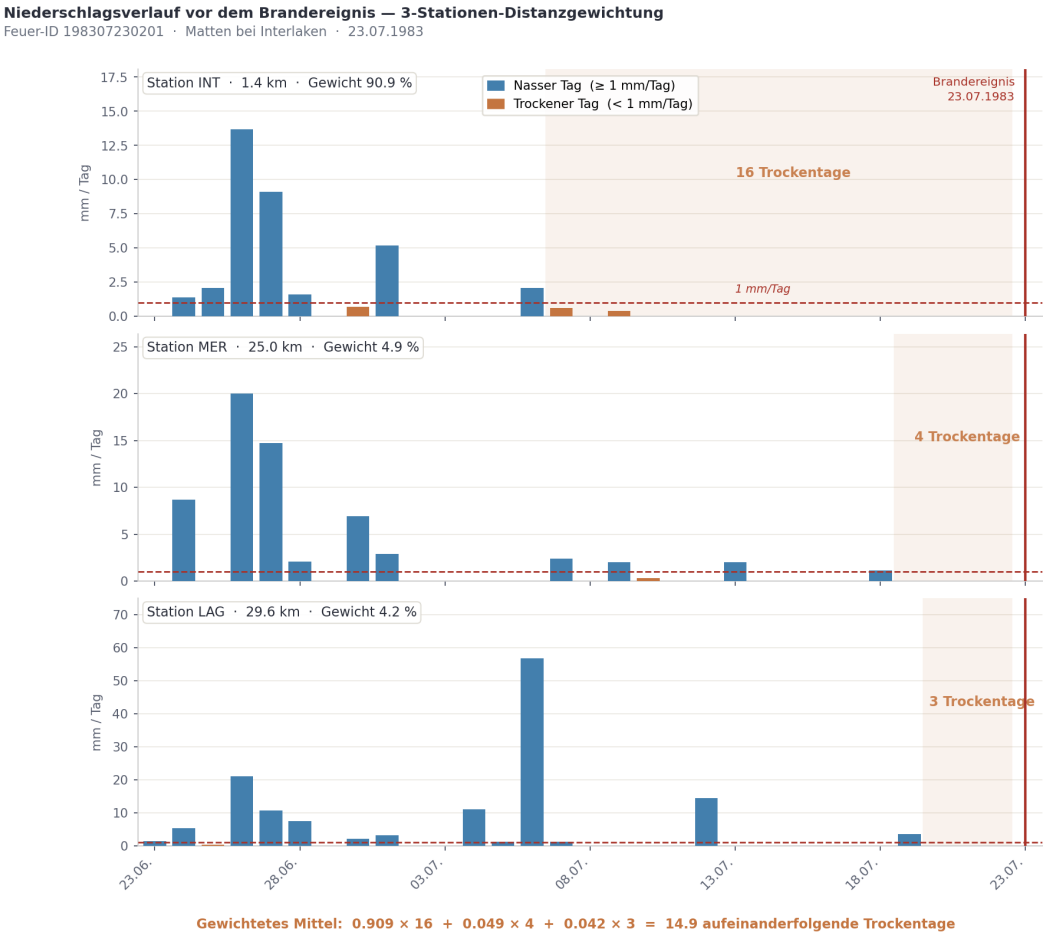


Abbildung 9.1: Kontextfenster Trockentage als gewichteter Niederschlagsverlauf

9.2.4 Vapor Pressure Deficit (VPD)

„VPD [...] oder Dampfdruckdefizit ist ein Mass für die Differenz zwischen der Feuchtigkeitsmenge in der Luft und der Menge, die sie bei vollständiger Sättigung (100 % Luftfeuchtigkeit) aufnehmen könnte“[55]. Damit beschreibt VPD einen Unterdruck [kPa], der eine austrocknende Wirkung auf seine Umgebung ausübt:

> Instead of relative humidity,the more accurate way to express the driving force of water loss from a leaf is vapor pressure deficit[56]

In Abbildung 9.2 wird der Zusammenhang zwischen VPD und relativer Luftfeuchtigkeit deutlich. VPD entspricht hierbei der „Differenz zwischen der Feuchtigkeitsmenge in der Luft bei [100%] Sättigung [...] und der tatsächlichen Feuchtigkeitsmenge in der Luft“[55].[6] Ein Temperaturanstieg von 25°C um 10°C auf 35 °C führt zu einer Erhöhung des VPD um 80% von 2.4 kPa auf 4.5 kPa.[55]

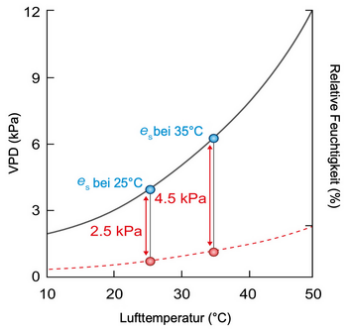


Abbildung 9.2: VPD und relative Luftfeuchtigkeit. Quelle WSL[55]

Damit beschreibt der VPD eine austrocknende Wirkung, die mit steigenden Temperaturen exponentiell anwächst.[7] Damit dürfte gerade der VPD zur Analyse der Feuergefahr ein interessantes Feature sein. So schreibt zum Beispiel W. A. Park et al. [53, S. 900]:

> The temporal stability of the relationship between forest-fire area and VPD indicates that the importance of VPD to forest-fire area was not amplified or overtaken by another climatic or nonclimatic variable during the study period [8]

Die Formel zur Berechnung lautet $VPD = e_s - e_a$.[9] Auf diese Weise kann VPD ohne weiteres den Positiv- wie Negativstichproben hinzugefügt werden.

[6] Wobei die schwarze Linie die 100%-Sättigung anzeigt und die rote gestrichelte Linie die tatsächliche Feuchtigkeitsmenge in der Luft.

[7] Vgl. die Exponentialkomponente der Magnus-Funktion.

[8] Als berücksichtigte Variablen werden in [53, S. 895] aufgeführt: „Climate variables considered in the regression analyses were precipitation total, wetday frequency, mean daily maximum temperature (Tmax), mean daily minimum temperature (Tmin), vapor pressure deficit (VPD), wind speed, solar radiation“ und andere.

[9] Wie in Abschnitt 4.1.1 erläutert. T entspricht dabei dem Tagesmaximum `tre200dx`, da dieses den Zeitpunkt stärkster atmosphärischer Trockenwirkung abbildet.

9.3 Evaluation des kontexterweiterten Modells

Feuerereignisse und auch die Negativstichproben sind um diese Featureerweiterungen zu ergänzen. Dieses neue erweiterte Modell weist nun 15 Features auf. Gewisse Einträge der Feuerereignisse werden entfernt, da hierzu keine oder unvollständige Terraininformationen über swissALTI3D zu erhalten sind. Es bleiben 5157 Feuerereignisse übrig — die Negativstichproben werden ebenfalls entsprechend verkleinert. Nachdem die Balanciertheit der beiden Datensätze sichergestellt ist, kann das Modell erneut trainiert und getestet werden, wobei die Hyperparameter der Vergleichbarkeit halber unangetastet bleiben. Das kontexterweiterte Modell erreicht so einen Train AUC-ROC von 0.9332 und einen **Test AUC-ROC** von **0.9032**, validiert durch einen durchaus akzeptablen Gap von 0.0301.

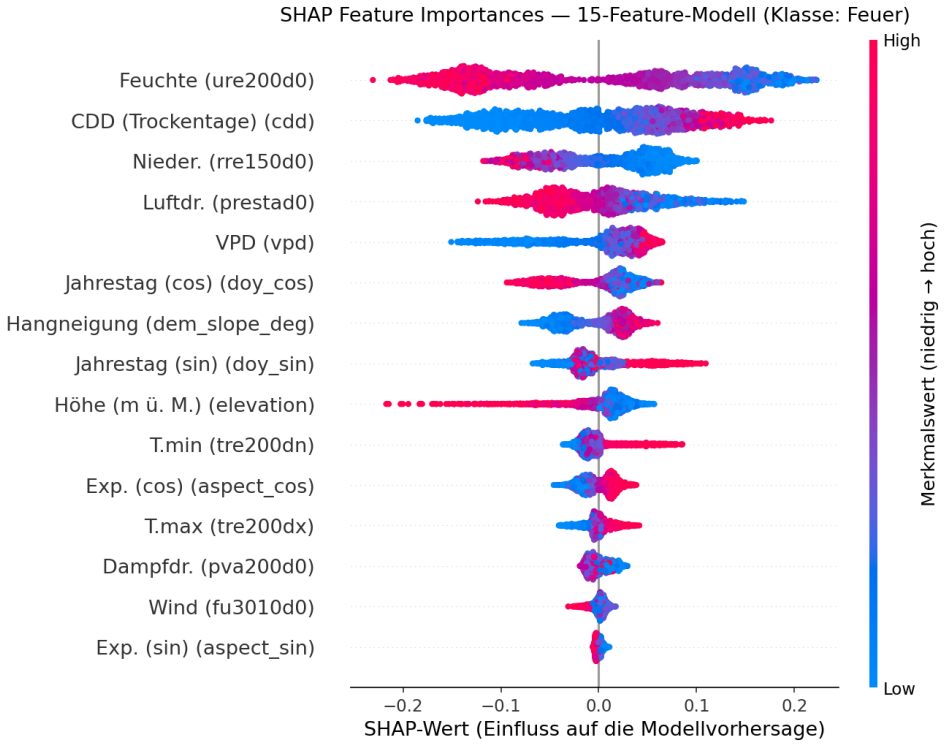


Abbildung 9.3: Volle SHAP-Analyse des kontexterweiterten Modells

9.3.1 Modellvereinfachung durch Featurereduktion

Wenn wir die SHAP-Analyse der 15 Features in Abbildung 9.3 betrachten, fällt auf, dass die fünf Features Exposition (cos), Maximaltemperatur, Dampfdruck, Wind und Exposition (sin) einen mittleren SHAP-Wert von unter 0.015 aufweisen. Dies dürfte vermutlich auf die neu eingeführten vielschichtigeren Features zurückzuführen sein: Der hinzugefügte VPD-Wert erreicht beachtenswerte fünfte Position, und auch Jahrestags-Informationen (in beiden Ausprägungen) erreichen sechst- und achtwichtigste Position. Die errechneten Trockentage (CDD) sind sogar zweitstärkstes

Feature geworden.

Wenn die oben erwähnten, fünf wenigst relevanten Features entfernt werden, erreicht das Modell sogar verbesserte Werte von Train AUC-ROC von 0.9329 und **Test AUC-ROC** von **0.9034**. Das Modell performt also mit reduzierten Features gleich gut oder (vernachlässigbar) besser. Dies könnte allenfalls durch reduzierten *Noise* erklärbar sein. Auch der leicht gesunkene Gap von 0.0296 widerspricht dieser Annahme nicht. In der Confusion Matrix in Abbildung 9.5 ist auch erkennbar, dass der wichtige Wert der **Falschnegativen** durch die Kontexterweiterung des Modells wesentlich gesunken ist und nur noch **192** beträgt.

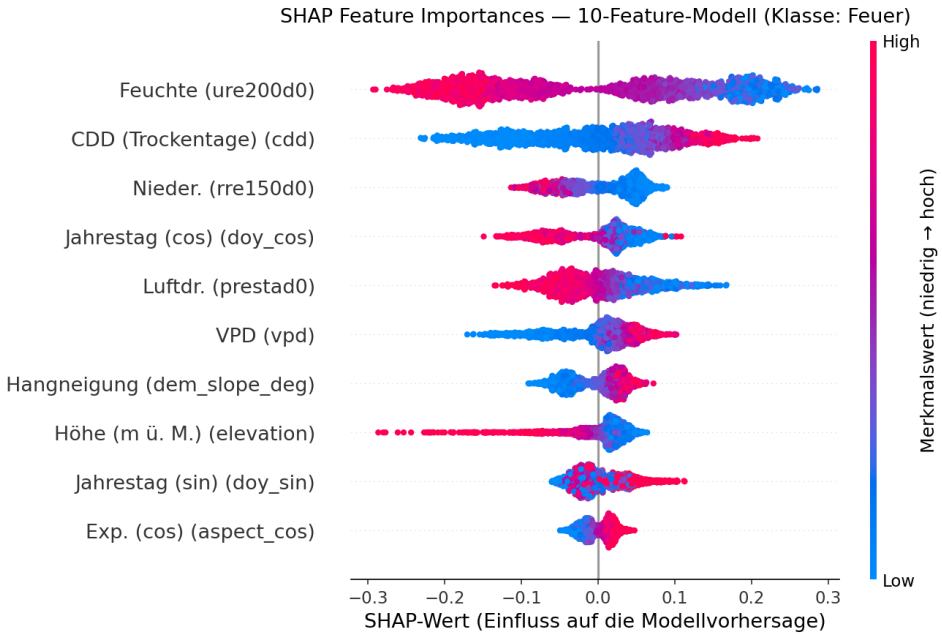


Abbildung 9.4: SHAP-Analyse des gekürzten kontexterweiterten Modells

Die zehn Features, welche in der SHAP-Analyse des reduzierten Modells in Abbildung 9.4 übrigbleiben, zeigen ein wesentlich verändertes Bild, als die SHAP-Analysen in den vorangegangen Kapiteln. Feuchtigkeit als wesentlichstes Feature wird gefolgt vom neu eingeführten Kontext der Trockentage. Beide Features weisen eine deutlich homogene Farbverteilung und Merkmalsrichtung auf, während sie in ihrer Ausprägung gegenläufig zueinander stehen. Nach dem Feature Niederschlag, welches immer noch einen hohen Einfluss auf die Modellvorhersage aufweist und den Features Luftdruck und VPD, bleiben starke nicht-meteorologische Features übrig.

Die Berechnung der Trockentage zeigt erstaunlich starken Einfluss auf die Modellvorhersage. Eine mögliche Erklärung dürfte sein, dass mit den Anzahl Trockentagen nicht nur der eigentliche Niederschlag gemessen wird, sondern implizit auch zu einem gewissen Anteil die Bodenfeuch-

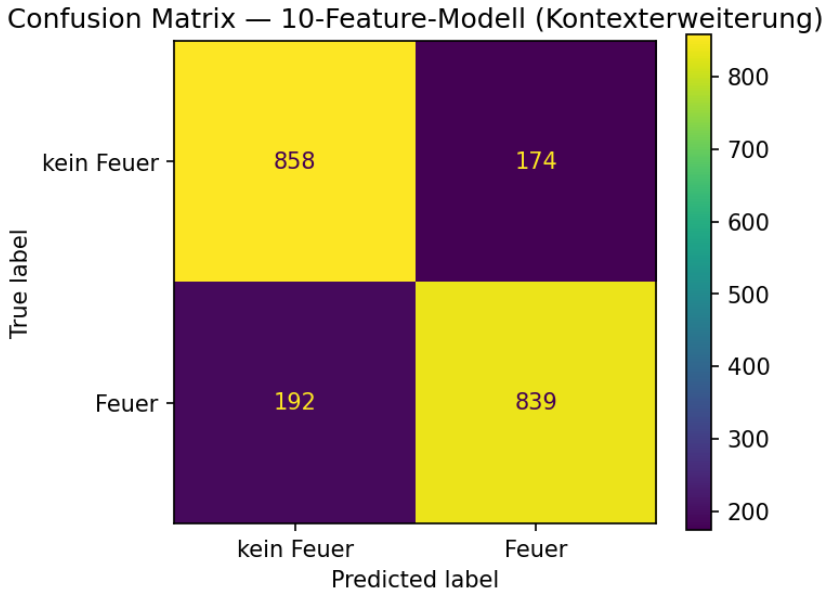


Abbildung 9.5: Confusion Matrix des kontexterweiterten Modells

tigkeit, welche vermutlich eine wesentliche Eigenschaft in der Entstehung eines Waldbrandes spielt.[10]

9.3.2 Diskussion exponentiell gewichteter Akkumulatoren

Wie bereits erwähnt, enthält der FWI auch Berechnungen[54, S. 13], mit welchen Trocknungsprozesse und Bodenfeuchtigkeit exponentiell gewichtet modelliert werden. Diese Herangehensweise wurde als Alternative zum binären Zähler der Trockentage ebenfalls getestet. Hierzu wurde ein exponentiell gewichteter Akkumulator $\sum_{k=0}^{n-1} \lambda^k \cdot x_{p,\,t-k}$ für die Features Niederschlag und Feuchtigkeit eingesetzt. Damit soll jüngeren Tagen höheres Gewicht beigemessen werden, da diese trivialerweise ausdrucksstärker sind.

Entgegen jeglicher Erwartung, führten alle obigen getesteten exponentiellen Erweiterungen zu wesentlich kleineren Verbesserungen der Modellvorhersage, als das in obigem kontexterweiterten Modell eingeführten Kontextfenster der Trockentage. Die exponentiell gewichteten Akkumulatoren wurden zur Überprüfung mit unterschiedlicher Gewichtung getestet. Von den getesteten drei Lambdas 0.7, 0.8, 0.9 wird mit $\lambda = 0.7$ das beste Testergebnis erreicht: Test **AUC-ROC = 0.8730**. Damit liegt dieser Wert sogar leicht unter dem AUC-ROC des vorherigen, rein geländebasierten Modells aus Kapitel 8.4 von 0.8782 und der Test AUC-ROC des kontexterweiterten Modells von 0.9032 wird um gut 3% unterschritten. Dies deutet darauf hin, dass die exponentiell gewichteten Akkumulatoren gegenüber den reinen Geländemerkmalen keinen messbaren Mehrwert bringen, und dass das Kontextfenster der Trockentage in Kombination mit den übrigen Features bereits

[10] Vgl. hierzu auch den Abschnitt zur sensorischen Messung des Untergrundes in Abschnitt 2.3.

deutlich wirksamer ist. Damit liegt auch der Schluss nahe, dass die bestehenden meteorologischen Features vermutlich bereits hinreichend aggregiert sind und auch der temporale Aspekt zu grossen Teilen ausgeschöpft ist. Damit ist nun ebenfalls begründet, dass strukturell andersartige Daten notwendig sind, um die Vorhersagekraft des Modells noch weiter steigern zu können.

10 Strukturerweiterung des Modells

10.1 Grundüberlegungen

Im vorangegangenen Kapitel ist deutlich geworden, dass die meteorologischen Signale bereits weitgehend ausgeschöpft sind. Auch temporale Aspekte sind durch das dreissigtägige Kontextfenster der Trockentage zu einem grossen Teil abgedeckt. Im Folgenden wird das Modell mit statischen Strukturdaten, mittels der folgenden einzelnen TIFFs angereichert:[1]

- Föhnhäufigkeit/Jahr[2]
- Sonnenscheindauer 1991–2020[3]
- Waldmischungsgrad[4]

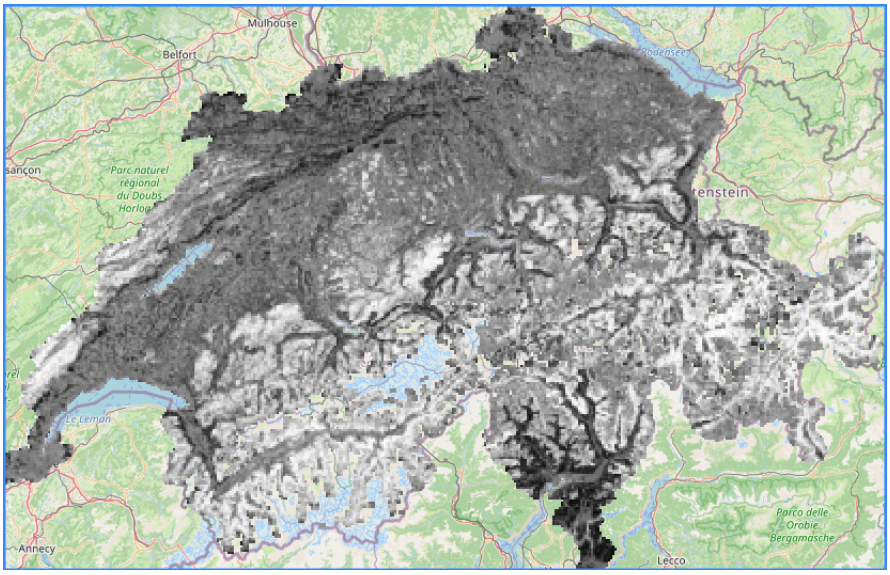


Abbildung 10.1: Waldmischungsgrad (TIF) auf OpenStreetMap-Karte. Quelle: BAFU, OSM[57]

[1] Aufgrund ihrer geringen Erklärkraft wurden MIV-Erreichbarkeit, Bahnlinien- und Distanz zu Wanderwegen als Marker menschlicher Bewegungsmuster nicht weiter in Betracht gezogen.
[2] data.geo.admin.ch/browser/index.html#/collections/ch.bafu.wald-foehnhaeufigkeit_jahr
[3] data.geo.admin.ch/ch.meteoschweiz.ogd-climate-normals-grid/ch/ogd-climate-normals-grid.snormy9120
[4] data.geo.admin.ch/browser/index.html#/collections/ch.bafu.landesforstinventar-waldmischungsgrad

Die Föhnhäufigkeit und Sonnenscheindauer sind Klimanormwerte, und beschreiben strukturelle Branddisposition eines Standortes. Der Waldmischungsgrad ist durch Satellitendaten des Copernicus-Programms[5] der ESA modelliert und stammt vom 31.10.2023.[6]

> the proportion of deciduous and coniferous wood is evaluated nationwide in grid cells with a spatial resolution of 10 metres. A machine learning method is used for this purpose. [...] In the case of the forest mix rate NFI based on the Sentinel-1 and -2 satellite data, the ratio of the visible tree crowns of deciduous and coniferous tree proportions is calculated.[58]

Damit erhält das Modell eine bereits aufbereitete Satellitendatenauswertung, die den Baumbestand bestmöglich beschreiben kann. Der Waldmischungsgrad beschreibt die „Laubgehölzwahrscheinlichkeit pro Pixel“[59] und damit die eigentliche standortspezifische Brennstoffzusammensetzung. Ein Wert von 100 entspricht einem vollständigen Laubbaumanteil, während ein Wert von 0 einem Nadelbaumwald entspricht.[Vgl. 60, S. 44] Dies ist insbesondere daher von Interesse, als dass sich Nadelstreu am Boden schneller entzündet „als der humose Oberboden in einem Laubwald.“[61]

Einziger Nachteil der Daten zum Waldmischungsgrad ist seine Unvollständigkeit. So erhalten wir für die Feuerereignisse in 38% der Fälle leider keine Werte. Mittels Rasterio wird, wie in Listing 10.1 ersichtlich, mittels einem KDTree die unvollständigen Datensätze des Waldmischungsgrads mit dem Wert des nächsten validen Nachbarpixels befüllt.

```
22  # Alle nicht vorhandenen Punkte befuellen:
23  tree = KDTree(valid_coords)
24  query_coords = np.column_stack([
25      df['lv95_east'].values[nan_mask],
26      df['lv95_north'].values[nan_mask],
27  ])
28  # Den jeweils naechsten Nachbar k=1 abfragen:
29  _, idx = tree.query(query\_coords, k=1, workers=-1)
30
31  # Die leeren Eintraege mit nun vorhandenem Waldmischungsgrad befuellen
32  filled = vals.copy()
33  filled[nan_mask] = valid_values[idx]
```

Listing 10.1: Fehlender Waldmischungsgrad mit KDTree befüllen

Wie in Listing 10.2 beschrieben, werden mittels `Rasterio` über die Koordinatenangaben die entsprechenden Werte der jeweiligen Pixel der obigen drei TIFF-Dateien gelesen und schliesslich in ein `NumPyArray` geschrieben und ausgegeben.

[5] https://sentinels.copernicus.eu

[6] Hierbei entspricht die Föhnhäufigkeit dem jährlichen Durchschnitt zwischen 1969 und 2013, die Sonnenscheindauer dem jährlichen Durchschnitt zwischen 1991 und 2020. Für das Unterfangen der Vorhersage ist diese Datengrundlage sicherlich hinreichend genau, auch wenn nicht das komplette Zeitfenster 1982–2025 abgedeckt ist. Selbiges trifft auf den Waldmischungsgrad zu.

```
for e, n in zip(df['lv95_east'], df['lv95_north']):
    [...]
    # Konvertiere LV95-Koordinaten nach Pixel Zeilen/Spalten
    row, col = src.index(e, n)
    v = data[row, col]

    # Ersetze fehlende Sentinel-Daten durch NaN, fuege Eintraege an Liste vals an:
    vals.append(float(v) if (nodata is None or v != nodata) else np.nan)
        [...]
    # Konvertiere Liste vals in ein NumPyArray (float)
    return np.array(vals, dtype=float)
```

Listing 10.2: Auslese TIFF mittels Rasterio

10.1.1 Evaluation der statischen Strukturerweiterung

Nun werden alle Feuerereignisse wie auch die Negativstichproben um diese drei Features erweitert. Aufgrund unvollständiger TIF-Datensätze verlieren wir rund 7% der Feuerereignisse und können nach erneuter Ausbalancierung der Positiv- und Negativstichproben das Modell mit je 5122 Datensätzen trainieren und testen. Dies resultiert in einem Train AUC-ROC von 0.9408 und einem **Test AUC-ROC** von **0.9169**. Die Gap von 0.0239 zeigt auf, dass das Modell eine gute Generalisierungsleistung erreicht.

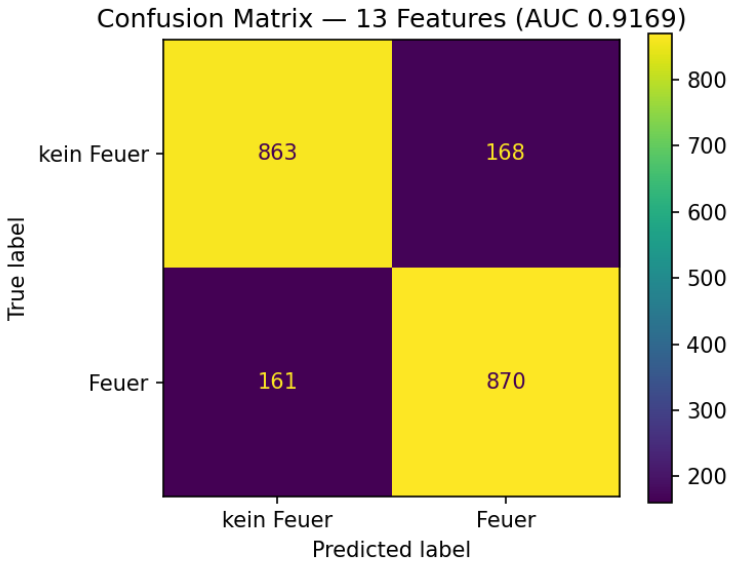


Abbildung 10.2: Confusion Matrix des strukturerweiterten Modells

In der Confusion Matrix in Abbildung 10.2 sind mittlerweile nur noch **161 Falschnegative** ersichtlich. Interessanterweise zeigt die SHAP-Analyse in 10.3 auf, dass die neu hinzugefügten

Features der Föhntage und der Sonnenscheindauer an zweiter und dritter Stelle zu liegen kommen, noch vor dem Kontextfenster der Trockentage. Der Waldmischungsgrad hingegen weist erstaunlicherweise nur wenig Erklärkraft auf. Ein hoher Waldmischungsgrad befördert sogar entgegen unserer Vermutung ein Brandereignis (wenn auch nur in geringem Masse).[7]

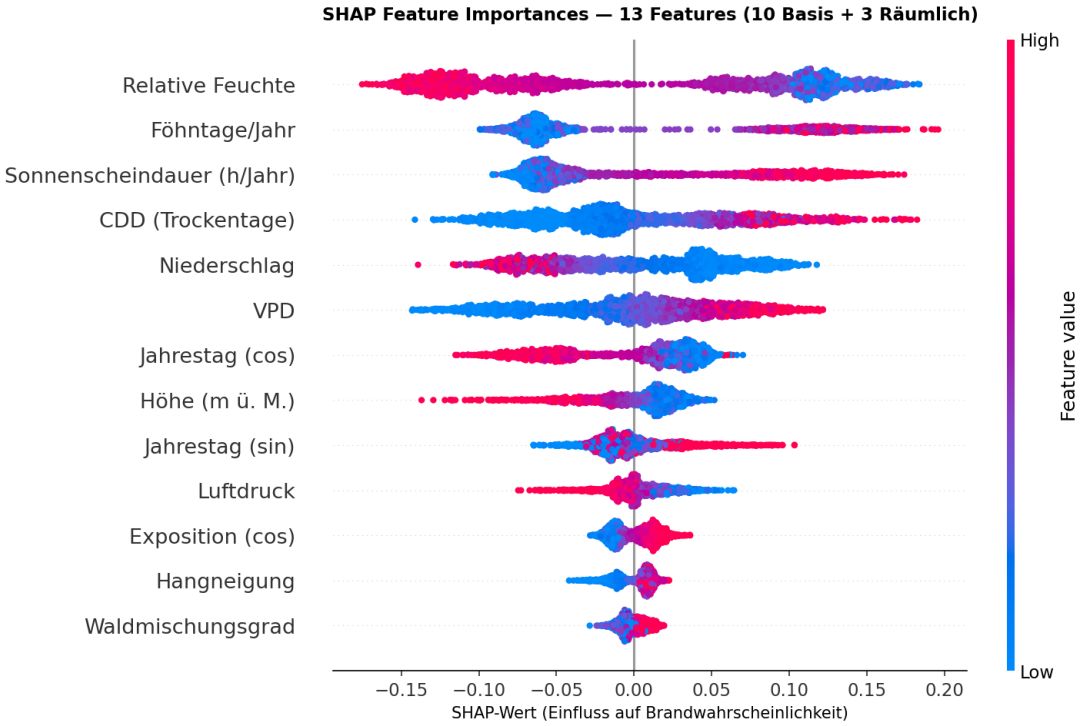


Abbildung 10.3: SHAP Feature Importances des reduzierten strukturerweiterten Modells

Mit der erfolgten Erweiterung der meteorologischen und temporalen Aspekte um statische Strukturdaten scheint die Feature-Auswahl weitgehend ausgeschöpft und erhöht den AUC-ROC nur noch unwesentlich. Vor einer allfälligen Anpassung der Hyperparameter soll im folgenden Kapitel zunächst überprüft werden, ob Random Forest als bisher verwendete Modellklasse tatsächlich die geeignetste Wahl darstellt.

[7] Vgl. Abschnitt 10.1.

11 Modellvergleich

11.1 Grundüberlegungen

Zu Beginn dieser Untersuchung fiel der Entscheid, die Modellklasse *Random Forest* zu benützen. In der Folge wurden Features erweitert und das Modell damit trainiert. Es wurde ersichtlich, dass die allermeisten Feature-Erweiterungen den AUC-ROC nicht beliebig weiter erhöhen, sondern eine gewisse Grenze der Modellierung erreicht wurde. Dies resultierte schliesslich in einem **Test AUC-ROC** von **0.9169**, einer Gap von 0.0239 und **161 Falschnegativen**. In den vorangegangenen Kapiteln sind die ursprünglich gewählten Hyperparameter aus Gründen der Vergleichbarkeit nicht mehr verändert worden. Bevor nun die Hyperparameter erneut überprüft werden, kann untersucht werden, wie robust und generalisierend das Modell tatsächlich ist.

11.2 Verifikation Modellauswahl

In Abschnitt 6.3 wurden die Modellklassen Logistic Regression, Random Forest und XGBoost evaluiert und in der Folge mit dem knappen Sieger Random Forest gearbeitet. Gemäss dem Benchmark von Grinsztajn, Oyallon und Varoquaux [62, S. 5] erreichen *classifier* auf mittelgrossen Datensätzen mit nur numerischen Features mit den folgenden Modellklassen die besten Vorhersagewerte: GradientBoostingTree, XGBoost, RandomForest, HistGradientBoostingTree. Wir fügen diese und weitere bekannte Modellklassen[39, S. 10] hinzu, lassen diese Modelle trainieren und erhalten die in Abbildung 11.1 ersichtlichen Resultate.

Die Boosting-Klassen schneiden tatsächlich äusserst gut ab. CatBoost und LightGBM resultieren beide in einem durchschnittlichen, fünffach kreuzvalidierten AUC-ROC von 0.9604, wobei CatBoost mit einer Standardabweichung von 0.0018 gegenüber einer Standardabweichung von 0.0022 von LightGBM sowie 0.0043 von Random Forest sogar leicht stabiler scheint.

11.3 Modellbewertung

Nachdem eine Suche nach idealen Hyperparametern durchgeführt worden ist[1], erreicht CatBoost[2] einen **Test AUC-ROC** von **0.9632**. Zwar neigt das Modell mit einem Train AUC-ROC von 0.9978 zum Auswendiglernen, aber die moderate **Gap** von **0.0346** zeigt auf, dass die Generalisierungsleistung hoch bleibt.

[1] Siehe `FireRiskModelPipeline/7b_SpatialFeatures_Reduced.ipynb`

[2] Mit Hyperparameter 'learning_rate'=0.1, 'l2_leaf_reg'=9, 'iterations'=1200, 'depth'=4, 'border_count'=254, 'bagging_temperature'=0.

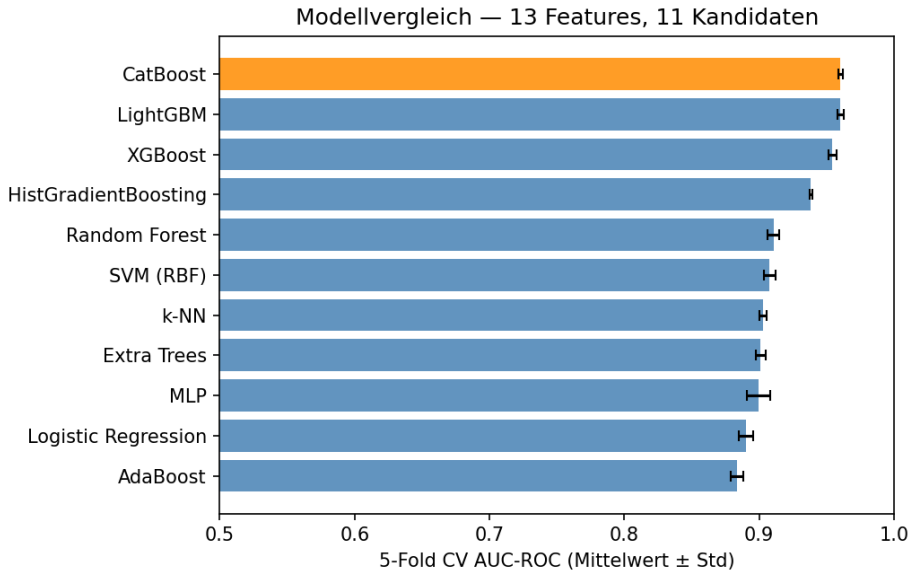


Abbildung 11.1: Vergleich der Modellklassen

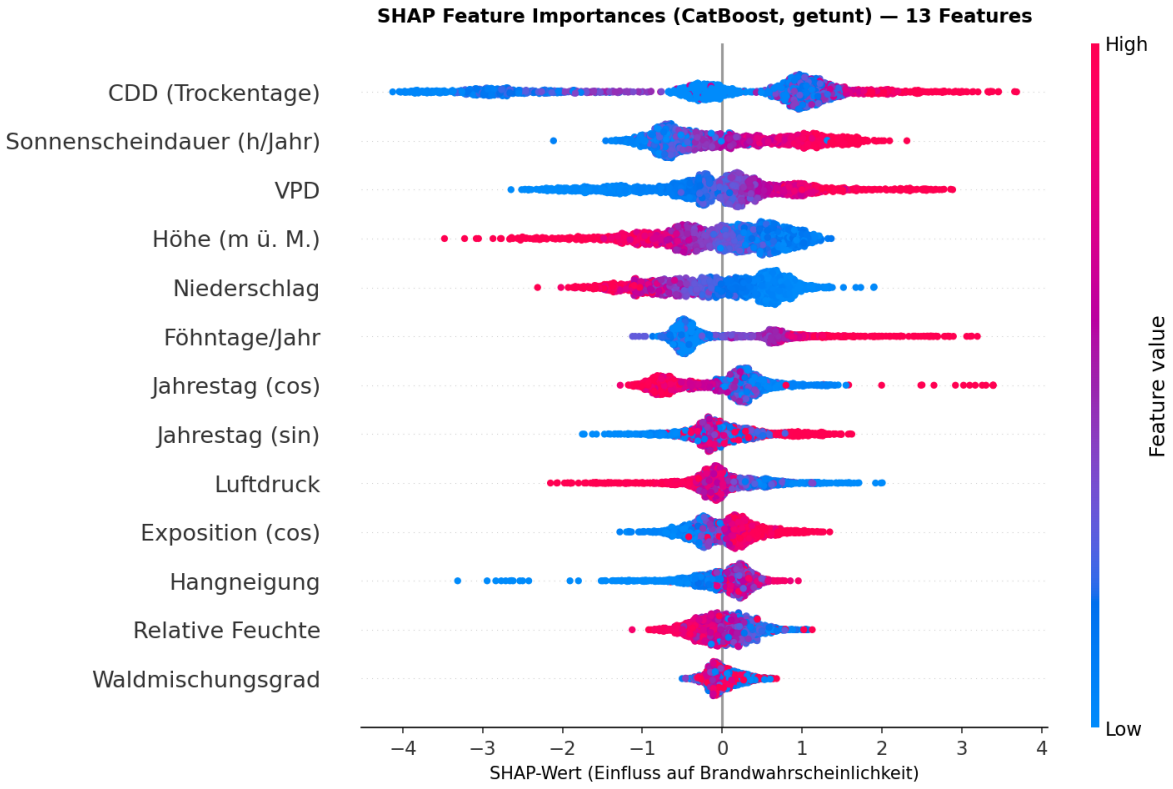


Abbildung 11.2: SHAP-Analyse des finalen Modells mit CatBoost, getuned

Interessanterweise hat der Austausch der Modellklasse zu einer veränderten Feature-Wichtigkeit geführt. Die Anzahl Trockentage ist nun wichtigstes Feature, gefolgt von der Sonnenscheindauer und dem VPD sowie der Höhe. Erstaunlicherweise hat sich das Feature der relativen Feuchtigkeit auf die zweitletzte Position verschoben, gefolgt vom erstaunlich gleichbleibend schwach relevanten Waldmischungsgrad. Auf der x-Achse wird zudem deutlich, wie unterschiedlich CatBoost und Random Forest den Einfluss auf die Brandwahrscheinlichkeit beurteilen.[3]

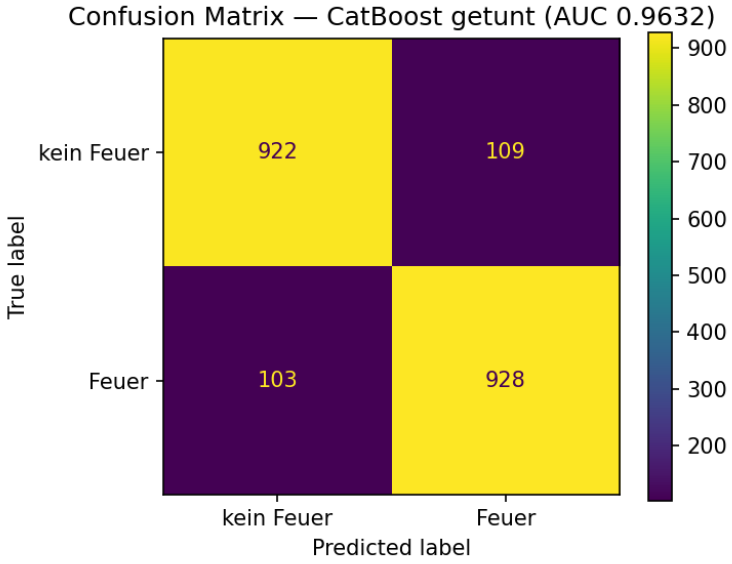


Abbildung 11.3: Confusion Matrix des finalen Modells, getuned

Die Confusion Matrix in Abbildung 11.3 schlüsselt die erhaltenen Werte detaillierter auf. Das Modell erreicht für die Klasse Feuer eine *precision* von 0.8949, einen ***recall*** von **0.9001**. Die für uns interessante Zahl der **Falschnegativen** beträgt damit also **103** – und könnte mit Anpassung des standardmässigen Schwellenwerts von 0.5 entsprechend optimiert werden. *precision* und *recall* sind zu gleichen Teilen im F1-Wert abgebildet, der daher ausgeglichene 0.90 beträgt.

Die Performance des Modells muss aber mit einer gewissen Vorsicht betrachtet werden. Zwar wurden die jeweiligen Trainings- und Testläufe jeweils fünffach kreuzvalidiert und damit in unterschiedliche Trainings- und Testdaten aufgeteilt. Es ist jedoch denkbar, dass zum Beispiel Brände aufgrund räumlicher Nähe sehr ähnliche Wetter-, Terrain- und sonstige Standortmerkmale aufweisen - aufgrund des Splittings aber in Trainings- und Testmenge landen. Damit wäre die Unabhängigkeit von Trainings- und Testdaten verletzt und die Generalisierungsleistung des Modells mit dem entsprechenden AUC-ROC systematisch überschätzt.[Vgl. 63] Weiter muss bedacht werden, dass hier der nachgelagerte Modellwechsel trotz Kreuzvalidierung eine leicht optimistische Verzerrung (*winner's curse*) einführen könnte. Die Differenz zum AUC-ROC des Random Forests

[3] Weswegen hier in der Folge auch auf einen detaillierten Vergleich mit den vorherigen SHAP Feature Importances verzichtet wird.

beträgt aber stattliche 4.35%, also wesentlich mehr als die Standardabweichungen beider Modelle, was diese Bedenken ein wenig abschwächt.

12 Modellevaluierung

12.1 Zeitliche Abhängigkeit und Durchmischung (*Shuffling*)

Obwohl alle bisherigen Modelle randomisiert kreuzvalidiert wurden, ist es denkbar, dass ein Datenleck (*leakage*) die AUC-ROC-, *precision*- und *recall*-Werte optimistisch verzerrt hat.[1] Die räumliche Nähe unterschiedlicher Brandereignisse kann dazu führen, dass ähnliche Feuerereignisse mit vergleichbaren Wetter-, Terrain- und Standortmerkmalen durch ebendiese randomisierten Splits in Trainings- und Testmenge landen und es dadurch zu einem Datenleck kommt.

Die originalen Datensätze der Feuer sind chronologisch geordnet und die bisher implementierten Aufteilungen in Trainings- und Testdaten sind hierbei durch `StratifiedKFolds` `shuffle=True` und der automatischen Durchmischung von `train_test_split` immer zufällig durchmischt (*shuffling*).[2] Diese Durchmischung sollte die Robustheit eines Modells erhöhen. In unserem Fall sind die einzelnen Feuerereignisse aber zeitlich voneinander abhängig und ein Durchmischen der Daten hat keinen positiven Effekt, sondern kann dazu führen, dass zeitlich nah beieinander auftretende Feuer (in geographischer Nähe und damit häufig identischen Meteodaten) sehr ähnlich aussehen und damit gerade durch die Durchmischung in Training- und Testmenge geraten und damit zu einer *Leakage* führen, da das Modell so zu testende Fälle bereits memorisieren konnte.

12.2 Validierung durch Label-*Shuffling*

Um sicherzugehen, dass keine anderen unentdeckten Fehlerquellen zu einem naiv-hohen AUC-ROC führen, können die Werte des Labelvektors (y) durchmischt werden. Die Werte werden mittels `sklearn.model_selection.permutation_test_score` zwanzigmal permutiert und fünffach kreuzvalidiert. Wir erreichen mit diesem Test[3] einen AUC-ROC auf Zufallsniveau von 0.4993 ± 0.0080. Dies zeigt auf, dass das Modell nicht auf geleakten Labels beruht, sondern vielmehr eine echte Beziehung zwischen Features und Labels gelernt hat.

12.3 Räumliche Kreuzvalidierung

Mit obigem *Label-Shuffling* wurde ausgeschlossen, dass das Modell durch leaking Labels lernt. Aus genannten Gründen der zeitlichen Abhängigkeit in Abschnitt 12.1 soll nun vor der Beurteilung unterschiedlicher Schwellenwerte, zunächst quantifiziert werden, inwiefern das Modell von räumlich

[1] Zumindest der vorher erwähnte *winner's curse* dürfte durch die Kreuzvalidierung deutlich reduziert sein.
[2] Diese Durchmischung erfolgt horizontal und ist kein *Label Shuffling* (vgl. weiter unten).
[3] `FireRiskModelPipeline/8_SpatialLeakageValidation.ipynb`

nahen Feuerereignissen profitiert. Im Folgenden soll dazu eine räumlich eingeschränkte Kreuzvalidierung durchgeführt werden, indem die vorhandenen Feuer mit den Negativstichproben zusammen mittels *sklearn.cluster.KMeans* anhand ihrer Koordinaten in acht Regionen aufgeteilt werden. So können jeweils sieben Regionen zusammengefasst als Trainingsmenge dienen und dann gegen die achte Region als unabhängige Testmenge getestet werden.

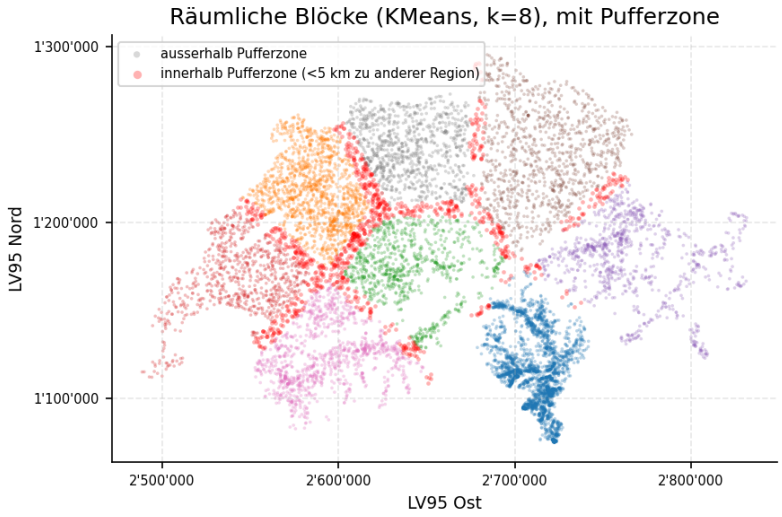


Abbildung 12.1: Karte der räumlichen Blöcke (KMeans, k=8), hervorgehobene Pufferzone ($<$ 5 km zu anderen Regionen).

Da an den Grenzen dieser Regionen das in Abschnitt 12.1 beschriebene Problem weiterbestehen kann, wird nun für jede einzelne Trainingsmenge (jeweils sieben Regionen) mittels einem `KDTree` berechnet, welche Punkte hiervon innerhalb einer gewählten Bufferdistanz von 5 km zur Testmenge zu liegen kommen. Da derart alle Regionen (ohne jeweils eine Testmenge) durchiteriert werden, und die Testmenge jeweils einer anderen Region entspricht, erhalten wir so eine Bufferzone um jede Region, was als rote Punkte in Abbildung 12.1[4] ersichtlich ist. Die entsprechenden Feuer, die in der Bufferzone zu liegen kommen, werden aus der Trainingsmenge entfernt und damit ein räumliches Datenleck möglichst ausgeräumt. Die Testmenge bleibt hiervon jeweils unberührt und dient in ihrer Gesamtheit der Prüfung.

Nun kann `CatBoostClassifier` mit jeder Trainingsmenge trainiert und gegen eine äquivalente Testmenge getestet werden. Vor dieser räumlichen Kreuzvalidierung erreichte das Modell einen Test AUC-ROC von 0.9632, eine *precision* von 0.8949 und einen *recall*-Wert von 0.9001. Mit

[4] Die Kartenpunkte sind Feuer und Non-Feuer (n=2*5155=10310), davon liegen 993 ($\sim$ 9.6%) in einer Bufferzone

der neu eingeführten räumlichen Kreuzvalidierung einen **Test AUC-ROC** von **0.9309** mit einer kleinen Standardabweichung von 0.0093. Das Modell erreicht zudem eine **precision** von **0.8206** und einen **recall**-Wert von **0.8038**. Das räumlich-kreuzvalidierte Modell verliert damit nur 0.0323 an AUC-ROC, 0.0743 *precision* und 0.0963 an *recall*. Damit ist gezeigt, dass die erreichten Werte zu optimistisch waren, aber dennoch bereits eine stabile Generalisierungsleistung erbrachten. Hierbei gilt es anzumerken, dass die starken topografischen Unterschiede und die unterschiedlichen Klimazonen der Schweiz eine besondere Schwierigkeit darstellen, ein Modell zu trainieren und in gewissen Fällen in sehr unterschiedlichen Regionen in seiner Vorhersageleistung zu testen.

12.4 Evaluation Schwellenwert

Wie in Abschnitt 11.3 angeschnitten, sind alle bisherigen Resultate mit einem Schwellenwert[64, Vgl.] von 0.5 erfolgt. Da unser Modell eine möglichst kleine Zahl an Falschnegativen produzieren soll, kann der Schwellenwert angepasst werden. Der Evaluation dazu dient der F2-Wert – er zeigt an, welcher Schwellenwert optimal ist:

> At its core, the F2 score's calculation stems from the harmonic mean of precision and recall, prioritizing recall higher than precision.[65]

Der F2-Wert operiert mit einem arbiträr gesetzten β-Wert, der aussagt, um wie viel *recall* stärker bewertet werden soll, als *precision*. Wir setzen $\beta = 2$, in der Praxis würde dieser Wert als operationelle Vorgabe einer Risikotoleranz gesetzt. Die entsprechende Berechnung[5] resultiert in einem F2-optimalen Schwellenwert von 0.1464 und einem F2-Score von 0.9190. Wie in Abbildung 12.2 ersichtlich, sinkt *precision* auf 0.7727 und steigt zugleich ***recall*** auf **0.9647**.

Ein solcher *recall* bedeutet, dass von 100 Waldbränden (abgerundet) tatsächlich 96 korrekt als solche identifiziert werden. Vier Waldbrände würden jedoch als Falschnegative nicht korrekt erkannt. In der Confusion Matrix 11.3 führte ein Schwellenwert von 0.5 zu rund 10% an Falschnegativen. Mit der spezifischen Gewichtung durch den F2-Wert konnten diese Falschnegativen reduziert werden, dies allerdings durch einen gesunkenen *precision*-Wert und damit einer höheren Fehlalarmrate.

12.5 Evaluation veränderter Trainingsgewichtung

Der `CatBoostClassifier` kann so parametriert werden, dass die Klassen Non-Feuer und Feuer unterschiedlich gewichtet werden. Mittels `class_weights=[1, 2]` wird im Training der Fehlerbeitrag (*Loss*) der Klasse 1 (Feuer) doppelt so stark gewichtet wie der Fehlerbeitrag der Klasse 0 (Non-Feuer).[6] Damit trägt ein falsch klassifiziertes Feuer doppelt soviel zum *Loss* bei, wie ein falsch klassifiziertes Non-Feuer. So ist das Modell stärker dazu angehalten, die korrekte Klassifikation von Feuer zu lernen.

Die obige räumliche Kreuzvalidierung erreicht mit dieser pointierten Trainingsgewichtung einen ***Recall*** von **0.9647** und eine *Precision* von 0.7709. Verglichen mit den obigen Resultaten

[5] Siehe `FireRiskModelPipeline/8_SpatialLeakageValidation.ipynb`
[6] Siehe hierzu CatBoost: class_weights.

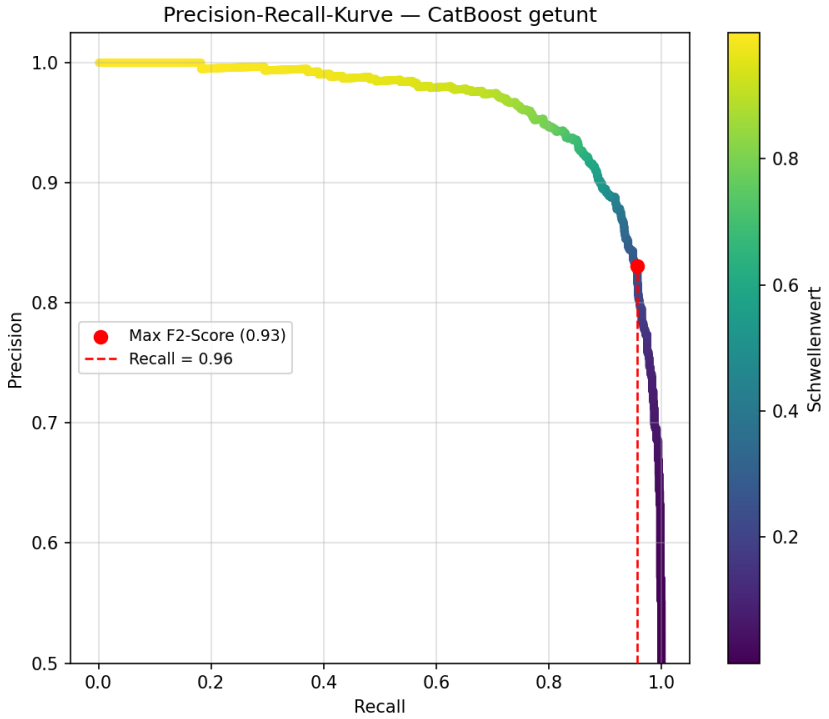


Abbildung 12.2: Precision-Recall-Kurve mit idealem F2-Wert 0.93

des angepassten Schwellenwerts in Abschnitt 12.4 bleibt der *Recall* also identisch und die *Precision* verändert sich in einem vernachlässigbaren Bereich. Veränderter Schwellenwert und veränderte Trainingsgewichtung zeigen damit äquivalente Vorhersageleistung.

13 Konklusion und Ausblick

13.1 Abschliessendes Ergebnis der Modellierung

Die vorliegende Arbeit ging der Frage nach, ob und inwiefern Waldbrände in der Schweiz mittels Machine Learning prognostiziert werden können. Insbesondere sollte dabei geprüft werden, inwiefern die Waldbrandvorhersage durch das Einpflegen zusätzlicher meteorologischer, aber auch topografischer Parameter zu einer genaueren Vorhersage führen als die bestehenden Vorhersagemodelle. Der Vergleichbarkeit halber wurden dazu zuerst bestehende Vorhersagemodelle[1] und technische Ausprägungen diskutiert. Für die eigentliche Modellierung wurden alle erfassten Schweizer Waldbrände explorativ analysiert und die Datengrundlage existierender Meteo- und Topografiedaten untersucht. Mittels dieser auf den Zeitraum 1982 – 2025 eingeschränkten Datengrundlage wurden testweise erste Machine Learning Modelle trainiert und evaluiert. Mit der Modellklasse `Random Forest` erfolgte der weitere Modellausbau, gestützt durch SHAP-Analysen der jeweiligen *Feature Importances*. Die benutzte Modellklasse ermöglicht die Interpretierbarkeit der *Features* und erleichtert damit Plausibilisierung und allenfalls eine spätere Weiterentwicklung.

Zusätzliche Features verbesserten die Vorhersage zu Beginn deutlich, zeigten aber auch abnehmenden Grenznutzen. Nach der Verbesserung der für das Training benötigten Negativstichproben und der Featureerweiterung um unterschiedlichste Aspekte besteht das Modell schliesslich aus dreizehn Features. Nach einer finalen Modellevaluation erfolgt der Einsatz der Modellklasse *CatBoost*, mit welcher das Modell nach Tuning der Hyperparameter einen **Test AUC-ROC** von **0.9632**, eine *precision* von 0.8949 und einen ***recall*-Wert** von **0.9001** erreicht. Der moderate Gap von 0.0346 deutet auf eine gute Generalisierungsleistung des Modells hin. Diese erreichten Vorhersagewerte wurden schliesslich durch *Label-Shuffling* und räumlicher Kreuzvalidierung zusätzlich geprüft, wobei letztere selbst für die klimatisch heterogene Geografie der Schweiz einen AUC-ROC von 0.9309 mit einer *precision* von 0.8206 und einen *recall*-Wert von 0.8038 erreicht.

Da eine Brandvorhersage idealerweise eine möglichst kleine Zahl an Falschnegativen hervorbringt, erlaubt die Anpassung des Schwellenwerts des finalen Modells schliesslich die Senkung der *precision* auf 0.7727 und das Erreichen eines ***recalls*** von **0.9647**: Damit erkennt das Modell von 100 Waldbränden tatsächlich rund 96 korrekt als solche. Als Falschnegative nicht korrekt erkannt würden davon vier Waldbrände. Damit ist gezeigt, dass die Vorhersage von Waldbränden in der Schweiz mit einem einfachen Modell[2] mit dreizehn *Features* mit den in Abschnitt 2 besprochenen

[1] Die meisten Vorhersagemodelle sind keine klassischen Machine Learning-Modelle in einem engeren Sinne.

[2] Das erzeugte Modell ist energieeffizient und läuft auf einfacher Hardware: Intel Core i7, 2.7 GHz, 24 GB Arbeitsspeicher, keine dedizierte GPU.

Modellen mithalten kann und gute Resultate zeigt.

Im nächsten Abschnitt 13.2 wird aufgezeigt, inwiefern das Modell mit einigen Anpassungen als einfache Webapplikation tagesaktuelle Waldbrandvorhersagen auf Grundlagen neuster meteorologischer Daten vornehmen kann. Im abschliessenden Abschnitt werden schliesslich die theoretischen Erkenntnisse aus der Modellierung mit den Ergebnissen der praktischen Anwendung zusammengeführt und ein Ausblick auf mögliche Weiterentwicklung geworfen. Siehe hierzu Abschnitt 13.3, der diskutiert, inwiefern *Features* reduziert werden könnten, wenn die Anzahl an Messstationen erhöht würde.

13.2 Praktische Anwendung des Modells

Zusätzlich zu obigen Resultaten des Modells soll im Folgenden diskutiert werden, ob und inwiefern aus obigem Modell eine anwendbare Applikation zur Vorhersage von Waldbränden entstehen kann. Zur tagesaktuellen Waldbrand-Gefahrenbewertung sollen die Modellresultate auf einer Karte in einer Webapplikation darstellbar werden, die in der Folge idealerweise tagesaktuelle Vorhersagen erlaubt. Das Modell muss für diesen Zweck nicht mehr nur die Feuerwahrscheinlichkeit einer Negativstichprobe berechnen, sondern für jeden Quadratkilometer der Schweiz. Dies erlaubt schliesslich die Erstellung einer *Heatmap* zur visuellen Gefahrenbewertung.[3] Für ein gegebenes Datum erhält so jede 1 km-Rasterzelle eine Vorhersagewahrscheinlichkeit der bereits benutzten `CatBoost`-Pipeline des Trainings und damit der dreizehn Features des in Abbildung 11.2 abgebildeten finalen Modells. Diese Resultate werden über einer interaktiven Kartenbasis gerendert, die als Webapplikation abrufbar ist. Der wesentliche Aufbau dieser in Abbildung 13.2 abgebildeten Applikation ist im Folgenden erläutert und ihre schematische Funktionsweise in Abbildung 13.1 illustriert:

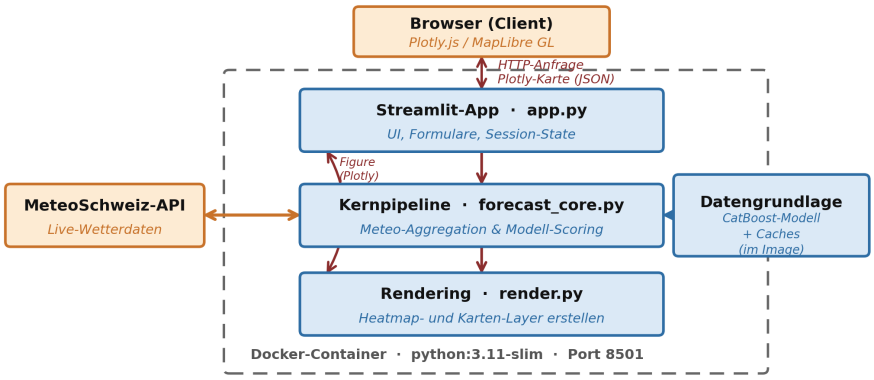


Abbildung 13.1: Illustration des Techstacks der containerisierten Webapplikation

[3] Der Entscheid für den Quadratkilometer als Rastereinheit ist einerseits pragmatisch (Rechenzeit), aber auch technisch bedingt aufgrund unterschiedlich hoher Auflösung der verschiedenen ins Modell eingeflossenen Layer.

i) Um die technische Umsetzung als *proof of concept* vorerst möglichst einfach zu halten, fiel der Entscheid auf `streamlit.io` als Backend, mit welchem mit akzeptablem Aufwand Python-Skripte in eine Webapplikation integriert werden können. Dazu wurde das finale Modell in ein CBM-File **catboost_final_model.cbm** überführt.[4]

ii) Dieses CBM-File wurde mit Swisstopo-Basiskarteninformationen mit Terrain, Föhnhäufigkeit, Sonnenscheindauer, Waldmischungsgrad und den Feuerereignissen 1982 – 2025 und den ursprünglichen sieben Meteoparameter aller 26 Messstationen (1982 – 2025) (inkl. Meta-Stationsdaten) in Verzeichnis `data` abgelegt. Beim Starten der Applikation durch **app.py** werden diese Datensätze durch `forecast_core.load_everything()` geladen.

iii) Das Skript **forecast_core.py** lädt nun mit dem CBM-File das eigentliche Modell. Die Wetterdaten von 1982 – 2025 sind lokal bereits abgelegt. So ist es nun möglich, dass alle notwendigen Features und sonstige benötigten Daten dem Modell zugeführt werden und für den per GUI ausgewählten gewünschten Tag des Forecasts durch **render.py** eine Karte gerendert wird, die durch Swisstopo-Informationen angereichert und zoombar ist.

iv) Das Modell wurde mit Feuerereignissen von 1982 bis Ende 2025 trainiert, soll nun aber aktuelle Vorhersagen leisten können. Dazu werden Meteodaten mittels `_refresh_with_live_data()` parallel für alle Stationen heruntergeladen. Solcherart ist es nun schliesslich möglich, dass alle notwendigen Features und sonstige benötigten Daten dem Modell zugeführt werden und die aktuelle Waldbrandgefahr wie in Abbildung 13.3 abgebildet, auf einer Karte visualisierbar ist.

Die Applikation ist im projektinternen Repository über ein mitgeliefertes `Dockerfile` containerisiert und kann damit ohne manuelle Installation der Abhängigkeiten lokal gebaut und betrieben werden.

13.2.1 Farbskala zur Bewertung der Feuerwahrscheinlichkeit

Die erhaltenen ersten Resultate zeigten zunächst leider ein Kalibrierungsproblem: Die feste Farbskala über dem Intervall $[0, 1]$ stellt starke Hitzetage einheitlich und grossflächig rot dar. Diese absolute Darstellung der Feuerwahrscheinlichkeit lässt wenig Raum bezüglich der relativen Gefährdung einzelner Regionen. Um die interessante räumliche Struktur der Feuerwahrscheinlichkeit deutlicher herauszustreichen, bietet sich die pragmatische Lösung an, die Feuerwahrscheinlichkeit nicht absolut, sondern als *relative* Feuerwahrscheinlichkeit des jeweiligen Tages darzustellen. Dazu wird die Feuerwahrscheinlichkeit tagesbezogen auf Basis des 5. bis 95. Perzentils normiert: Dadurch werden 90% der Feuer (enthalten in $[P5, P95]$) auf einen Intervall $[0, 1]$ gelegt und damit ein wenig „gedehnt“ – der Grossteil der Feuer wird so auf dem kompletten Farbintervall detaillierter farblich abbildbar.[5] Dieser Kunstgriff ist auf der Kartendarstellung vermerkt, hat aber den erwähnten Nachteil einer tagesrelativen Darstellung.

[4] Siehe CatBoost: save_model.

[5] Die niedrigsten und höchsten 5% Feuerwahrscheinlichkeit werden dafür sozusagen ununterscheidbar an den jeweiligen Enden komprimiert dargestellt.

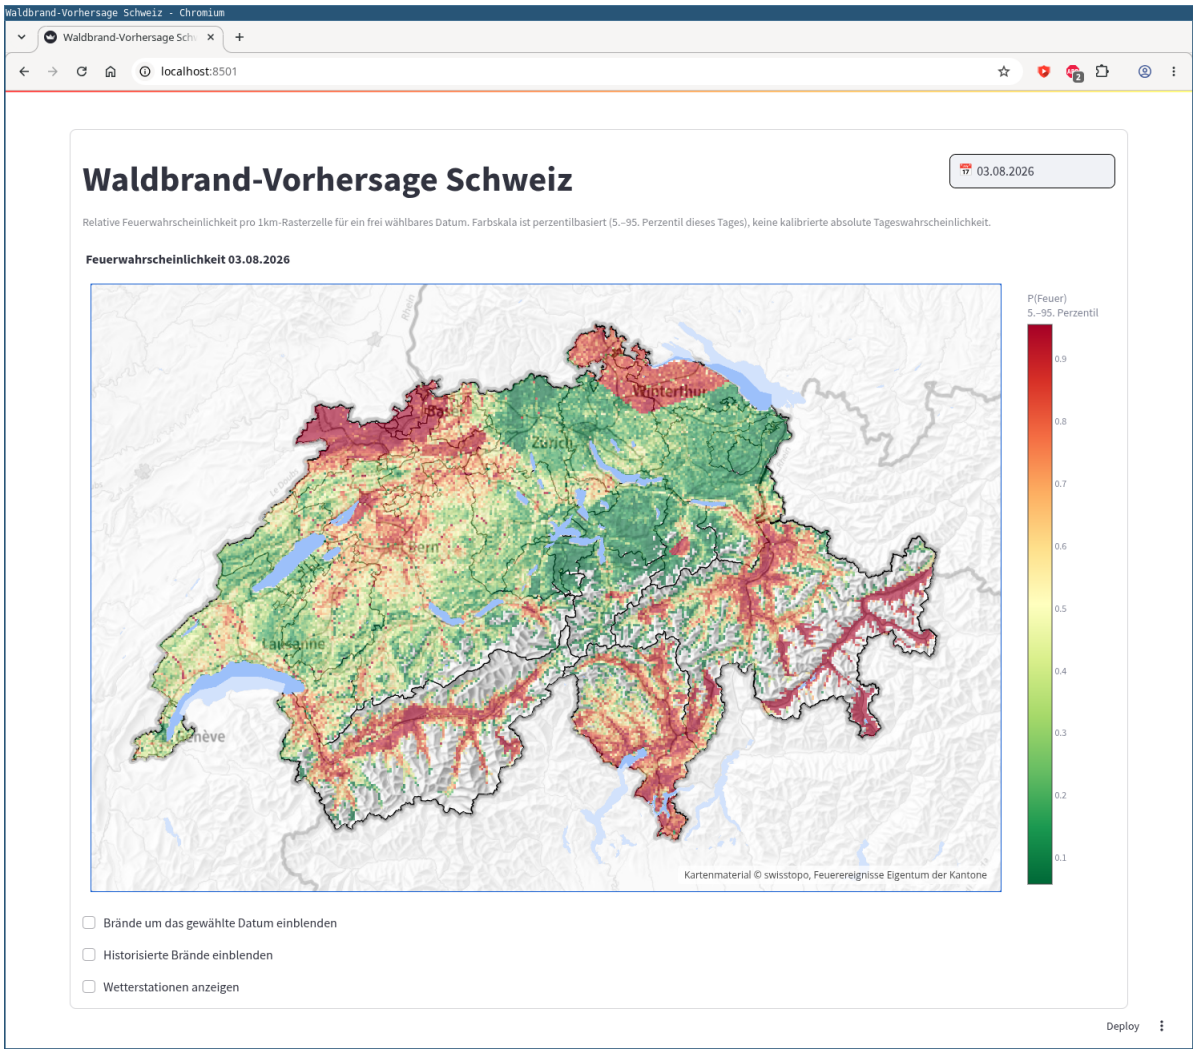


Abbildung 13.2: Screenshot der Webapplikation

13.2.2 Visuelle Plausibilisierung

Das Modell generiert nun mittels Meteodaten tatsächlich auch tagesaktuelle Vorhersagen, wie in Abbildung 13.3 ersichtlich ist.

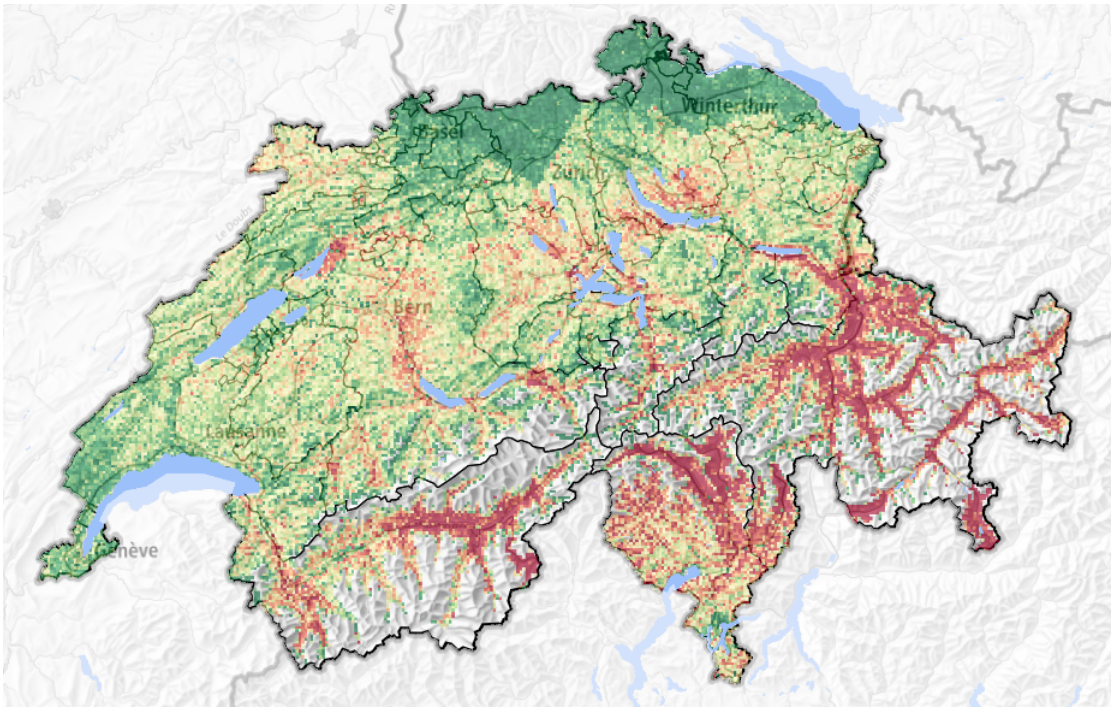


Abbildung 13.3: Visuelle Vorhersage vom 30.08.2026

Eine optische Plausibilisierung der Vorhersage in der Webapplikation kann (für den Zeitraum 1982 – 2025) durch das Einblenden der historisierten Brände erfolgen. In der Abbildung 13.4 beispielsweise ist das Gebiet eines Brandes zur Illustration eingefügt, welches weiter oben (siehe Abbildung 2.3) als IGNIS-Gefahrenkarte abgebildet wurde.

Die visuelle Überprüfung vermag zu plausibilisieren, aber aufgrund fehlender Daten aus den existierenden Vorhersageprogrammen ist eine quantitative Überprüfung – selbst wenn sie denn möglich wäre – nicht durchführbar. Mit dieser Webapplikation zur Vorhersage ist aber gezeigt, dass ein Transfer des theoretischen Modells in eine praktische Anwendung möglich ist und mit bestehenden Anwendungen vergleichbar zu sein scheint.

13.3 Zusammenführung und Ausblick

Sicherlich würde das Modell allgemein von gleichmässiger verteilten[6] und in ihrer Anzahl erhöhten Messstationen profitieren. Gerade von Waldbränden stark betroffene Regionen wie das Wallis oder das Tessin sind auf eine einzelne respektive zwei Stationen vor Ort angewiesen und der Beitrag der nahegelegensten Nachbarstationen ist aufgrund der Gewichtung durch die grosse Distanz

[6] Vgl. hierzu Abschnitt 5.1.

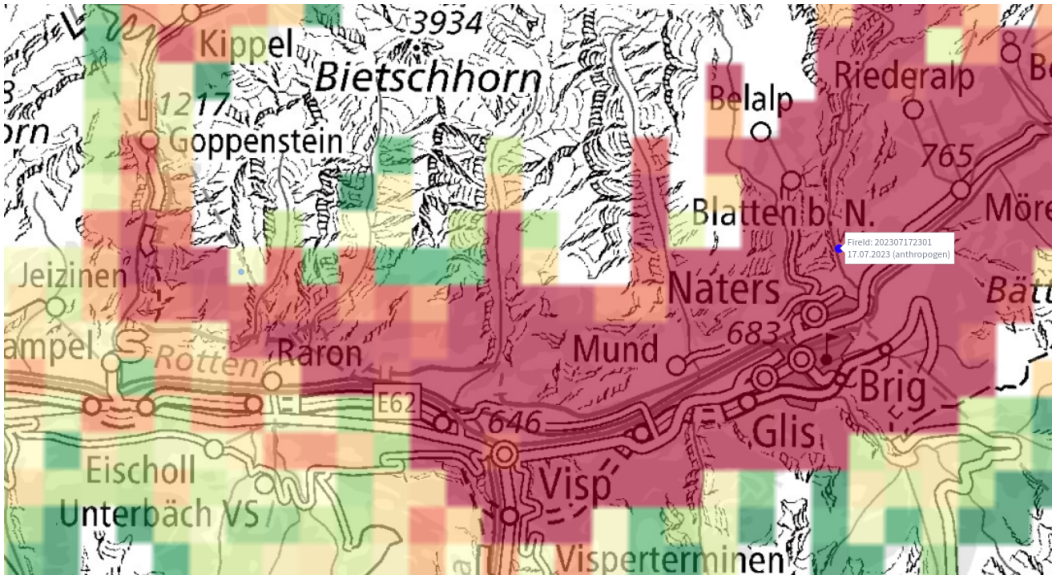


Abbildung 13.4: Screenshot um Ortschaft Bitsch (Wallis) am Brand vom 17.07.2023 (markiert)

sowie der Topografie offensichtlich ungünstig. An gewissen Tagen sind auf den visualisierten Vorhersagekarten durchaus Fragmente sichtbar[7], die vermutlich darauf zurückzuführen sind, dass die ausgewählten 26 Messstationen ungleichmässig verteilt sind.[8]

Diese Selektion der Messstationen erfolgte aufgrund der ursprünglich sieben ausgewählten Parameter.[9] Wenn nun die SHAP-Analyse des finalen Modells in Abbildung 11.2 betrachtet wird, zeigt sich, dass von diesen sieben Parametern einzig fünf mehr gebraucht werden. Denn die fünf Parameter Niederschlag, Luftfeuchtigkeit, Luftdruck (und indirekt Maximaltemperatur und Dampfdruck) reichen aus, um die meteorologischen Features in der SHAP-Analyse in Abbildung 11.2 zu bilden (neben der Unterfütterung durch statische Werte wie Föhntage oder Hangneigung). Das finale Modell benötigt daher tatsächlich weniger meteorologische Parameter als das Ursprungsmodell zu Beginn dieser Untersuchung. Ein Modell welches weniger meteorologische Parameter benötigt, erlaubt damit bestenfalls den Zugriff auf eine grössere Anzahl an Messstationen und erhält damit eine höhere meteorologische Abdeckung. Es ist daher denkbar, dass ein Modell mit weniger *Features* dadurch eine genauere und insbesondere detaillierte Vorhersage leisten könnte. Zukünftig werden immer mehr Messstationen mit den benötigten Parametern aufwarten und eine höhere Auflösung ermöglichen.

Weiter basieren die diskutierten Ergebnisse der Modellierung aus einem Training mit Feuerereignissen der ganzen Schweiz. Insbesondere die topografischen Ausprägungen lassen vermuten, dass auch eine Reduktion des Trainings auf einzelne klimatisch homogenere Regionen die Modell-

[7] Siehe zum Beispiel die schroffe Kante in der Region um Winterthur in Abbildung 13.2.
[8] Vermutlich dürften es sich bei diesen Fragmenten um sogenannte *Voronoi-Diagramme* handeln. Siehe hierzu: [66].
[9] Siehe Abschnitt 4.2.1.

leistung steigern dürfte.[10]

Von diesen Schwachpunkten abgesehen, zeigt obiger Abschnitt 13.1 auf, dass das Modell gute Vorhersagewerte erreicht, und dies auch im Vergleich mit den in Kapitel 2 beschriebenen Vorhersagemodellen. Den durch Anpassung des Schwellenwerts erreichten *recalls* von **0.9647** dürfte sich daher trotz obiger Optimierungsmöglichkeiten und allenfalls ausgeklügelterer und aufwändigerer Modellklassen, sehr wahrscheinlich einer natürlichen Grenze angenähert haben, die jeglicher Vorhersage von Bränden innewohnt: dem Zufall.

[10] Vgl. hierzu die Diskussion über räumliche Kreuzvalidierung in Abschnitt 12.3.

Glossar

2-d-Baum	k-d-Baum mit Ausprägung k=2 zur Speicherung und Suche von zweidimensionalen Punkten
BAFU	Bundesamt für Umwelt
Cloud-Optimized GeoTIFF	GeoTIFF via HTTP
curl	Kommandozeilen-Tool zum Senden von HTTP-Requests
DEM	Digital Elevation Model
ESA	Europäische Weltraumorganisation
FireLess II	Frühwarnsystem mit sensorischer Feuchtigkeitsmessung
FireNiche	FireNiche: Statistische Methode zur Waldbrandgefahrerkennung
FWI	Canada's Fire Weather Index System
GeotTIFF	TIFF-Format für georeferenzierte Rasterbilder
GIS	Geoinformationssystem
jq	Kommandozeilen-Tool zum Transformieren und Filtern von JSON-Datensätzen
JSON	Datenformat zum Übertragen und Speichern strukturierter Daten
LINDAS	Linked Data Services: offene, strukturierte Schweizer Behördendaten
LV03	Schweizer Landeskoordinaten, Koordinatensystem von 1903 (veraltet)
LV95	Schweizer Landeskoordinaten, Koordinatensystem von 1995
Meteoschweiz	Bundesamt für Meteorologie und Klimatologie
OcCC	Beratende Organ für Fragen der Klimaänderung (Organe consultatif sur les changements climatiques)
OSM	OpenStreetMap
ProClim	Forum for Climate and Global Change der SCNAT
Rasterio	Software zum Lesen von TIFF
SCNAT	Akademie der Naturwissenschaften Schweiz
Semantic Web	Maschinenlesbares, graphenorientiertes World Wide Web
SHAP	Shapley Additive Explanations
SPARQL	Protokoll mit Abfragesprache des Semantic Web
STAC	Spatial Temporal Asset Catalog
swissALTI3D	hochpräzise digitale Höhenmodell der Schweiz
Swissfire	Datenbank der Waldbrände in der Schweiz
swisstopo	Bundesamt für Landestopografie
Taupunkt	Temperatur zu welcher Wasserdampf kondensiert
TIFF	Tag Image File Format - Grafikformat für Rasterbilder
WSL	Eidgenössische Forschungsanstalt für Wald, Schnee und Landschaft

Literatur

1. BAFU. *Faktenblatt Gefahrenprozess Waldbrand*. URL: https://www.bafu.admin.ch/dam/de/sd-web/k8JGHQ65qz6M/waldbrand.pdf (besucht am 18. 05. 2026).
2. MeteoSchweiz. *Tägliche Vorhersage der Waldbrandgefahr mit IGNIS*. URL: https://www.meteoschweiz.admin.ch/ueber-uns/meteoschweiz-blog/de/2025/04/vorhersage-der-waldbrandgefahr-mit-ignis.html (besucht am 18. 05. 2026).
3. BAFU. *Waldbrandgefahr.ch*. URL: https://www.waldbrandgefahr.ch (besucht am 18. 05. 2026).
4. MeteoSchweiz. *ICON-Prognosesysteme*. URL: https://www.meteoschweiz.admin.ch/wetter/warn-und-prognosesysteme/icon-prognosesysteme.html (besucht am 18. 05. 2026).
5. Natural Resources Canada. *Canada's Fire Weather Index System*. 1.2025. URL: https://natural-resources.canada.ca/forests-forestry/wildland-fires/canada-fire-weather-index-system (besucht am 21. 05. 2026).
6. Kantonales Amt für Feuerwesen, Kanton Wallis. *Kantonales Waldbrandbekämpfungskonzept*. URL: https://www.vs.ch/documents/19446297/19603979/1204_01+Kantionales+Waldbrandbek%C3%A4mpfungskonzept.pdf/83f6c27f-bec3-4975-b00a-f91f8602f78c?t=1433332938242&v=1.0 (besucht am 26. 08. 2026).
7. Naturgefahrenfachstellen des Bundes. *Aktuelle Lage Naturgefahren*. URL: https://www.naturgefahren.ch/#hazards-tab=forestfire (besucht am 24. 05. 2026).
8. Schweizerisches Bundesarchiv. *Forest fire danger*. URL: https://environment.ld.admin.ch/foen/gefahren-waldbrand-warnung/1 (besucht am 24. 05. 2026).
9. Schweizerisches Bundesarchiv. *Query Data*. URL: https://environment.ld.admin.ch/sparql/#content-query-data (besucht am 24. 05. 2026).
10. Kanton Wallis - vs.ch. *Die aktuelle Waldbrandgefahr im Kanton Wallis*. URL: https://www.vs.ch/de/web/sfnp/incendi (besucht am 25. 06. 2026).
11. Bulletin Valais Wallis (Archiv Amtsblatt). *Achtung Waldbrände!* 2.2013. URL: https://www.bulletinvalaiswallis.ch/de/nachrichten/achtung-waldbrande-1926 (besucht am 25. 06. 2026).
12. Amt für Wald, Kanton Graubündnen. *Waldbrandbekämpfung in Graubünden*. URL: https://www.gr.ch/DE/institutionen/verwaltung/diem/awn/dokumentenliste_afw/3_8_1_waldbrandbekaempfung_in_graubuenden.pdf (besucht am 06. 08. 2026).
13. S. Blum. *Eine neue Methode warnt vor Waldbrand*. 2.2012. URL: https://www.waldwissen.net/assets/waldwirtschaft/schaden/brand/wsl_fireless2/download/wsl_fireless2_originalartikel1.pdf.pdf (besucht am 18. 05. 2026).

14. WSL. *FireNiche: Statistische Methode zur Erkennung von Waldbrandgefahr*. URL: https://www.wsl.ch/de/services-produkte/fireniche (besucht am 18. 05. 2026).
15. A. De Angelis, C. Ricotta, M. Conedera und G. B. Pezzatti. „Modelling the Meteorological Forest Fire Niche in Heterogeneous Pyrologic Conditions“. *PLOS ONE* 10:2, 2015, e0116875. DOI: 10.1371/journal.pone.0116875.
16. A. Jiménez-Valverde. „Insights into the area under the receiver operating characteristic curve (AUC) as a discrimination measure in species distribution modelling“. *Global Ecology and Biogeography* 21:4, S. 498–507. DOI: https://doi.org/10.1111/j.1466-8238.2011.00683.x.
17. M. Markov, S. M. Ailuro, L. V. Gool, K. Schindler und D. P. Paudel. *FireScope: Wildfire Risk Raster Prediction with a Chain-of-Thought Oracle*. URL: https://firescope.ai/research/ (besucht am 07. 08. 2026).
18. M. Markov, S. M. Ailuro, L. V. Gool, K. Schindler und D. P. Paudel. *FireScope: Wildfire Risk Raster Prediction with a Chain-of-Thought Oracle*. 2026. arXiv: 2511.17171 [cs.CV]. URL: https://arxiv.org/abs/2511.17171.
19. WSL. *Swissfire*. URL: https://www.wsl.ch/de/services-produkte/swissfire (besucht am 22. 05. 2026).
20. swisstopo. *Landestriangulation LV03*. 8.2024. URL: https://www.swisstopo.admin.ch/de/transformationen-3d-lage (besucht am 20. 05. 2026).
21. swisstopo. *Transformationen (3D / Lage)*. 8.2024. URL: https://www.swisstopo.admin.ch/de/transformationen-3d-lage (besucht am 20. 05. 2026).
22. BAFU. *Waldbrandgefahr FAQs*. URL: https://www.waldbrandgefahr.ch/de/fragen (besucht am 20. 05. 2026).
23. SCNAT. *Hitzesommer 2003. Synthesebericht.* 2005. URL: https://scnat.ch/de/uuid/i/8a4a432d-77cc-5849-9200-7698c624bd7a-Hitzesommer_2003 (besucht am 24. 05. 2026).
24. MeteoSchweiz. *Niederschlags-Klimastationen - Homogene Messreihen*. URL: https://opendatadocs.meteoswiss.ch/c-climate-data/c2-climate-percipitation-stations_homogeneous (besucht am 29. 05. 2026).
25. MeteoSchweiz. *Nutzungsbedingungen (Open Data Dokumentation)*. URL: https://opendatadocs.meteoswiss.ch/general/terms-of-use (besucht am 29. 05. 2026).
26. MeteoSchweiz. *Climate stations - Homogeneous data series (NBCN)*. URL: https://data.geo.admin.ch/browser/index.html#/collections/ch.meteoschweiz.ogd-nbcn (besucht am 29. 05. 2026).
27. MeteoSchweiz. *ch.meteoschweiz.ogd-nbcn*. URL: https://data.geo.admin.ch/api/stac/v1/collections/ch.meteoschweiz.ogd-nbcn (besucht am 29. 05. 2026).
28. MeteoSchweiz. *ch.meteoschweiz.ogd-nbcn_meta_stations*. URL: https://data.geo.admin.ch/ch.meteoschweiz.ogd-nbcn/ogd-nbcn_meta_stations.csv (besucht am 29. 05. 2026).
29. MeteoSchweiz. *ch.meteoschweiz.ogd-nbcn_meta_parameter*. URL: https://data.geo.admin.ch/ch.meteoschweiz.ogd-nbcn/ogd-nbcn_meta_parameters.csv (besucht am 29. 05. 2026).

30. MeteoSchweiz. *ch.meteoschweiz.ogd-nbcn/items*. URL: https://data.geo.admin.ch/api/stac/v1/collections/ch.meteoschweiz.ogd-nbcn/items (besucht am 29. 05. 2026).
31. MeteoSchweiz. *Homogene Messreihen ab 1864*. URL: https://www.meteoschweiz.admin.ch/klima/grundlagen-fuer-die-klimaanalyse-daten-und-methoden/homogene-messreihen-ab-1864.html (besucht am 24. 06. 2026).
32. D. Bolton. „The Computation of Equivalent Potential Temperature“. *Monthly Weather Review* 108:7, 1980, S. 1046–1053. DOI: 10.1175/1520-0493(1980)108<1046:TCOEPT>2.0.CO;2. URL: https://journals.ametsoc.org/view/journals/mwre/108/7/1520-0493_1980_108_1046_tcoept_2_0_co_2.xml.
33. Canadian Forest Service Fire Danger Group. „The 2025 Update to the FWI System: Structure, Changes and Interpretation“, 2025. URL: https://publications.gc.ca/collections/collection_2026/rncan-nrcan/Fo123-2-42-2025-eng.pdf.
34. MeteoSchweiz. *Automatische Wetterstationen*. URL: https://opendatadocs.meteoswiss.ch/a-data-groundbased/a1-automatic-weather-stations (besucht am 25. 06. 2026).
35. swisstopo. *Landesvermessung LV95*. URL: https://www.swisstopo.admin.ch/de/landesvermessung-lv95 (besucht am 26. 06. 2026).
36. docs.scipy.org. *scipy.spatial.KDTree*. URL: https://docs.scipy.org/doc/scipy/reference/generated/scipy.spatial.KDTree.html (besucht am 26. 06. 2026).
37. scikit-learn.org. *Choosing the right estimator*. URL: https://scikit-learn.org/stable/machine_learning_map.html (besucht am 02. 07. 2026).
38. educative.io. *Scikit-learn cheat sheet: methods for classification & regression: Classification algorithm guide*. URL: https://www.educative.io/blog/scikit-learn-cheat-sheet-classification-regression-methods#Classification-algorithm-guide (besucht am 02. 07. 2026).
39. A. Shmuel, O. Glickman und T. Lazebnik. „A Comprehensive Benchmark of Machine and Deep Learning Across Diverse Tabular Datasets“, 2024. arXiv: 2408.14817 [cs.LG]. URL: https://arxiv.org/abs/2408.14817.
40. developers.google.com. *Datasets: Class-imbalanced datasets*. 28.2025. URL: https://developers.google.com/machine-learning/crash-course/overfitting/imbalanced-datasets (besucht am 02. 07. 2026).
41. MeteoSchweiz. *Globaler Klimawandel - aktueller Wissenstand*. URL: https://www.meteoschweiz.admin.ch/klima/klimawandel/globaler-klimawandel-aktueller-wissensstand.html (besucht am 02. 07. 2026).
42. developers.google.com. *AUC (Area under the ROC curve)*. 13.2026. URL: https://developers.google.com/machine-learning/glossary/metrics#auc-area-under-the-roc-curve (besucht am 02. 07. 2026).
43. geeksforgeeks.org. *Stratified K Fold Cross Validation*. 15.2025. URL: https://www.geeksforgeeks.org/machine-learning/stratified-k-fold-cross-validation/ (besucht am 03. 07. 2026).

44. scikit-learn.org. *StratifiedKFold*. URL: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.StratifiedKFold.html#sklearn.model_selection.StratifiedKFold (besucht am 03. 07. 2026).
45. geeksforgeeks.org. *Pruning Decision Trees*. 2.2026. URL: https://www.geeksforgeeks.org/machine-learning/pruning-decision-trees/ (besucht am 09. 07. 2026).
46. A. Cooper. *How Shapley Values Work*. 31.2022. URL: https://www.aidancooper.co.uk/how-shapley-values-work/ (besucht am 10. 07. 2026).
47. swisstopo. *REST Interface: Spatial Temporal Asset Catalog API*. 31.2022. URL: https://www.geo.admin.ch/en/rest-interface-stac-api (besucht am 12. 07. 2026).
48. swisstopo. *swissALTI3D*. 8.2024. URL: https://www.swisstopo.admin.ch/en/height-model-swissalti3d (besucht am 12. 07. 2026).
49. Eidgenössischen Departements für auswärtige Angelegenheiten. *Geografie*. 17.2023. URL: https://www.aboutswitzerland.eda.admin.ch/de/geografie (besucht am 16. 07. 2026).
50. MeteoSchweiz. *Typische Wetterlagen im Alpenraum*. URL: https://www.meteoswiss.admin.ch/dam/jcr:7fc86ff0-23d6-41df-85c8-c66c92eee634/Typische_Wetterlagen_DE_low.pdf (besucht am 16. 07. 2026).
51. Landwirtschaft und Wald, Kanton Luzern. *Leitfaden Waldbrand*. URL: https://lawa.lu.ch/-/media/LAWA/Dokumente/Wald/Wald_und_Klima/Leitfaden_Waldbrand_Kanton_Luzern.pdf?rev=b297ff2a0a30489c8d3ed013a850a3a2 (besucht am 16. 07. 2026).
52. MeteoSchweiz. *Luftfeuchtigkeit*. URL: https://www.meteoschweiz.admin.ch/wetter/wetter-und-klima-von-a-bis-z/luftfeuchtigkeit.html (besucht am 22. 07. 2026).
53. W. A. Park et al. „Observed Impacts of Anthropogenic Climate Change on Wildfire in California“. *Earth's Future 7(8)* 10:8, 2019, S. 892–910. DOI: https://doi.org/10.1029/2019EF001210.
54. C. V. Wagner. *Development and structure of the Canadian Forest Fire Weather Index System*. 1987. URL: https://ostrnrcan-dostrncan.canada.ca/entities/publication/d96e56aa-e836-4394-ba29-3afe91c3aa6c (besucht am 23. 07. 2026).
55. WSL. *Was ist VPD?* URL: https://vpdrought.wsl.ch/de/was-ist-vpd/ (besucht am 22. 07. 2026).
56. Heidi Wollaeger and Erik Runkle. *VPD vs. Relative Humidity*. URL: https://www.canr.msu.edu/uploads/resources/pdfs/vpd-vs-rh.pdf (besucht am 22. 07. 2026).
57. OpenStreetMap contributors. *Planet dump retrieved from https://planet.osm.org*. 2017.
58. BAFU. *Forest mix rate NFI*. URL: https://data.geo.admin.ch/browser/#/collections/ch.bafu.landesforstinventar-waldmischungsgrad (besucht am 31. 07. 2026).
59. WSL/BAFU. *Interaktive Karte Waldmischungsgrad des Landesforstinventar*. URL: https://www.lfi.ch/de/karten/waldmischungsgrad?mapX=2660000&mapY=1139978.0862&zoom=3.903238538439554 (besucht am 31. 07. 2026).

60. WSL/BAFU. *Schweizerisches Landesforstinventar*. URL: https://www.lfi.ch/media/documents/publikationen/ergebnisberichte/LFI4_Ergebnisbericht.pdf (besucht am 31. 07. 2026).
61. Naturschutzbund Deutschland. *Warum brennen unsere Wälder?* URL: https://www.nabu.de/natur-und-landschaft/waelder/lebensraum-wald/26646.html (besucht am 31. 07. 2026).
62. L. Grinsztajn, E. Oyallon und G. Varoquaux. „Why do tree-based models still outperform deep learning on tabular data?“, 2022. arXiv: 2207.08815 [cs.LG]. URL: https://arxiv.org/abs/2207.08815.
63. T. Mucci. *Was ist ein Datenleck beim maschinellen Lernen?* URL: https://www.ibm.com/de-de/think/topics/data-leakage-machine-learning (besucht am 11. 08. 2026).
64. developers.google.com. *Thresholds and the confusion matrix*. 12.2026. URL: https://developers.google.com/machine-learning/crash-course/classification/thresholding (besucht am 11. 08. 2026).
65. deepgram.com. *F2 Score*. URL: https://deepgram.com/ai-glossary/f2-score (besucht am 08. 05. 2025).
66. F. S. Bellelli. *The fascinating world of Voronoi diagrams*. 2021. URL: https://fbellelli.com/posts/2021-07-08-the-fascinating-world-of-voronoi-diagrams/ (besucht am 09. 02. 2026).